

可信机器学习 课程笔记 (Lecture 01—07)

AutoPku · 整理

2026-05-12

Contents


课程概览	3
课程脉络	4
各讲速览	6
全局术语中英对照	7
期中复习路线图	9
Lecture 01 —可信机器学习课程概览 (Course Overview)	10
0. 核心问题 / Motivation	10
1. 课程组织	10
2. 从 AI 到可信 ML	11
3. 为什么需要”可信”?	11
4. 六大模块预览	12
5. 学习路径建议	13
6. 概念关系图	13
7. 关键术语速查 (中英对照)	13
8. 各维度之间的内在联系	14
9. 课程外的阅读建议	15
9.5 课程方法论: 从”为什么”到”怎么改”	15
9.6 易混淆术语速辨	15
10. 期中复习要点	16
10. 期中复习要点	16
Lecture 02 —机器学习基础 (Introduction of Machine Learning)	17
0. 核心问题 / Motivation	17
1. 函数类型	17
2. ML 训练三步范式	18
3. 从线性到深度	19
4. 评估与过拟合	20
5. 分类的特殊处理	22
6. 概念关系图	22
7. 记号速查	22
8. 期中复习要点	23
Lecture 03 —卷积神经网络 (Convolutional Neural Network, CNN)	24
0. 核心问题 / Motivation	24
1. Observation 1: 局部特征 → Receptive Field	24
2. Observation 2: 模式平移不变 → Parameter Sharing	25
3. 两种等价视角	26
4. 卷积运算的具体计算	26
5. Observation 3: 子采样 → Pooling	26
6. 完整 CNN Pipeline	27

7. 三大设计原则的统一总结	27
8. 一个完整例题	28
9. 概念关系图	29
10. 记号速查	29
10.5 训练 CNN 时的常见技巧	30
11. 经典 CNN 架构纵览	30
12. 期中复习要点	31
Lecture 04 —可解释机器学习 (Explanations: LIME & Shapley)	32
0. 核心问题 / Motivation	32
1. 解释方法的分类	32
2. LIME (Local Interpretable Model-Agnostic Explanations)	33
3. 从博弈论引入: Shapley Value	34
4. 一个完整例题	36
5. LIME vs Shapley 对比	36
6. 概念关系图	37
7. 记号速查	37
8. 期中复习要点	38
Lecture 05 —Saliency Map 与 Class Activation Map (CAM)	39
0. 核心问题 / Motivation	39
1. Saliency Map: 梯度即解释	39
2. CAM: Class Activation Map	40
3. Saliency vs CAM 对比	42
4. 一个完整例题	42
5. 概念关系图	43
5.5 其他 Saliency 变种 (拓展)	43
5.6 Sanity Check: 解释方法本身要被怀疑	44
6. 记号速查	44
7. 期中复习要点	44
Lecture 06 —对抗攻击 (Adversarial Attack)	45
0. 核心问题 / Motivation	45
1. 白盒攻击 (White-box)	46
2. 黑盒攻击 (Black-box)	47
3. 物理对抗攻击 (Physical AE)	49
4. 关键攻击算法对照表	49
5. 一个完整例题	50
6. 概念关系图	50
7. 记号速查	50
8. 期中复习要点	51
Lecture 07 —对抗防御 (Adversarial Defense)	52
0. 核心问题 / Motivation	52
1. 对抗训练 (Adversarial Training) 基础	52
2. FOSC: 度量“内 Max 是否解好了”	53
3. AWP: 从权重 Loss Landscape 视角	54
4. Accuracy-Robustness Trade-off 与 TRADES	55
5. MART: Misclassified Examples 视角	56
6. 三种改进对照	56
7. 一个完整例题	57
8. 概念关系图	57
9. 记号速查	57
10. 期中复习要点	58

课程概览

本课程 **可信机器学习 (Trustworthy Machine Learning)** 由王奕森 (Yisen Wang) 老师在北大信智学院开设 (25–26 学年第 2 学期)。在经典 ML 主要关注 **准确率 / 效率** 的基础上，本课系统介绍如何让模型同时满足 **可解释性、鲁棒性、隐私、公平、安全 (后门)** 等多维“可信”属性。前 7 讲覆盖 **基础 → 可解释 → 对抗鲁棒** 三个模块，是后续模块的方法论基础。

课程脉络



各讲速览

Lec	主题	关键概念	文件
01	课程概览 / 可信 ML 全景	六大模块, Mitchell 定义, 失败案例	lec01_overview.md
02	机器学习基础	function/loss/GD 三步, sigmoid 复合, softmax+CE, 过拟合, bias-complexity	lec02_ml_introduction.md
03	卷积神经网络	Receptive Field, Parameter Sharing, Pooling, 输出尺寸公式	lec03_cnn.md
04	可解释 ML (Model-Agnostic)	LIME (局部线性代理), Shapley (4 公理 + 公式)	lec04_explanations_lime_shapley.md
05	可解释 ML (Model-Specific)	Saliency Map, SmoothGrad, CAM, Pokémon vs Digimon 案例	lec05_saliency_cam.md
06	对抗攻击	min-max, FGSM, BIM, PGD, C&W, 黑盒 Transfer/Query, EOT	lec06_adversarial_attack.md
07	对抗防御	AT (Madry), FOSC, AWP, TRADES, MART	lec07_adversarial_defense.md

全局术语中英对照

中文	English	缩写	首次出现
可信机器学习	Trustworthy Machine Learning	TML	Lec 01
机器学习	Machine Learning	ML	Lec 01
深度学习	Deep Learning	DL	Lec 01
鲁棒性	Robustness	–	Lec 01
可解释性	Explainability / Interpretability	–	Lec 01
公平性	Fairness	–	Lec 01
隐私	Privacy	–	Lec 01
后门攻击	Backdoor Attack	–	Lec 01
损失函数	Loss Function	L	Lec 02
梯度下降	Gradient Descent	GD	Lec 02
随机梯度下降	Stochastic Gradient Descent	SGD	Lec 02
学习率	Learning Rate	η	Lec 02
超参数	Hyperparameter	–	Lec 02
均方误差	Mean Squared Error	MSE	Lec 02
平均绝对误差	Mean Absolute Error	MAE	Lec 02
交叉熵	Cross-Entropy	CE	Lec 02
过拟合	Overfitting	–	Lec 02
模型偏差	Model Bias	–	Lec 02
偏差-方差权衡	Bias-Variance Trade-off	–	Lec 02
交叉验证	Cross Validation	CV	Lec 02
卷积神经网络	Convolutional Neural Network	CNN	Lec 03
感受野	Receptive Field	–	Lec 03
参数共享	Parameter Sharing	–	Lec 03
滤波器 / 卷积核	Filter / Kernel	–	Lec 03
步长	Stride	s	Lec 03
填充	Padding	p	Lec 03
池化	Pooling	–	Lec 03
全局平均池化	Global Average Pooling	GAP	Lec 03
特征图	Feature Map	–	Lec 03
模型无关	Model-Agnostic	–	Lec 04
模型相关	Model-Specific	–	Lec 04
局部可解释模型	LIME (Local Interpretable Model-Agnostic Explanations)	LIME	Lec 04
局部代理模型	Local Surrogate Model	–	Lec 04
合作博弈	Cooperative Game	–	Lec 04
边际贡献	Marginal Contribution	–	Lec 04
显著图	Saliency Map	–	Lec 05
类激活图	Class Activation Map	CAM	Lec 05
反向传播	Backpropagation	BP	Lec 05
捷径学习	Shortcut Learning	–	Lec 05

中文	English	缩写	首次出现
对抗样本	Adversarial Example	AE	Lec 06
快速梯度符号法	Fast Gradient Sign Method	FGSM	Lec 06
基础迭代法	Basic Iterative Method	BIM	Lec 06
投影梯度下降	Projected Gradient Descent	PGD	Lec 06
白盒攻击	White-box Attack	–	Lec 06
黑盒攻击	Black-box Attack	–	Lec 06
迁移性	Transferability	–	Lec 06
物理对抗	Physical Adversarial	–	Lec 06
变换期望	Expectation over Transformations	EOT	Lec 06
对抗训练	Adversarial Training	AT	Lec 07
一阶静止条件	First-Order Stationary Condition	FOSC	Lec 07
对抗权重扰动	Adversarial Weight Perturbation	AWP	Lec 07
准确率-鲁棒性权衡	Accuracy-Robustness Trade-off	–	Lec 07
错分样本	Misclassified Examples	–	Lec 07
梯度遮蔽	Gradient Masking / Obfuscation	–	Lec 07

期中复习路线图

[TIP] 全局复习思路

1. 回路 1 —ML 基础回顾: Lec 02–03, 能徒手写出”三步范式 + CNN 三大原则”2. 回路 2 —可解释: Lec 04–05, 能默写 LIME 算法 4 步、Shapley 公式 (4.5)、CAM 推导 (5.4–5.7)。3. 回路 3 —对抗: Lec 06–07, 能默写 FGSM/BIM/PGD 三式 + AT min-max + FOSC + 三大改进 (AWP/TRADES/MART) 的损失公式。4. 跨章节联系: – CNN (Lec3) → CAM (Lec5): CAM 要求 GAP + 线性分类层 (ResNet 架构) – 可解释 (Lec4–5) → 攻击 (Lec6): Saliency / Shapley 能用来诊断模型为何被对抗样本骗 – 攻击 (Lec6) → 防御 (Lec7): AT 的 inner-max 就是 PGD, FOSC 度量它的解质量 5. 概念题预测: – 给个具体 CNN 配置算输出尺寸 / 参数量 – 3 玩家手算 Shapley value – 写出 PGD 一步的具体更新 – 写出 AT min-max 并解释每个 max 的物理含义 – FOSC 闭式公式 (7.3) 的推导

Lecture 01 —可信机器学习课程概览 (Course Overview)

[TIP] 学习指南

本节核心：建立“可信机器学习 (Trustworthy ML)”的总体认知框架，理解为什么传统 ML 不再够用，并对课程的六大支柱 (可解释性 / 公平性 / 隐私 / 鲁棒性 / 后门 / 伦理) 形成直观印象。前置知识：本科概率论、线性代数、基本的机器学习概念 (训练 / 测试 / 损失函数)。重点关注：(1) 可信 ML 的定义与传统 ML 的差异；(2) 六大模块各自要解决的核心问题；(3) 学术写作中常出现的英文术语对照。

0. 核心问题 / Motivation

近十年来，机器学习模型 (尤其是深度神经网络) 在感知、语言、决策等任务上取得了人类难以企及的精度。然而当模型被部署到 **真实物理世界** 与 **高风险决策场景** (司法、医疗、金融、自动驾驶) 时，它的“高准确率”光环就远远不够了。本课程的主线问题是：

如何在保证准确率与效率的同时，让机器学习系统对“鲁棒性 / 隐私 / 公平 / 可解释 / 安全”等多维度可信属性同时负责？

王奕森老师在课程定位上明确：本课不是一门工程实战课，而是带学生进入可信 ML 这一研究前沿领域，建立批判式思考能力，能够 (a) 识别模型的不可信表现、(b) 设计相应的防御 / 改进机制、(c) 阅读最新顶会论文。

1. 课程组织

1.1 教学信息

- 授课教师：王奕森 (Yisen Wang)，北大信智学院
- 邮箱：yisen.wang@pku.edu.cn
- 助教：Ang Li (charles_li@stu.pku.edu.cn)、Taiye Chen (yeyutaihan@stu.pku.edu.cn)
- 办公室：理科 2 号楼 2201

1.2 评估方式

作业	主题	占比
HW 1	Explanations (可解释性)	25%
HW 2	Privacy (隐私)	25%
HW 3	Robustness (鲁棒性)	25%
HW 4	Backdoor (后门)	25%

- 作业形式：填代码 (fill the code)。工作量不重，无期末考。
- 课堂会有作业 review，鼓励发言交流。

- 优秀率 (excellence rate) 不设限制——课程鼓励大家把作业做扎实，最终拿到优 (A/A+) 的学生数不被强制控制。

[WARN] 易错点

“无考试”≠“轻松”。本课作业偏向论文式编程任务 (例如 PGD 攻击实现、Shapley value 近似)，需要花时间读文献。不要等到 ddl 前两天再开始。

1.3 学习目标

“Understand how to **assess** and **improve** trustworthiness of ML.”

注意两个动词：**assess** (度量 / 评估) 与 **improve** (改进 / 设计算法)。前者属于“诊断”，后者属于“治疗”。两条主线贯穿整门课。

2. 从 AI 到可信 ML

2.1 定义层级

$$AI \supset ML \supset DL \quad (1.1)$$

- 人工智能 (AI)：由机器表现出的智能，区别于自然智能 (人 / 动物的意识与情感)。
- 机器学习 (ML)：Tom Mitchell 1997 经典定义——A computer program is said to learn from experience E w.r.t. some task T and some performance measure P , if its performance on T , as measured by P , improves with experience E .
- 深度学习 (DL)：以多层人工神经网络 (ANN) 为代表的 ML 子集，灵感来自大脑皮层结构。

[NOTE] 直觉

ML 与 rule-based 编程的本质区别：**ML 的“规则”是从数据中自动归纳出来的**，而非工程师手写 if-else。这赋予了机器“演化”的可能性，也带来了“我们其实并不完全理解模型在做什么”的不可信问题。

2.2 ML 的典型任务

- 回归 (Regression)：输出实数标量，例如预测明天的 PM2.5。
- 分类 (Classification)：在给定类别集合中挑出正确答案，例如垃圾邮件过滤、AlphaGo 落子 ($19 \times 19 = 361$ 类)。
- 生成 (Generation)：输出新样本 (本节未展开，后续 LLM / 扩散模型涉及)。

2.3 AI 的常见分支

机器学习 (ML)、计算机视觉 (CV)、自然语言处理 (NLP)、语音识别 (Speech)、以及作为载体的智慧医疗 / 交通 / 金融。ML 是其他分支的核心方法论。

3. 为什么需要“可信”？

3.1 现实中的失败案例

课件列举了若干“翻车”现场：

场景	失败表现	对应可信维度
刷脸支付	用 3D 打印面具被破解	鲁棒性 + 隐私
特斯拉车祸	自动驾驶在罕见场景下识别失效	鲁棒性

场景	失败表现	对应可信维度
ChatGPT 污染中文互联网	大模型生成虚假内容	伦理 + 真实性
AI 医疗误诊 对抗样本 (Dog → Ostrich)	正常胸片被分类为肺炎 在图像上加几乎不可见的扰动, DNN 置信度从 82% 翻转到 98% 错类	鲁棒性 + 公平性 鲁棒性
Face ID 攻击	攻击者通过对抗补丁让 Person1 不被识别	鲁棒性 + 隐私

3.2 形式化定义

Trustworthy ML 是与传统 ML 平行又延伸的概念。传统 ML 主要关注 **accuracy** 与 **efficiency**；可信 ML 在保持这两者的前提下，还要同时考虑 **robustness, privacy, fairness, explainability, security**。

可以写成一个多目标优化的语义：

$$\min_{f \in \mathcal{F}} \mathcal{L}_{\text{task}}(f) \quad \text{s.t.} \quad \underbrace{\mathcal{R}_{\text{rob}}(f) \leq \varepsilon_1}_{\text{鲁棒}}, \underbrace{\mathcal{R}_{\text{priv}}(f) \leq \varepsilon_2}_{\text{隐私}}, \underbrace{\mathcal{R}_{\text{fair}}(f) \leq \varepsilon_3}_{\text{公平}}, \dots \quad (1.2)$$

[WARN] 易错点

准确率高 $\neq$ 可信。后续会反复看到：标准训练得到的 f^* 在 i.i.d. 测试集上 99% 准确，但被一个 ℓ_∞ 范数 $\leq 8/255$ 的扰动就能打到 0% ——这正是可信 ML 关心的“鲁棒泛化 gap”。

4. 六大模块预览

4.1 可解释性 (Explainability)

核心问题：模型为什么这么预测？

应用动机：– 法律：信贷模型必须解释拒贷原因。– 医疗：医生需要知道 AI 诊断的依据，因为模型对人命负责。– 司法：模型不能有歧视；要能审计。– 自动驾驶：一旦出现异常行为，必须解释成因以追责。

后续章节会学：LIME (局部线性近似)、Shapley value (合作博弈论)、Saliency Map (梯度法)、CAM (类激活图)。

4.2 鲁棒性 (Robustness)

核心问题：当输入被对抗性地小幅扰动时，输出是否仍然稳定？

形式化：

$$\text{Robustness}(f, x) := \mathbb{P}_{\delta \sim B(\epsilon)}[f(x + \delta) = f(x)] \quad (1.3)$$

后续章节学习 FGSM / BIM / PGD / C&W / DeepFool 攻击与 AT / TRADES / MART / AWP 防御。

4.3 隐私 (Privacy)

Alan Westin 定义 (现代数据隐私法之父)：> Privacy is the claim of individuals, groups, or institutions to determine for themselves when, how, and to what extent information about them is communicated to others.

在大数据时代，免费服务的代价是隐私让渡。会涉及：成员推理攻击 (MIA)、模型反演、深度合成 (Deepfake)、差分隐私 (DP)、联邦学习。

4.4 公平性 (Fairness)

核心问题：模型对不同群体 (性别 / 种族 / 年龄) 的待遇是否一致？

直觉是“数据不会说谎”，但实际：– 数据采集偏差 (sample bias) – 标注偏差 (label bias) – 训练算法偏差 (algorithmic bias)

任一个都会让训练得到的模型产生群体歧视。

4.5 后门 (Backdoor)

核心问题：攻击者在训练阶段植入“触发器 (trigger)”，模型在干净样本上表现正常，但只要看到 trigger 就分类到目标类。属于 supply-chain 级别的安全威胁。

4.6 伦理 (Ethics)


核心问题：AI 应不应该被用来做某件事？这超越技术，涉及法律、社会学。

5. 学习路径建议

[EX] 学习路径建议

1. 第 2–3 讲：补足 ML / DL 基础 (线性模型、Sigmoid、CNN)。2. 第 4–5 讲：进入解释性，从模型无关 (LIME / Shapley) 到模型相关 (Saliency / CAM)。3. 第 6–7 讲：对抗攻击 (白盒 / 黑盒) 与对抗防御 (AT / TRADES / AWP / MART)。4. 后续：隐私、公平、后门、伦理 (不属于第 1–7 讲范围)。

6. 概念关系图



7. 关键术语速查 (中英对照)

中文	English	缩写
人工智能	Artificial Intelligence	AI
机器学习	Machine Learning	ML
深度学习	Deep Learning	DL
可信机器学习	Trustworthy Machine Learning	TML
可解释性	Explainability / Interpretability	–

中文	English	缩写
鲁棒性	Robustness	–
公平性	Fairness	–
隐私	Privacy	–
后门攻击	Backdoor Attack	–
对抗样本	Adversarial Example	AE
训练 / 推理	Training / Inference	–
损失函数	Loss Function	L
梯度下降	Gradient Descent	GD

7.1 数学符号速查 (跨章节)

符号	含义
θ	模型参数向量
$f_{\theta}(\cdot)$	参数为 θ 的模型
$L(\cdot, \cdot)$	损失函数
$\mathcal{D}$	数据分布 / 训练集
δ	对抗扰动
ϵ	扰动幅度上限 (ℓ_p 范数)
$\sigma(\cdot)$	sigmoid / 标准差, 依上下文
∇	梯度算子
$\arg \min, \arg \max$	取最优自变量

8. 各维度之间的内在联系

8.1 鲁棒性 可解释性

- **互补**: 可解释方法 (Saliency / Shapley) 可暴露 shortcut learning, 从而指明哪里需要鲁棒化; 反过来, 鲁棒训练 (AT) 后的模型其 saliency 更”语义化”。
- **冲突**: 鲁棒模型在准确率上有 trade-off (Lec 07 §4); 可解释模型有时不得不简化预测过程。

8.2 隐私 解释

- 提供详细解释 **可能泄露训练数据** (model inversion via feature importance)。
- 差分隐私训练能缓解, 但会牺牲解释精度。

8.3 公平 准确率

- 公平约束 (e.g. equalized odds) 是对最大似然的硬约束, 通常会让总体 accuracy 略降, 但保证子群体之间的差异变小。

8.4 矩阵式总览

维度 影响	准确率	效率 (训练 / 推理)	其他可信维度
鲁棒性	↓ (5–10%)	显著 ↓ (AT 慢 7×)	可解释 ↑
可解释	≈	推理 ↓ (Shapley 慢)	隐私 ↓
隐私 (DP)	↓ (3–8%)	训练 ↓↓	解释 ↓

维度 影响	准确率	效率 (训练 / 推理)	其他可信维度
公平	↓ (2–5%)	≈	解释要求 ↑
后门防御	≈	训练 ↓ (re-clean)	鲁棒 ↑

注意 可信 ML 不是单目标优化，而是多目标 Pareto 前沿——工程师必须根据应用场景挑权衡点。

9. 课程外的阅读建议

虽然课程不要求，但若想拓展可信 ML 视野：– 教材：Trustworthy Machine Learning (book draft, Singh et al.) – 顶会论文：ICLR / ICML / NeurIPS 的 Adversarial / Privacy / Fairness Workshop – 综述：Yuan et al. “Adversarial Examples: Attacks and Defenses for Deep Learning”(TNNLS 2019); Mehrabi et al. “A Survey on Bias and Fairness in Machine Learning”(CSUR 2021) – 实战：CleverHans (攻击库), AdvBox, Fairlearn, SHAP

9.5 课程方法论：从”为什么”到”怎么改”

王老师在课堂上反复强调一个研究流程，可作为做作业 / 写论文的 checklist：

1. 观察现象 (Observe)：模型在什么情况下失败？(对抗扰动 / 罕见样本 / 子群体)
2. 形式化问题 (Formalize)：写出失败的数学描述，例如 $\exists \delta : \|\delta\| \leq \epsilon, f(x + \delta) \neq f(x)$ 。
3. 量化指标 (Measure)：定义可量化的可信度指标，如鲁棒准确率、 L_∞ 鲁棒半径、统计平价差 (statistical parity)。
4. 设计算法 (Design)：基于上述指标设计训练 / 后处理算法。
5. 理论分析 (Analyze)：证明算法收敛 / 给出泛化界 / 上下界。
6. 实证评估 (Evaluate)：在多个数据集 / 多个攻击 / 多个模型上测试。

后续 6 讲每一节都能套到这个 6 步流程上。

9.6 易混淆术语速辨

术语 A	术语 B	区别
Interpretability	Explainability	前者更强调”模型本身可读”，后者强调”事后解释”；课程中混用
Adversarial Example	Out-of-Distribution Sample	前者是 人为对抗构造，后者是 自然分布外；处理思路不同
Robustness	Generalization	Robustness 关心最坏情况，Generalization 关心平均；可信 ML 把”鲁棒泛化”作为统一目标
Privacy	Security	Privacy 侧重 数据不被泄露；Security 侧重 系统不被绕过 / 攻破；后门同时属于两类
Fairness	Bias	模型是否偏向某些群体 (现象) vs 偏差的来源 (数据 / 算法 / 部署)

[WARN] 易错点

期中题目里如果出现”distinguish A from B”，要能用一句话讲清差异；切忌把 Adversarial Example 和 OOD 混为一谈。

10. 期中复习要点

10. 期中复习要点

[TIP] 期中复习要点

1. 能复述课程结构：六大模块名称、各自核心问题、对应的代表性算法。2. 能给出可信 ML 与传统 ML 的差异：传统 ML 优化 $\min L$ ；可信 ML 在 $\min L$ 之外加上 robustness / privacy / fairness 等约束 (见式 1.2)。3. 能举出 3 个真实失败案例：对抗样本翻转 ImageNet 标签 (Dog $\rightarrow$ Ostrich)；Face ID 被攻破；ChatGPT 污染语料。能说明它们各自违背了哪个可信维度。4. 明白评估方式：4 次作业各 25%，无考试。5. 熟悉 Mitchell 的 ML 经典定义：experience E 、task T 、performance P 。可信 ML 实际上是在 P 上做扩展，加入多个性能指标 (不只是 accuracy)。6. 理解可信 ML 是多目标 Pareto 优化：不同可信维度之间存在 trade-off，没有”全维度都最优”的模型。7. 能在脑中画出 §6 的概念关系图：AI $\rightarrow$ ML $\rightarrow$ 可信 ML $\rightarrow$ 六大模块；每个模块再有代表算法。

Lecture 02 —机器学习基础 (Introduction of Machine Learning)

[TIP] 学习指南

本节核心：用一条主线——“机器学习 $\approx$ 找一个函数 f ”——串起线性模型、Sigmoid 复合模型、神经网络的统一框架，并完整给出 ML 训练的三步范式 (Function $\rightarrow$ Loss $\rightarrow$ Optimization)。前置知识：高数 (偏导)、线性代数 (矩阵乘法)、概率 (期望、概率分布)。重点关注：(1) 梯度下降公式与超参；(2) 模型偏差 / 过拟合 / Bias-Complexity Trade-off；(3) 分类 vs 回归的输出层差异 (Softmax / Cross-entropy)。

0. 核心问题 / Motivation

机器学习的本质：

$$\text{Machine Learning} \approx \text{Looking for a function } f \quad (2.1)$$

给定输入 x 与希望的输出 y ，我们要在一类候选函数 $\mathcal{F}$ 中找一个 f 让 $f(x) \approx y$ 。下面所有内容 (线性回归、CNN、Transformer) 都是 $\mathcal{F}$ 的不同形式。

1. 函数类型

按输出形式可以分两类：

1.1 回归 (Regression)

函数输出一个 标量。例如：

$$f : (\text{今日 PM2.5, 温度, O}_3) \mapsto \text{明日 PM2.5}$$

1.2 分类 (Classification)

给定类别集合 $\mathcal{Y} = \{1, 2, \dots, K\}$ ，函数输出正确类别。例如：- 垃圾邮件过滤： $\mathcal{Y} = \{\text{Yes, No}\}$ - AlphaGo 落子： $\mathcal{Y} =$ 棋盘上的 $19 \times 19 = 361$ 个位置 (每个位置视作一个类)

[NOTE] 直觉

分类与回归在底层数学上其实统一：都是把输入映射到一个实向量，再用 argmax / 阈值 / softmax 转成离散决策。区别只在最后一层的“读取方式”。

2. ML 训练三步范式

以预测 YouTube 频道明日观看数为例 (李宏毅老师的经典案例):

2.1 Step 1: 带未知参数的函数 (Function with Unknown)

基于领域知识猜一个模型:

$$y = b + w x_1 \quad (2.2)$$

其中 x_1 是今天的观看数 (feature), w (weight) 与 b (bias) 是 **未知参数**, 需要从数据中学习。

2.2 Step 2: 定义损失 (Loss)

损失是参数的函数 $L(b, w)$, 刻画”这组参数有多差”。

取训练数据 $\{(x_1^{(n)}, \hat{y}^{(n)})\}_{n=1}^N$, 逐样本计算 **error**:

$$e_n = |\hat{y}^{(n)} - y^{(n)}| \quad \text{或} \quad e_n = (\hat{y}^{(n)} - y^{(n)})^2 \quad (2.3)$$

再做平均:

$$L = \frac{1}{N} \sum_{n=1}^N e_n \quad (2.4)$$

Loss 名称	公式	适用
MAE (Mean Absolute Error)	$e = y - \hat{y} $	回归, 鲁棒于离群点
MSE (Mean Squared Error)	$e = (y - \hat{y})^2$	回归, 光滑可导
Cross-Entropy	$e = -\sum_i \hat{y}_i \ln y_i$	分类, 配合 softmax

[WARN] 易错点

MSE 与 Cross-Entropy 不能随便互换。分类任务用 MSE 会让 softmax 输出在两端饱和时梯度极小, 训练几乎不动。分类首选 **Cross-Entropy**。

2.3 Step 3: 优化 (Optimization)

目标:

$$w^*, b^* = \arg \min_{w, b} L(w, b) \quad (2.5)$$

梯度下降 (Gradient Descent):

1. 随机初始化 w^0 (并 b^0);
2. 计算梯度:

$$g_w = \left. \frac{\partial L}{\partial w} \right|_{w=w^0, b=b^0}, \quad g_b = \left. \frac{\partial L}{\partial b} \right|_{w=w^0, b=b^0}$$

3. 更新参数:

$$w^1 \leftarrow w^0 - \eta g_w, \quad b^1 \leftarrow b^0 - \eta g_b \quad (2.6)$$

4. 重复直到收敛。

其中 η 是 **学习率 (learning rate)**, 属于 **超参 (hyperparameter)** ——不通过梯度学, 需要工程师设定。

[EX] 例题 2.1 (梯度下降一步)

设 $L(w) = (w - 3)^2$, 初始 $w^0 = 0$, 学习率 $\eta = 0.1$ 。

解: $\frac{\partial L}{\partial w} = 2(w - 3)$, 在 $w^0 = 0$ 处 $g = -6$ 。

一步更新: $w^1 = 0 - 0.1 \times (-6) = 0.6$ 。

继续: $g = 2(0.6 - 3) = -4.8$, $w^2 = 0.6 + 0.48 = 1.08$ 。

可见每步向最优值 $w^* = 3$ 接近, 但接近速度随梯度衰减。

[WARN] 易错点

– **局部最小值 (local minima)** 在 1D 凸问题里是真问题, 但深度学习高维空间里, 绝大多数停留点是 **鞍点 (saddle point)** 而非真正的局部最小。Loss landscape 真正的难点不是 local minima。– **学习率** 太大 → 震荡发散; 太小 → 收敛过慢。后续会学 Adam / SGDM 等自适应方法。

2.4 一次完整 pipeline 回顾

Step 1: 构造带未知参数的函数 $y = b + w x_1$

Step 2: 定义损失 $L(b, w)$

Step 3: 优化 $w^*, b^* = \operatorname{argmin} L$

实际运行结果 (课件例子): $w^* = 0.97, b^* = 0.1k$, 训练 loss $L^* = 0.48k$, 2021 年测试 loss $L' = 0.58k$ 。注意训练 / 测试之间的 gap。

3. 从线性到深度

3.1 更多输入特征

只用昨天一天的观看数显然不够。把过去 7 天 / 28 天 / 56 天的观看数都纳入:

$$y = b + \sum_{j=1}^{56} w_j x_j \quad (2.7)$$

实验显示: 随着 feature 数 $7 \rightarrow 28 \rightarrow 56$, 训练 loss 持续下降 ($0.48k \rightarrow 0.38k \rightarrow 0.33k$); 但测试 loss 在 28 之后下降趋缓 ($0.58 \rightarrow 0.49 \rightarrow 0.46$)。这是泛化的临界点。

3.2 线性模型的根本局限: Model Bias

无论怎么调整 w 与 b , 线性函数 $y = b + wx$ 永远画不出 S 形、阶梯形曲线。这种“无法表达目标函数”的现象叫做 **模型偏差 (model bias)**, 需要更柔性的模型。

3.3 用 Sigmoid 组合出分段线性曲线

任何连续曲线都可以用足够多段的 **分段线性 (piecewise linear)** 函数逼近。每一“段”可以由一个 **Hard Sigmoid** 实现, 而 Hard Sigmoid 可用光滑 Sigmoid 近似:

$$y = c \sigma(b + wx_1) = c \cdot \frac{1}{1 + e^{-(b+wx_1)}} \quad (2.8)$$

参数效果：- w 控制斜率 - b 控制水平偏移 - c 控制高度

把若干 sigmoid 加起来，再加常数项：

$$y = b + \sum_i c_i \sigma(b_i + w_i x_1) \quad (2.9)$$

这就能 逼近任意连续 1D 函数 (Universal Approximation 的最简版本)。

3.4 多输入版

$$y = b + \sum_i c_i \sigma\left(b_i + \sum_j w_{ij} x_j\right) \quad (2.10)$$

其中 w_{ij} 是第 i 个 sigmoid 神经元对第 j 个特征的权重。

3.5 矩阵形式 (重要)

设

$$r = b + Wx, \quad a = \sigma(r), \quad y = b + c^\top a \quad (2.11)$$

把所有可学习参数打包成向量：

$$\theta = [W; b; c; b] \quad (2.12)$$
$$y = f_\theta(x)$$

这就是一个 单隐层神经网络 的完整数学描述。

[NOTE] 直觉

把 (2.11) 看作一个流水线：原始特征 $x \rightarrow$ 线性变换 $Wx + b \rightarrow$ 非线性激活 $\sigma \rightarrow$ 线性输出 $c^\top a + b$ 。非线性激活是核心，没有它再多层也只等价于一个线性变换。

3.6 优化新模型

把 w, b 推广到 θ 后，梯度下降的形式不变：

$$\theta^1 \leftarrow \theta^0 - \eta g, \quad g = \nabla L(\theta^0) \quad (2.13)$$

实际工程里通常用 mini-batch SGD：把训练集切成大小为 B 的 batch，每个 batch 算一次梯度做一次更新；遍历一遍数据集叫做一个 epoch。

1 epoch = 看完所有 batch 一遍

4. 评估与过拟合

4.1 训练 / 测试 gap

完美训练 loss $\neq$ 好模型。极端反例：

$$f(x) = \begin{cases} \hat{y}_i, & \exists x_i = x \\ \text{random}, & \text{otherwise} \end{cases}$$

训练 loss 为 0，但测试时几乎全错。这种 零训练损失 + 高测试损失 就是 过拟合 (overfitting) 的极端形式。

4.2 过拟合的成因

模型过于柔性 (flexible)、训练数据不足，模型记住了训练数据的噪声而非规律。


4.3 缓解过拟合的方法

思路	具体做法
增加有效数据	更多训练数据、数据增强 (Data Augmentation)
约束模型复杂度	更少参数、参数共享 (CNN)、更少 feature、Dropout、L2 正则化
限制训练时长	Early Stopping
限制函数形式	用 $y = a + bx + cx^2$ 替代任意多项式

[WARN] 易错点

约束过度 → 又回到 model bias 太大、训练 loss 高的状态。Bias-Complexity Trade-off 永远存在。

4.4 Bias-Complexity Trade-off (重要)



- 模型太简单 → bias 大，训练 / 测试 loss 都高 (欠拟合)。
- 模型太复杂 → variance 大，训练 loss 低但测试 loss 高 (过拟合)。
- 最优解：测试 loss 极小值，往往在两条曲线“拐弯”处。

4.5 N-Fold Cross Validation

把训练集切成 N 等份，第 k 次用第 k 份做验证、其余做训练，得到 N 个验证 mse，平均得到该超参组合的 CV 误差。选 CV 误差最小的模型。

例 (3-fold):

Fold	M1	M2	M3
1	0.4	0.5	0.3
2	0.5	0.6	0.4
3	0.3	0.4	0.2
Avg	0.4	0.5	0.3 ← 最佳

[WARN] 易错点

在 CV 内还要做 真正的 测试集分离 (holdout test set)，否则模型选择本身就会偷看 test。课件里的“Testing Set”应在 CV 之前就被锁起来。

5. 分类的特殊处理

5.1 把分类当回归?

直接把类别编号成 1, 2, 3 再做回归是糟糕的, 因为类别之间没有自然顺序 (狗、猫、树 没有”狗 < 猫 < 树”).

5.2 One-hot 编码 + Softmax

把类别 k 编码成 one-hot 向量:

$$\hat{y} = e_k \in \{0, 1\}^K$$

模型输出 K 维实数向量 y , 再过 softmax:

$$y'_i = \frac{e^{y_i}}{\sum_j e^{y_j}}, \quad \sum_i y'_i = 1, \quad y'_i \in (0, 1) \tag{2.14}$$

5.3 Cross-Entropy 损失


$$e = - \sum_i \hat{y}_i \ln y'_i \tag{2.15}$$

$\hat{y}$ 是 one-hot 时, cross-entropy 简化为 $-\ln y'_{\text{true}}$, 即”正确类别的 log 似然取负”。

[EX] 例题 2.2 (Softmax + CE 计算)

- 设 3 类问题, 模型输出 $y = [3, 1, -3]$, 真实类别为 1。
- Softmax: $e^3, e^1, e^{-3} \approx 20, 2.7, 0.05$, 和 ≈ 22.75
 - $y'_1 = 20/22.75 \approx 0.88$
 - $y'_2 = 2.7/22.75 \approx 0.12$
 - $y'_3 \approx 0$
 - CE: $e = -\ln 0.88 \approx 0.128$

6. 概念关系图



7. 记号速查

符号	含义
x, x	输入特征 (标量 / 向量)
$\hat{y}, y$	标签 / 模型输出
w, b	权重 / 偏置
θ	所有可学习参数打包成的向量
$L(\theta)$	损失函数

符号	含义
η	学习率
∇L	损失关于参数的梯度
$\sigma(\cdot)$	Sigmoid 激活 $\sigma(z) = 1/(1 + e^{-z})$
$\text{softmax}(\cdot)$	概率归一化 $\propto e^{y_i}$
B	mini-batch 大小
N	训练集大小

8. 期中复习要点

[TIP] 期中复习要点

1. **三步范式**：能用一句话复述“function with unknown $\rightarrow$ define loss $\rightarrow$ optimization”，并写出对应公式。
2. **梯度下降**：能给出更新规则 $\theta \leftarrow \theta - \eta \nabla L$ ；解释 η 的影响；说明 local minima 在高维不是核心问题，鞍点才是。
3. **Sigmoid 复合 = 神经网络**：能从分段线性逼近的角度推导为什么神经网络能拟合任意连续函数。
4. **矩阵化**：能把 $y = b + \sum_i c_i \sigma(b_i + \sum_j w_{ij} x_j)$ 写成 $y = b + c^\top \sigma(Wx + b)$ 。
5. **过拟合 vs model bias**：能画出 bias-complexity trade-off 曲线，并列至少 4 种缓解过拟合的方法。
6. **分类的输出层**：能解释为什么用 softmax + cross-entropy 而非直接 MSE。
7. **Cross Validation**：能描述 N-fold 流程；强调 test set 必须在 CV 之外。
8. **mini-batch / epoch**：能给出定义；解释 batch size 对方差与显存的影响（定性即可）。

Lecture 03 —卷积神经网络 (Convolutional Neural Network, CNN)

[TIP] 学习指南

本节核心：从“为什么图像不能用全连接”出发，推导出 CNN 三大设计原则 (Receptive Field, Parameter Sharing, Pooling)，并把两种等价“故事”(神经元视角 vs 滤波器视角) 拼接到一起。前置知识：第 2 讲的神经网络 / 梯度下降 / 矩阵运算；图像即 3-D 张量 (Height $\times$ Width $\times$ Channels) 的基本概念。重点关注：(1) 输出 feature map 尺寸的计算；(2) 三种 simplification 与 model bias 的关系；(3) 参数量对比 FC vs Conv。

0. 核心问题 / Motivation

把一张 $100 \times 100 \times 3$ 的彩色图直接展平输入全连接网络 (Fully Connected, FC)，第一层若有 1000 个隐藏神经元就需要 $100 \times 100 \times 3 \times 1000 = 3 \times 10^7$ 个参数。这导致两个问题：

1. **参数爆炸** $\rightarrow$ 严重过拟合 + 显存炸；
2. **没有先验** $\rightarrow$ 模型既能学到“鸟”的概念，也可能学到完全无关的像素组合 (例如把背景颜色当作类别标志)。

CNN 的诞生就是为图像这一类 **具有局部结构的数据** 注入合适的归纳偏置 (inductive bias)。

1. Observation 1: 局部特征 $\rightarrow$ Receptive Field

1.1 直觉

人类识别一只鸟时，先看 **鸟嘴、鸟眼、鸟爪** 等局部模式，不必看整张图。深层一些的神经元再把这些局部检测器的结果组合 (鸟嘴 + 鸟爪 + 翅膀 = 鸟)。

“Some patterns are much smaller than the whole image.”

结论：每个神经元不需要看整张图，只需关注一小块区域——**感受野 (receptive field)**。

1.2 Simplification 1: 局部连接

设 receptive field 大小 $k \times k$ (e.g. 3×3)，channel 数为 C (e.g. 3)，则每个神经元的参数量从 $H \cdot W \cdot C$ 缩减为 $k^2 C$ 。例如 $3 \times 3 \times 3 = 27$ 个权重 + 1 个 bias = 28 个参数。

1.3 典型设置 (Typical Setting)

- **Kernel size:** 3×3 或 5×5 ，覆盖所有 channel
- **Stride:** 感受野中心的滑动步长 (e.g. stride=1 或 stride=2)
- **Padding:** 边界补零，让输出尺寸可控

- 每个感受野 有一组神经元 (e.g. 64 个), 每个神经元对应一组独立的 $3 \times 3 \times C$ 权重 (但同感受野的多个神经元不共享参数)
- 多个感受野 覆盖整张图, 可以重叠

[NOTE] 直觉

感受野设计回答的是 **空间局部性**: 相邻像素往往相关, 距离越远的像素相关性越弱。所以”只看局部”是合理的归纳偏置。

1.4 输出尺寸公式

设输入 $H \times W$, 卷积核 $k \times k$, padding p , stride s , 输出尺寸为:

$$H_{\text{out}} = \left\lfloor \frac{H + 2p - k}{s} \right\rfloor + 1, \quad W_{\text{out}} = \left\lfloor \frac{W + 2p - k}{s} \right\rfloor + 1 \quad (3.1)$$

[EX] 例题 3.1

输入 6×6 , kernel 3×3 , padding 0, stride 1。

$H_{\text{out}} = (6 - 3)/1 + 1 = 4$, 输出 4×4 。

2. Observation 2: 模式平移不变 → Parameter Sharing

2.1 直觉

“鸟嘴”这个 pattern 可能出现在图像的左上角, 也可能出现在右下角; 但 **检测器应该相同**——不必为每个位置训练一个独立的“鸟嘴检测器”。

“The same patterns appear in different regions.”

2.2 Simplification 2: 参数共享

让所有感受野共享同一组权重 (即 **filter / kernel**)。这样: - 一个 $3 \times 3 \times C$ 的 filter 可以检测整张图任何位置的同一种模式; - 多个 filter (e.g. 64 个) 检测不同种模式 (边缘、纹理、颜色块等)。

注意: 同一个感受野内的不同神经元 (e.g. 64 个 filter 在同一空间位置的输出) **不共享参数**, 否则就退化成单一 filter 了。

2.3 参数量对比

模型	第 1 层参数量 (假设 1000 隐藏单元 / 64 filter)
FC, 输入 $100 \times 100 \times 3 \rightarrow 1000$	3×10^7
Conv, $3 \times 3 \times 3 \times 64$ filters	$3 \times 3 \times 3 \times 64 \approx 1.7 \times 10^3$

参数减少 4 个数量级。

3. 两种等价视角

CNN 可以从两个角度理解，它们在数学上是等价的：

Neuron Version	Filter Version
每个神经元只看一个感受野 不同感受野的神经元共享参数	一组 filter 在图像上卷积 每个 filter 滑过整张图

[WARN] 易错点

教科书 / 课件常常在两种视角之间切换。看到“filter”与“neuron”时要意识到它们指向同一件事，不要被搞晕。

4. 卷积运算的具体计算

4.1 单 filter 卷积示例

输入 6×6 灰度图 (channel=1), filter $1 = \begin{pmatrix} 1 & -1 & -1 \\ -1 & 1 & -1 \\ -1 & -1 & 1 \end{pmatrix}$ (检测斜对角)。

卷积：每个 3×3 窗口与 filter 逐元素相乘求和，得到一个标量；窗口在图像上以 stride 1 滑动，得到 4×4 的输出 feature map。

4.2 多 filter, 多 channel

- 输入： $H \times W \times C_{in}$
- F 个 filter, 每个 $k \times k \times C_{in}$
- 输出： $H_{out} \times W_{out} \times F$ (F 个 channel)

注意：filter 的 channel 数必须等于输入的 channel 数，每个 filter 输出一个 channel。

4.3 多层堆叠

- 第 1 层：filter $3 \times 3 \times 3$, 64 个 $\rightarrow$ 输出 64 channel
- 第 2 层：filter $3 \times 3 \times 64$, 再 64 个 $\rightarrow$ 输出 64 channel
- ...

层数加深 $\rightarrow$ 有效感受野 (effective receptive field) 越来越大，最深层的单个神经元可以“看到”输入图的相当大区域，从而捕获高层语义。

5. Observation 3: 子采样 $\rightarrow$ Pooling

5.1 直觉

把图像下采样 (e.g. 抽掉一半像素) 后，鸟仍然是鸟。

“Subsampling the pixels will not change the object.”

5.2 Max Pooling

把 2×2 区域取最大值:

$$y_{ij} = \max\{x_{2i,2j}, x_{2i+1,2j}, x_{2i,2j+1}, x_{2i+1,2j+1}\} \quad (3.2)$$

效果: – 降低 feature map 尺寸 (空间维度 $\div 2$) – 减少参数与计算 – 提供轻微的平移不变性 (translation invariance)

5.3 Average Pooling

$$y_{ij} = \frac{1}{4} \sum_{2 \times 2 \text{ window}} x \quad (3.3)$$

比 max pooling 平滑, 常用在 ResNet 最后一层 (Global Average Pooling, GAP)。

[WARN] 易错点

Pooling 会丢信息。在高分辨率检测 / 分割任务中过度 pooling 会损失细节。现代架构 (e.g. ResNet) 倾向于用 `stride=2` 卷积 替代 pooling, 让下采样过程也是可学习的。

6. 完整 CNN Pipeline

Input image

- ↓ Conv ($k \times k \times C_{in} \times F$ filters)
- ↓ ReLU / Sigmoid
- ↓ Pooling
- ↓ Conv
- ↓ ReLU
- ↓ Pooling
- ... (重复若干 Conv+Pool 块)
- ↓ Flatten (把 $H \times W \times C$ 拉成 1-D)
- ↓ FC layers
- ↓ Softmax

Output: cat / dog / ...

这是 LeNet / AlexNet / VGG 的统一框架。后续 ResNet 在此基础上加入 **skip connection** 解决深层网络的梯度退化。

7. 三大设计原则的统一总结

观察	简化	后果
局部模式	Receptive Field (局部连接)	参数 ↓, model bias ↑
模式平移不变	Parameter Sharing	参数 ↓↓
子采样不变	Pooling	计算 ↓, translation invariance ↑

注意 **Convolutional Layer** 比 **FC** 的 **model bias** 更大——它强加了“图像有局部结构 + 平移不变”的先验。对图像这是好事；对完全无空间结构的表格数据，则会反而限制表现。

[NOTE] 直觉

“Jack of all trades, master of none”——FC 什么都能拟合但什么都拟合不好；CNN 通过引入合理偏置，在图像上做精通。

8. 一个完整例题

[EX] 例题 3.2 (CNN 输出尺寸 + 参数量计算)

给定输入 $32 \times 32 \times 3$ (CIFAR-10 图像), 网络结构:


1. Conv 3×3 , 32 filters, stride=1, padding=1
2. ReLU
3. Max Pool 2×2 , stride=2
4. Conv 3×3 , 64 filters, stride=1, padding=1
5. Max Pool 2×2 , stride=2
6. Flatten $\rightarrow$ FC 10

逐层尺寸: - 输入: $32 \times 32 \times 3$ - 1) Conv: $H_{\text{out}} = (32 + 2 - 3)/1 + 1 = 32$, 输出 $32 \times 32 \times 32$
- 3) Pool: $32/2 = 16$, 输出 $16 \times 16 \times 32$ - 4) Conv: $16 + 2 - 3 + 1 = 16$, 输出 $16 \times 16 \times 64$
- 5) Pool: $16/2 = 8$, 输出 $8 \times 8 \times 64$ - 6) Flatten: $8 \times 8 \times 64 = 4096$, FC $4096 \rightarrow 10$

参数量: - 1) $3 \times 3 \times 3 \times 32 + 32 = 896$ - 4) $3 \times 3 \times 32 \times 64 + 64 = 18496$ - 6) $4096 \times 10 + 10 = 40970$ - 合计 ≈ 60362 。

同样规模的纯 FC 第一层就要 $32 \times 32 \times 3 \times 1000 \approx 3 \times 10^6$, 可见 CNN 的紧凑性。

9. 概念关系图



10. 记号速查

符号	含义
H, W, C	图像高 / 宽 / channel
k	kernel size (e.g. 3)
p	padding

符号	含义
s	stride
F	filter 数量 (输出 channel 数)
$f_k(x, y)$	第 k 个 filter 在空间 (x, y) 处的激活
GAP	Global Average Pooling

10.5 训练 CNN 时的常见技巧

为帮助后续作业实现，下列经验性技巧应熟悉：

- **数据增强 (Data Augmentation)**: 随机裁剪 (RandomCrop)、水平翻转 (RandomFlip)、颜色抖动 (ColorJitter)、CutMix、MixUp。在 CIFAR-10 上能提升 3–5%。
- **批归一化 (Batch Normalization)**: 对每层激活做规范化 $\hat{z} = (z - \mu_B) / \sqrt{\sigma_B^2 + \epsilon}$ ，让训练更稳定，可用更大学习率。
- **学习率调度**: StepLR / CosineAnnealing / Warmup，避免后期 loss 抖动。
- **权重初始化**: He init (ReLU) / Xavier init (tanh, sigmoid)，避免梯度消失 / 爆炸。
- **Dropout**: FC 层间随机置零，缓解过拟合 (但 CNN 层间常被 BN 替代)。

[WARN] 易错点

BN 在测试时使用的是训练阶段累积的 running mean/var，**不是** 当前 batch 的统计。这一点在做 PGD 攻击 (Lec 06) 时尤其重要：很多攻击会在 eval mode 下进行，须确认 BN 处于固定参数状态。

11. 经典 CNN 架构纵览

虽然课件只点了 CNN 基本结构，但备考可以横向比较：

架构	年份	关键创新	备注
LeNet-5	1998	卷积 + 池化交替, 适用 MNIST	第一代实用 CNN
AlexNet	2012	ReLU + Dropout + GPU 训练, ImageNet 冠军	引爆深度学习
VGG	2014	全 3×3 卷积堆叠, 简单优雅	16/19 层
GoogLeNet (Inception)	2014	1×1 卷积降维, Inception block	22 层但参数少
ResNet	2015	Skip connection 解决梯度消失	50/101/152 层
DenseNet	2017	每层都和之前所有层相连	参数复用
MobileNet	2017	Depthwise Separable Conv	移动端友好
EfficientNet	2019	复合缩放 (depth, width, resolution)	SOTA + 参数效率

Skip Connection 公式

ResNet 的核心:

$$y = \mathcal{F}(x, \{W_i\}) + x \quad (3.4)$$

让网络只学 **残差** $\mathcal{F}(x) = y - x$ ，恒等映射变得容易学到 $\rightarrow$ 极深网络也能稳定训练。后续 Lec 06 会看到 skip connection 还和 **对抗迁移性** 紧密相关。

12. 期中复习要点

[TIP] 期中复习要点

1. **三大原则**: Receptive Field, Parameter Sharing, Pooling, 能各举一个观察来由说明。2. **公式 (3.1)** 必背: 能根据输入尺寸 + kernel + padding + stride 算出输出 feature map 尺寸。3. **参数量计算**: 第 ℓ 层卷积参数 = $k \times k \times C_{\text{in}} \times C_{\text{out}} + C_{\text{out}}$ (bias)。4. **两种视角的等价性**: 能说明“neuron with receptive field”和“filter convolution”是同一回事。5. **CNN vs FC 的 model bias**: CNN 因为施加了图像先验, bias 比 FC 大; 这是好事 (减小过拟合) 也是限制 (在表格数据上反而不如 FC)。6. **Pooling 类型**: max / average / global average; 能说明各自适用场景。7. **完整 pipeline**: 能默写 Conv $\rightarrow$ ReLU $\rightarrow$ Pool $\rightarrow$ Conv $\rightarrow \dots \rightarrow$ Flatten $\rightarrow$ FC $\rightarrow$ Softmax 的标准结构。8. **典型 CNN 架构对比**: LeNet、AlexNet、VGG、GoogLeNet、ResNet 关键区别; 能默写 ResNet skip connection 式 (3.4)。9. **Lec3 $\rightarrow$ Lec5 桥梁**: CAM 要求 GAP + 线性分类层, ResNet 满足。10. **Lec3 $\rightarrow$ Lec6 桥梁**: Skip connection 在对抗攻击中有特殊作用 (transferability 更高)。

Lecture 04 —可解释机器学习 (Explanations: LIME & Shapley)

[TIP] 学习指南

本节核心：进入“可信 ML”第一大支柱——**可解释性**。从两个 **模型无关 (model-agnostic)** 解释方法入手——LIME (局部线性近似) 与 Shapley Value (合作博弈论)，理解它们的算法、性质、优缺点。前置知识：第 2 讲的线性模型、加权最小二乘；基本概率 (期望、条件期望)；可选：合作博弈论中“特征函数”概念。重点关注：(1) LIME 的算法 4 步；(2) Shapley 公理化定义 (4 axioms)；(3) Shapley 公式与近似 (Monte Carlo)。

0. 核心问题 / Motivation

“I know **why** the answers are wrong, so I can fix it.”——解释让我们能 (a) 诊断模型错误 (b) 满足合规要求 (c) 增进对模型 / 数据的理解。

可解释 ML 需要回答：

给定训练数据 $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$ ，一个已学好的模型 f ，以及实例 $\vec{x} \in \mathbb{R}^p$ ，**找一个对 $f(\vec{x})$ 的解释**。

什么算“解释”？常见形式：– **特征重要性 (feature importance)** ——哪些 feature 推动了这次预测 – **决策规则**——等价的¹可读规则集合 – **样例对照**——反事实 / 影响样本 – **可视化**——Saliency / CAM (见第 5 讲)

1. 解释方法的分类

按对模型的访问程度：

类别	说明	代表方法
Model-Agnostic Model-Specific	把 f 当黑盒，只用 query 利用模型内部信息	LIME, Shapley, PDP, ALE Saliency (梯度), CAM (CNN), attention 权重

本节聚焦 model-agnostic 的两个最经典方法。

1.1 有“天生可解释”的模型吗？

线性模型： $y = b + \sum_j w_j x_j$ 。 w_j 的大小与符号直接表示 feature 重要性 / 方向。但实际场景 (图像、文本、高维表格) 中线性模型表现往往太弱。

决策树 / 规则集合 也是天生可解释；但深度网络远比它们强。所以需要 **事后解释 (post-hoc explanation)** 把黑盒模型局部“翻译”成可解释模型。

2. LIME (Local Interpretable Model-Agnostic Explanations)

2.1 核心思想

全局上，深度模型决策边界复杂得无法理解；但在某个具体样本 $\vec{x}$ 的邻域，决策边界可以用一个简单可解释模型 g (e.g. 线性模型) 近似。

[NOTE] 直觉

想象一座蜿蜒的山脉 (全局复杂)，但站在山脚某一点，你只需用一个切平面描述脚下的坡度——这个切平面就是 LIME 的局部代理 (local surrogate)。

2.2 算法 4 步

Step 1: 给定要解释的点 x

Step 2: 在 x 的邻域采样 m 个扰动点 z_i

Step 3: 用线性 (或其他可解释) 模型拟合 $(z_i, f(z_i))$,
损失按距离 $\|z_i - x\|$ 加权

Step 4: 解读这个线性模型的系数 = 特征重要性

2.3 形式化

定义可解释模型族 $\mathcal{G}$ (通常是线性模型族)，距离核 $w_i \propto \exp(-\|z_i - \vec{x}\|^2 / \sigma^2)$ 。

优化目标：

$$\arg \min_{g \in \mathcal{G}} \frac{1}{m} \sum_{i=1}^m w_i L(f(z_i), g(z_i)) + \lambda \Omega(g) \quad (4.1)$$

其中 $\Omega(g)$ 是模型复杂度正则项 (如 L_1 稀疏化，让最终只剩少数 feature)。

当 g 是线性模型 $g(z) = \langle \vec{\beta}, z \rangle$ 时：

$$\arg \min_{\vec{\beta} \in \mathbb{R}^p} \frac{1}{m} \sum_{i=1}^m w_i (f(z_i) - \langle \vec{\beta}, z_i \rangle)^2 + \lambda \|\vec{\beta}\|_1 \quad (4.2)$$

通过 LASSO / 正交匹配追踪解此问题，调整 λ 控制最终保留几个非零 β_j (即用户希望的解释特征数)。

2.4 邻域采样的具体做法

表格数据

$z_{ij} \sim \mathcal{N}(\mu_j, \sigma_j^2)$ ，其中 μ_j, σ_j 是训练集第 j 特征的均值 / 方差。

图像数据

- 把图像分割成 **超像素 (superpixel)**
- 随机“打开 / 关闭”超像素 (开 = 保留原像素, 关 = 替换成灰色)
- 形成二进制向量 $z_i \in \{0, 1\}^K$ ，这就是可解释特征

文本数据

- 随机删除若干 token，形成 BoW 向量

2.5 经典案例：Wolf vs Husky

LIME 在一组“狼 / 哈士奇”图像分类器上发现：模型其实是在判断 **背景里有没有雪**。预测为狼的图像里，重要特征是 **雪地**；预测为哈士奇时，重要特征是 **室内地板**。这种“偷懒”现象 (**shortcut learning**) 是 LIME 暴露黑盒病灶的经典案例。

2.6 优缺点

优点： – **人类友好：** 少量特征 + 可解释代理模型 – **通用：** 任何黑盒都能用 (回归 / 分类 / 多模态) – **变体丰富：** 文本 LIME、图像 LIME、表格 LIME

缺点： – **邻域定义敏感：** 核宽度 σ 一改，解释就变 – **不稳定：** 相邻样本可能得到完全不同的解释 (因为采样随机) – **局部线性假设可能错：** 当 f 在 $\vec{x}$ 附近高度非线性时，线性 g 拟合不准

[WARN] 易错点

LIME 的解释只是 **局部** 的——不要把“这个像素重要”推广成“模型整体上看这个像素”。每个样本可能有完全不同的解释。

3. 从博弈论引入：Shapley Value

3.1 合作博弈的小例子

3 个程序员合作写一个 500 行项目，单人 / 多人组合的产出：

$$\begin{aligned}v(\{1\}) &= 100, & v(\{2\}) &= 125, & v(\{3\}) &= 50 \\v(\{1, 2\}) &= 270, & v(\{2, 3\}) &= 350, & v(\{1, 3\}) &= 375 \\v(\{1, 2, 3\}) &= 500\end{aligned}$$

问：如何在 3 人间 **公平** 分配总产出 500？

直观答案要满足： – 每个人拿到的与他的 **真实贡献** 成正比 – 全部分完 – 对换名字答案不变 (对称) – ...

Shapley (1953) 证明：**满足若干“公平公理”的分配方案，存在且唯一。**

3.2 Shapley 公理 (4 axioms)

记 $\phi_i(v)$ 为玩家 i 在博弈 v 中应得的份额。

Efficiency (有效性 / 全分配)

$$\sum_{i \in P} \phi_i(v) = v(P) \quad (4.3)$$

总和等于大联盟的总产出。

Symmetry (对称性)

若 i 和 j 可互换 (即对所有不含 i, j 的子集 S 都有 $v(S \cup \{i\}) = v(S \cup \{j\})$)，则 $\phi_i = \phi_j$ 。

Linearity (线性性)

对两个博弈 v, w 与实数 a ：

$$\phi_i(v + w) = \phi_i(v) + \phi_i(w), \quad \phi_i(a \cdot v) = a \cdot \phi_i(v) \quad (4.4)$$

Null Player (空玩家)

若 i 是“空玩家”，即 $v(S \cup \{i\}) = v(S)$ 对所有 $S \not\ni i$ ，则 $\phi_i(v) = 0$ 。

3.3 Shapley 公式 (Theorem)

[NOTE] 定理 4.1 (Shapley 1953)

满足以上 4 公理的唯一分配方案是：

$$\Phi_j(v) = \sum_{S \subseteq P \setminus \{j\}} \frac{|S|!(p - |S| - 1)!}{p!} [v(S \cup \{j\}) - v(S)] \quad (4.5)$$

其中 $p = |P|$ ，求和遍历所有不含 j 的子集 S 。

解读：- $v(S \cup \{j\}) - v(S)$ 是 j 加入联盟 S 后的 **边际贡献** - 权重 $\frac{|S|!(p-|S|-1)!}{p!}$ 是把这种“加入顺序”在所有 $p!$ 排列中按等概率加权 - 因此 $\Phi_j = j$ 在所有可能加入顺序下的 **平均边际贡献**

3.4 把 Shapley 用到机器学习

类比 (核心翻译表)：

博弈论	解释 ML
博弈 v	一次预测 $f(\vec{x})$
全联盟产出	$f(\vec{x}) - \mathbb{E}[f]$ (预测与平均预测之差)
玩家 i	特征 j
玩家份额 ϕ_i	特征重要性 $\varphi(j, f, \vec{x})$

3.5 ML 中的 Shapley 公式

把 $v(S)$ 实例化为“只观察特征集合 S 时的期望预测”：

$$\psi(f, \vec{x}, S) := \mathbb{E}[f(X) \mid X_k = x_k, k \in S] \quad (4.6)$$

则

$$\varphi(j, f, \vec{x}) = \sum_{S \subseteq \{1, \dots, p\} \setminus \{j\}} \frac{|S|!(p - |S| - 1)!}{p!} [\psi(f, \vec{x}, S \cup \{j\}) - \psi(f, \vec{x}, S)] \quad (4.7)$$

3.6 计算难点与近似

(4.7) 的子集个数是 2^{p-1} ，对 $p = 100$ 已是 10^{30} 级别，**无法精确计算**。常用近似：

1. **Monte Carlo 采样**：随机抽 K 个排列，每次按位置算 j 的边际贡献，最后平均。
2. **KernelSHAP**：把 Shapley 化为加权线性回归 (SHAP 库的核心)。
3. **TreeSHAP**：在 Tree-based 模型上能多项式时间精确计算。

3.7 优缺点

优点：- 满足 公理化的公平性：理论性质极佳 - 考虑了特征间的交互：不像单变量遮挡 (occlusion)，会平均所有 coalition - 全局 (整数据集 Shapley 累积) + 局部 (单样本 Shapley) 视角均可用

缺点：- 计算量爆炸： $O(2^p)$ ，精确不可行 - 解释偏抽象：“这个 feature 对 (预测 - 平均预测) 的差异贡献了多少”——对非技术用户难懂 - 依赖参考分布： $\mathbb{E}[f(X) \mid X_S]$ 的估计需要 background dataset，选择不同 background 结果不同

[WARN] 易错点

SHAP value 与“single-feature drop-off”(去掉某 feature 后 loss 变化) 不一样：SHAP 平均了 所有可能的特征加入顺序，是顺序无关的“公平”分摊。

4. 一个完整例题

[EX] 例题 4.1 (Shapley 手算)

沿用 §3.1 的 3 人合作项目： $v(\emptyset) = 0$, $v(1) = 100$, $v(2) = 125$, $v(3) = 50$, $v(1, 2) = 270$, $v(1, 3) = 375$, $v(2, 3) = 350$, $v(1, 2, 3) = 500$ 。

用公式 (4.5) 计算 Φ_1 ：

子集 $S \subseteq \{2, 3\}$ ，共 4 个： $\emptyset, \{2\}, \{3\}, \{2, 3\}$ 。 $p = 3$ 。


S	$\ S\ $	系数 $\frac{\ S\ !(p-\ S\ -1)!}{p!}$	边际 $v(S \cup \{1\}) - v(S)$
$\emptyset$	0	$0! \cdot 2! / 3! = 2/6 = 1/3$	$100 - 0 = 100$
$\{2\}$	1	$1! \cdot 1! / 3! = 1/6$	$270 - 125 = 145$
$\{3\}$	1	$1/6$	$375 - 50 = 325$
$\{2, 3\}$	2	$2! \cdot 0! / 3! = 2/6 = 1/3$	$500 - 350 = 150$

$\Phi_1 = \frac{1}{3} \cdot 100 + \frac{1}{6} \cdot 145 + \frac{1}{6} \cdot 325 + \frac{1}{3} \cdot 150 = 33.33 + 24.17 + 54.17 + 50 = 161.67$
类似可算 $\Phi_2 = 158.33$, $\Phi_3 = 180$ 。验证 Efficiency: $161.67 + 158.33 + 180 = 500$

5. LIME vs Shapley 对比

维度	LIME	Shapley
思想	局部线性代理	平均边际贡献 (博弈论)
复杂度	$O(m \cdot p)$ ，可控	$O(2^p)$ ，需近似
稳定性	低 (邻域采样影响大)	高 (有公理化定义)
直观度	高 (像线性回归系数)	中 (需要博弈论背景)
适用	表格 / 图像 / 文本	表格为主，图像需特殊处理
主要库	lime	shap (KernelSHAP, TreeSHAP)

6. 概念关系图



7. 记号速查

符号	含义
$\vec{x}$	要解释的实例
f	已训练好的 (黑盒) 模型
$g \in \mathcal{G}$	局部代理 (可解释模型)
z_i	邻域采样点
w_i	距离权重 (核函数)
$\Omega(g)$	代理模型复杂度正则
P	玩家全集 / 特征全集
$S \subseteq P \setminus \{j\}$	不含 j 的子集
$v(S)$	特征函数 / 联盟价值
Φ_j	Shapley value
$\varphi(j, f, \vec{x})$	ML 版 Shapley (feature j 对 $f(\vec{x})$ 的贡献)
$\psi(f, \vec{x}, S)$	只看 S 时的期望预测

8. 期中复习要点

[TIP] 期中复习要点

1. **解释方法分类**：能写出 model-agnostic vs model-specific，并各举 2 个代表。2. **LIME 算法 4 步**：能默写采样 → 加权 → 拟合代理 → 解读系数；说明为什么用 LASSO 控制稀疏。3. **Wolf vs Husky 案例**：能讲清“模型偷懒”现象 (shortcut learning)，及 LIME 如何暴露。4. **LIME 缺陷**：邻域敏感、不稳定、依赖 σ ；5. **Shapley 4 公理**：Efficiency, Symmetry, Linearity, Null Player ——能用一句话给出每条。6. **公式 (4.5)** 必背：能解读 $\frac{|S|!(p-|S|-1)!}{p!}$ 为“按加入顺序的均匀概率”。7. **手算练习**：3 玩家或 3 特征的 Shapley 能完整算出 (§4 例题)。8. **近似方法**：知道 Monte Carlo / KernelSHAP / TreeSHAP 各自适用场景。9. **优缺点对比表**：能填出 LIME vs Shapley 在复杂度 / 稳定性 / 直观度上的差异。

Lecture 05 —Saliency Map 与 Class Activation Map (CAM)

[TIP] 学习指南

本节核心：进入 **model-specific** 解释方法，利用网络内部（梯度 / 激活）直接生成可视化热图。两条主线：(1) 反向传播视角 → Saliency Map / SmoothGrad；(2) 前向传播视角 → CAM。前置知识：第 2 / 3 讲的 CNN、反向传播、Softmax；矩阵展开 / 加权和。重点关注：(1) Saliency = $|\partial e / \partial x_i|$ 的物理意义；(2) Pokémon vs Digimon 案例（假高准确率元凶）；(3) CAM 公式推导与 ResNet 结构要求。

0. 核心问题 / Motivation

第 4 讲学的 LIME / Shapley 是 **model-agnostic** 的事后解释：把模型当黑盒，靠采样 / 拟合。优点是通用，缺点是计算贵 (Shapley) / 不稳定 (LIME)。

Model-specific 视角：模型自身就是可读的——神经网络的 **梯度** 与 **激活** 直接揭示了“哪里重要”。本节学最经典的两类：

视角	方法	来源
反向传播 (Backward)	Saliency Map, SmoothGrad	梯度 $\nabla_x \ell$
前向传播 (Forward)	CAM (Class Activation Map)	最后一层 conv 激活与全连接权重的加权和

1. Saliency Map: 梯度即解释

1.1 直觉

模型 f 在输入 x 处的输出对 x_i (第 i 个像素 / 分量) 的灵敏度，可由偏导刻画：

$$\left| \frac{\partial e}{\partial x_i} \right| \quad (5.1)$$

其中 e 是损失 (或某类别的 logit / score)。梯度越大，意味着该像素的微小变化会显著改变模型输出 → 该像素“重要”。

1.2 推导

考虑两个邻近输入：

$$x = (x_1, \dots, x_i, \dots, x_n) \quad \text{vs} \quad x' = (x_1, \dots, x_i + \Delta x, \dots, x_n)$$

损失变化 Δe 满足

$$\Delta e \approx \frac{\partial e}{\partial x_i} \Delta x \implies \left| \frac{\Delta e}{\Delta x} \right| \approx \left| \frac{\partial e}{\partial x_i} \right| \quad (5.2)$$

1.3 Saliency Map 算法

输入：训练好的模型 f ，待解释图像 x ，类别 c

1. 前向： $y = f(x)$, $e = \text{score}_c$ (或 cross-entropy with label c)
2. 反向： $g = \partial e / \partial x$ (size = $x.\text{shape}$, 一次反向传播即可)
3. Saliency: $|g|$ 取绝对值, 通道上取最大 (或求和)
4. 可视化: 把 $|g|$ reshape 成图像尺寸的热图

计算成本: 1 次前向 + 1 次反向 = 一次完整的 backprop, 远比 LIME 的多次重采样便宜。

1.4 朴素 Saliency 的问题：噪声

直接 $|\nabla_x e|$ 通常很 嘈杂, 原因: - ReLU 等非线性带来梯度的“尖锐” - 像素级别梯度对小扰动极敏感 - 训练好的网络在 saturation 区域梯度小但实际语义重要

1.5 SmoothGrad: 高斯平滑

[NOTE] 直觉

既然单点梯度抖动大, 那就在 x 邻域采样多个加噪点, 把它们的梯度平均一下, “洗”掉随机性。

$$\text{SmoothGrad}(x) := \frac{1}{n} \sum_{k=1}^n \nabla_x e(x + g_k), \quad g_k \sim \mathcal{N}(0, \sigma^2 I) \quad (5.3)$$

实验表明 (σ 取像素值标准差的 10–20%), SmoothGrad 给出的热图比朴素 Saliency 更连贯、定位更准。

1.6 案例研究：Pokémon vs Digimon (重要)

这是课件中最具警示意义的案例。

实验设置: - 训练数据: 宝可梦 PNG (透明背景) + 数码宝贝 JPEG - 训练精度 98.9%, 测试精度 98.4% ——看起来 “Amazing!”

Saliency Map 检查: - 模型几乎只看 图像四角的背景

真相: - PNG 文件有 透明通道, 加载时透明部分变 黑色 - JPEG 没有透明通道, 背景多为 白色 / 自然色 - 模型其实在区分 “背景是不是黑的” 而非 “宝可梦 vs 数码宝贝”

[WARN] 易错点 (这个例子要刻在 DNA 里)

高准确率不等于学到了正确的概念。任何“看起来太好”的结果都应该用 Saliency / Shapley 等工具去检查。这种现象叫 shortcut learning / spurious correlation, 是可信 ML 关心的核心病态之一。

2. CAM: Class Activation Map

2.1 前置：架构要求

CAM 不能用于任意 CNN, 要求倒数第二层是 Global Average Pooling (GAP), 倒数第一层是 线性 (FC) 分类层。ResNet / GoogLeNet 等天然满足。

... → Conv → ReLU → ... → 最后一层 conv (输出 $H' \times W' \times K$)
 ↓ GAP
 $(1 \times 1 \times K)$ 即 F_k
 ↓ Linear ($K \rightarrow \bar{C}$ 类)
 logits → softmax

2.2 推导

记最后一层 conv 在空间位置 (x, y) 处第 k 个 channel 的激活为 $f_k(x, y)$ 。GAP 给出：

$$F_k = \sum_{x,y} f_k(x, y) \quad (5.4)$$

类 c 的 softmax 输入 (logit) 为：

$$S_c = \sum_k w_k^c F_k \quad (5.5)$$

其中 w_k^c 是 GAP 后那一层全连接权重 (类 c 对 channel k 的权重)。忽略 bias。

代回 (5.4)：

$$S_c = \sum_k w_k^c \sum_{x,y} f_k(x, y) = \sum_{x,y} \underbrace{\sum_k w_k^c f_k(x, y)}_{M_c(x,y)} \quad (5.6)$$

定义 Class Activation Map：

$$M_c(x, y) := \sum_k w_k^c f_k(x, y) \quad (5.7)$$

解读： $M_c(x, y)$ 直接告诉我们“空间位置 (x, y) 对类 c 的总贡献”——把 M_c 双线性上采样到原图尺寸，叠加可视化，就是类 c 的 CAM 热图。

2.3 为什么需要 GAP

如果倒数第二层不是 GAP 而是 Flatten + FC，那 FC 的权重就和 **某个具体空间位置上的 channel** 一一绑定，难以拆出“空间 × channel”的乘积结构。GAP 提供了一个“空间维度被聚合”的瓶颈，让 w_k^c 自然成为 channel 重要性，进而可以重新分发到空间。

2.4 实验现象

CAM 论文 (Zhou et al., CVPR 2016) 的经典图：同一张图在不同预测类下生成不同的热图——例如对“dome”类，热图集中在 **建筑的圆顶**；对“palace”类，热图集中在 **下方平整建筑体**。表明 CAM 能很好定位 **类别相关区域**。

2.5 应用：弱监督定位

意外副产品：只用图像级标签 (image-level label) 训练分类器，CAM 就能 **粗略定位物体边界框**。无需任何像素级标注 → 显著降低标注成本。这是 **weakly-supervised localization** 的奠基方法之一。

2.6 CAM 的局限

局限	说明
架构限制	必须 GAP + 线性分类层
分辨率低	M_c 在最后一层 conv 尺寸 (e.g. 7×7), 需上采样到原图, 细节丢失
只能解释最后一层	对中间层的语义没有直接刻画

后继: Grad-CAM (Selvaraju et al., 2017) 把 (5.7) 中的 w_k^c 换成 **每个 channel 的梯度均值**:

$$\alpha_k^c = \frac{1}{Z} \sum_{x,y} \frac{\partial S_c}{\partial f_k(x,y)} \quad (5.8)$$

$$M_c^{\text{Grad-CAM}}(x,y) = \text{ReLU}\left(\sum_k \alpha_k^c f_k(x,y)\right) \quad (5.9)$$

这样 **任意 CNN** 都能用, 且能针对中间任意一层做。

3. Saliency vs CAM 对比

维度	Saliency / SmoothGrad	CAM
来源	Backward (梯度)	Forward (激活加权)
计算	一次反向传播	一次前向 + 取最后一层激活
分辨率	输入像素级 (高)	最后 conv 层级 (低)
架构限制	任意可微模型	GAP + 线性分类层 (后由 Grad-CAM 解除)
嘈杂度	高 (需 SmoothGrad)	较低 (天然平滑)
颗粒度	像素	区域

4. 一个完整例题

[EX] 例题 5.1 (CAM 数值计算)

设最后一层 conv 输出 $2 \times 2 \times 3$, 激活为: $-f_1 = \begin{pmatrix} 1 & 2 \\ 0 & 1 \end{pmatrix} - f_2 = \begin{pmatrix} 0 & 1 \\ 1 & 2 \end{pmatrix} - f_3 = \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix}$

GAP 后: $F_1 = (1 + 2 + 0 + 1)/4 = 1, F_2 = 4/4 = 1, F_3 = 2/4 = 0.5$ 。

类“cat”的全连接权重 $w^{\text{cat}} = (2, -1, 3)$ 。


Logit $S_{\text{cat}} = 2 \cdot 1 + (-1) \cdot 1 + 3 \cdot 0.5 = 2.5$

CAM: $M_{\text{cat}}(x,y) = 2f_1(x,y) - 1f_2(x,y) + 3f_3(x,y) = 2 \begin{pmatrix} 1 & 2 \\ 0 & 1 \end{pmatrix} - \begin{pmatrix} 0 & 1 \\ 1 & 2 \end{pmatrix} + 3 \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix}$
 $= \begin{pmatrix} 2 & 4 \\ 0 & 2 \end{pmatrix} + \begin{pmatrix} 0 & -1 \\ -1 & -2 \end{pmatrix} + \begin{pmatrix} 6 & 0 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 8 & 3 \\ -1 & 0 \end{pmatrix}$

验证: $\sum_{x,y} M_{\text{cat}}(x,y)/4 = (8 + 3 - 1 + 0)/4 = 2.5 = S_{\text{cat}}$ (与 (5.6) 一致)

解读: 左上角 (8) 是模型预测为“cat”的最强证据; 右下角 (-1, 0) 反而稍微抑制。

5. 概念关系图



5.5 其他 Saliency 变种 (拓展)

除了 SmoothGrad, 研究界还提出多个改进版:

Integrated Gradients (Sundararajan et al., ICML 2017)

$$IG_i(x) = (x_i - x'_i) \int_{\alpha=0}^1 \frac{\partial f(x' + \alpha(x - x'))}{\partial x_i} d\alpha \quad (5.10)$$

x' 是 baseline (通常黑色图像)。好处: 满足 **Completeness** 公理 (各像素 IG 之和 = $f(x) - f(x')$), 类似 Shapley。

Guided Backpropagation (Springenberg et al., 2015)

反向传播过 ReLU 时, 只保留正梯度:

$$\frac{\partial L}{\partial z_i^{(\ell)}} = \mathbb{1}[z_i^{(\ell)} > 0] \cdot \mathbb{1}[\partial L / \partial z_i^{(\ell+1)} > 0] \cdot \frac{\partial L}{\partial z_i^{(\ell+1)}}$$

让生成的热图更”干净”, 但 Sanity Check (Adebayo et al., NeurIPS 2018) 显示它有时 与模型权重无关——输出像随机网络一样的图, 警惕。

Score-CAM (Wang et al., CVPR 2020 Workshop)

不用梯度, 而是把每个 channel 的激活 mask 上原图, 重新前向, 用预测分数当 channel 权重 → 避免梯度噪声 / 饱和问题。

5.6 Sanity Check: 解释方法本身要被怀疑

Adebayo et al. (NeurIPS 2018) “Sanity Checks for Saliency Maps”测试了主流方法在以下扰动下的表现：

- **Model Parameter Randomization Test**：把训练好的模型权重逐层重置成随机值。理想情况下解释应该变化巨大。
- **Data Randomization Test**：把训练数据的 label 随机重排，重新训练。理想情况下解释应该不可读。

发现：– Saliency, Integrated Gradients, SmoothGrad **通过** – Guided BP, Guided Grad-CAM **未通过** (随机模型也给出“漂亮”的热图！)

这说明视觉好看 $\neq$ 真正反映模型。可信 ML 评估必须用 sanity check。

6. 记号速查

符号	含义
x	输入图像
e	损失或目标类的 score
$\partial e / \partial x_i$	输出关于第 i 像素的偏导
$g_k \sim \mathcal{N}(0, \sigma^2)$	SmoothGrad 高斯噪声样本
$f_k(x, y)$	最后一层 conv 第 k channel 在 (x, y) 的激活
F_k	GAP 后的 channel 标量
w_k^c	类 c 对 channel k 的 FC 权重
S_c	类 c 的 logit
$M_c(x, y)$	类 c 的 CAM 热图
α_k^c	Grad-CAM 中第 k channel 的梯度加权

7. 期中复习要点

[TIP] 期中复习要点

1. **Saliency 公式 (5.1)**：能写出 $|\partial e / \partial x_i|$ 与一阶 Taylor 近似的关系。2. **SmoothGrad 公式 (5.3)**：能写出加噪 + 平均的形式，说明为什么能去噪。3. **Pokémon vs Digimon 案例**：能讲清楚 png/jpeg 背景颜色泄露真相，理解 shortcut learning。4. **CAM 推导 (5.4–5.7)**：必须能从 GAP $\rightarrow$ logit $\rightarrow$ 重排得到 $M_c = \sum_k w_k^c f_k$ 。5. **CAM 架构要求**：必须是 GAP + 线性分类层；否则需要用 Grad-CAM。6. **CAM vs Saliency 对比表**：能从分辨率、架构、嘈杂度三个维度做比较。7. **弱监督定位**：能说明为什么只用图像级标签 + CAM 就能做近似目标检测。8. **Grad-CAM 的推广方向**：把 w_k^c 替换成梯度均值 α_k^c ，再加 ReLU。

Lecture 06 —对抗攻击 (Adversarial Attack)

[TIP] 学习指南

本节核心：进入“可信 ML”第二大支柱——鲁棒性。聚焦 攻击方 视角：在不同访问权限下 (白盒 / 黑盒)，如何生成几乎不可见但能让 DNN 翻车的 **对抗样本 (adversarial example, AE)**。前置知识：第 2 / 3 讲的梯度、Cross-Entropy; ℓ_p 范数；带约束优化的拉格朗日 / 投影方法。重点关注：(1) 对抗样本的 min-max 形式化；(2) FGSM / BIM / PGD 公式与适用场景；(3) 黑盒攻击两条主路线 (Transfer-based / Query-based)。

0. 核心问题 / Motivation

经典图：一张 **狗** 的图加上肉眼几乎看不见的扰动后，DNN 以 98% 置信度判为 **鸵鸟 (ostrich)**。这种现象 (Szegedy et al., 2013; Goodfellow et al., 2014) 让人意识到：**深度模型的高准确率在最坏情况下完全不可靠。**

对抗样本 = 输入空间中精心构造、视觉上几乎不可分、但导致模型预测翻转的样本。

形式化：模型训练目标是

$$\min_{\theta} \mathbb{E}_{(x_i, y_i) \sim \mathcal{D}_{\text{train}}} L(f_{\theta}(x_i), y_i) \quad (6.1)$$

对抗攻击则在 固定 θ 后，对每个样本求：

$$\max_{x'} L(f_{\theta}(x'), y) \quad \text{s.t.} \quad \|x' - x\|_p \leq \epsilon, \quad x \in \mathcal{D}_{\text{test}} \quad (6.2)$$

“在 x 的 ϵ -ball 内找一个让损失最大的点”。

0.1 范数选择

- ℓ_{∞} 最常见，要求每个像素的修改不超过 ϵ ；适合“全局微小噪声”
- ℓ_2 整体扰动能量小；攻击在视觉上更“光滑”
- ℓ_0 / ℓ_1 稀疏扰动；适合“修改少数像素 (one-pixel attack)”

0.2 攻击分类轴

分类轴	选项
模型访问	白盒 White-box / 黑盒 Black-box
攻击目标	无目标 Untargeted (任意错类) / 有目标 Targeted (指定目标类)
扰动形式	数字 Digital / 物理 Physical (3D 打印贴纸、补丁)
一次性 / 普适	个例 (per-sample) / 通用扰动 UAP

1. 白盒攻击 (White-box)

1.1 设置

攻击者拥有 **模型完整信息**：架构、参数、超参、梯度。这是 **最强假设**、**最高成功率** 的场景，常用于评估防御方法的最差表现。

1.2 Direction I —基于梯度迭代

1.2.1 FGSM (Fast Gradient Sign Method)

Goodfellow et al., 2014: 一步走，沿着损失梯度的 **符号** 方向：

$$x^{\text{adv}} = x + \epsilon \text{sign}(\nabla_x L(f_\theta(x), y)) \quad (6.3)$$

特点：– 只需 1 次前向 + 1 次反向，**极快** – 满足 $\|x^{\text{adv}} - x\|_\infty = \epsilon$ (顶到 ϵ -ball 表面) – 对 robust 模型攻击成功率较低 (一步走太粗暴)

1.2.2 BIM (Basic Iterative Method)

Kurakin et al., 2016: 把 FGSM 拆成多小步，每步走 α ，并做 **clip 投影** 回 ϵ -ball：

$$x_0^{\text{adv}} = x, \quad x_{t+1}^{\text{adv}} = \text{Clip}_{x, \epsilon} \left\{ x_t^{\text{adv}} + \alpha \text{sign}(\nabla_x L(f(x_t^{\text{adv}}), y)) \right\} \quad (6.4)$$

其中 $\text{Clip}_{x, \epsilon}(z) := \min(\max(z, x - \epsilon), x + \epsilon)$ 是逐元素的截断。

1.2.3 PGD (Projected Gradient Descent) —白盒攻击金标准

Madry et al., 2018: 在 BIM 之上加 **随机初始化**：

$$x_0^{\text{adv}} = x + \text{Uniform}(-\epsilon, \epsilon) \quad (6.5)$$

迭代公式同 (6.4)。**随机起点** 让 PGD 探索 ϵ -ball 内更多局部极大值，相当于一个带约束的强 **first-order** 攻击。

[NOTE] 直觉

把 ϵ -ball 想成一个小方盒子。FGSM 朝坡度最陡方向一步顶到墙，BIM 多步走小步走到墙边，PGD 从盒内随机一点开始多步走 → 能找到墙上”更陡的极大点”。

1.2.4 三者对比

方法	步数	随机初始化	成功率 (对未防御模型)	计算成本
FGSM	1	否	~80% (CIFAR-10)	极低
BIM	10–40	否	~98%	中
PGD	10–40	是	~99%	中

1.3 Direction II —基于优化的精细攻击

1.3.1 DeepFool

Moosavi-Dezfooli et al., CVPR 2016: 在每步把 **决策边界** 用线性近似 (类似牛顿法)，沿最近边界法向走最小距离，把样本推过去。– 优点：找到 **最小扰动** (sample-wise 几乎最优 ℓ_2) – 缺点：迭代相对慢，扰动幅度需多次校准

1.3.2 C&W (Carlini & Wagner, 2017)

把“误分类”目标写成可优化目标：

$$\min_{\delta} \|\delta\|_p + c \cdot \max \left(\max_{i \neq t} Z_i(x + \delta) - Z_t(x + \delta), -\kappa \right) \quad (6.6)$$

其中 Z_i 是 logit, t 是目标类, κ 控制置信度, c 是平衡参数 (二分搜索)。

特点：– 对许多防御 (e.g. 蒸馏 defensive distillation) 都能突破 – 计算贵, 但扰动最小化更精细 – 是评估防御鲁棒性的“金标准”之一

1.4 几种方法对比一览

方法	一步 / 迭代	主要范数	目标 / 无目标	强度
FGSM	一步	ℓ_{∞}	都可	★★
BIM	迭代	ℓ_{∞}	都可	★★★★
PGD	迭代 + 随机	ℓ_{∞} (ℓ_2 推广)	都可	★★★★★
DeepFool	迭代	ℓ_2	无目标	★★★★
C&W	优化	$\ell_2 / \ell_{\infty} / \ell_0$	都可	★★★★★

[WARN] 易错点

评估一个防御时, 不要只跑 FGSM 一遍就宣称“鲁棒”。许多 2017–2019 年的“防御”都被 PGD / C&W 攻破 (Athalye et al., 2018 “Obfuscated Gradients”论文)。**Defense evaluation 必须用强攻击。**

2. 黑盒攻击 (Black-box)

2.1 设置

模型被部署到云端 / API 后端, 攻击者 看不到 架构、参数、梯度, 只能 查询 API 获取：– 硬标签 (hard label)：只返回类别 – 软标签 / 分数 (score)：返回所有类的概率

2.2 两条主路线

黑盒攻击

- Transferability-based ← 用替代模型生成 AE, 靠迁移性攻击目标
- Query-based ← 直接查询目标 API, 迭代优化扰动

2.3 Transferability-based

2.3.1 核心观察 (Transferability)

对模型 f_1 有效的 AE, 对结构 / 训练数据相似的 f_2 通常也有效。攻击流程：

1. 训练或拿到一个 source model f_{src}
2. 用 PGD / C&W 等白盒方法在 f_{src} 上生成 AE
3. 把 AE 直接送给 target model f_{tgt}
4. 期望迁移成功

2.3.2 提升迁移性的三类技巧

(a) **Momentum-based** Dong et al., CVPR 2018 (“MI-FGSM”): 在迭代过程中维护 **动量项**:

$$g_{t+1} = \mu g_t + \frac{\nabla_x L_t}{\|\nabla_x L_t\|_1}, \quad x_{t+1}^{\text{adv}} = \text{Clip}(x_t^{\text{adv}} + \alpha \text{sign}(g_{t+1})) \quad (6.7)$$

动量能让攻击跳出 f_{src} 的局部极大点, 迁移到 f_{tgt} 时更鲁棒。

(b) **Diverse Input** Xie et al., CVPR 2019 (“DI²-FGSM”): 每次迭代前对 x_t^{adv} 做 **随机变换** (resize / pad / crop), 让 AE 不过度拟合 f_{src} 。

类似地: Translation-Invariant Attack (Dong et al., 2019)。

(c) **Architecture-related** Wu et al., ICLR 2020 (“Skip Connections Matter”): 发现 ResNet 的 skip connection 上的梯度对迁移性贡献巨大。在反向时给 skip 路径加权能显著提升迁移率。

2.3.3 局限

- 成功率难达 100%
- 受 source / target 相似度限制
- 不能保证特定目标类 (targeted) 的迁移

2.4 Query-based

2.4.1 任务

直接在目标模型上做 **零阶优化 (zeroth-order optimization)** ——没有梯度, 只能靠多次查询估梯度或搜索。

2.4.2 按返回信息分两类

Score-based (有概率分数):

方法	思想
ZOO (Chen et al., 2017)	用有限差分估梯度
AutoZOOM (Tu et al., 2019)	$\hat{g}_i \approx (L(x + h e_i) - L(x))/h$, 再做坐标下降
Square Attack (Andriushchenko et al., 2020)	用 autoencoder 把高维输入压到低维, 在低维做 ZOO
NES / NAttack	随机方块扰动 + 接受率搜索; 不需要梯度估计; 极高效 自然进化策略, 把搜索方向参数化为高斯分布

Hard-label (只有类别):

方法	思想
Boundary Attack (Brendel et al., ICLR 2018)	从一个已是 adversarial 的点出发, 沿决策边界 random walk 不断逼近原图
RayS (Chen & Gu, KDD 2020)	在 ℓ_∞ 球面方向上做 ray search, 把问题降到 1D

2.4.3 查询复杂度

攻击 ImageNet 上的 ResNet50, 2024 年代典型查询数 (untargeted, $\ell_\infty = 0.05$): - ZOO 类: $\sim 10^5$ – 10^6 - Square Attack: $\sim 10^3$ - Boundary Attack: $\sim 10^4$ – 10^5 - 现代分布学习 (NP-Attack, Bai et al., ECCV 2020): 数百 query 即可

[WARN] 易错点

查询数过多容易被 API 检测到 (rate limit / anomaly detection)。实际攻击中, “少查询 + 高成功率”才是关键指标。

3. 物理对抗攻击 (Physical AE)

数字像素扰动到现实世界往往因 打印失真 / 摄像头噪声 / 视角变化 而失效。物理攻击的目标是 在现实可实施的扰动。

3.1 主要形式

形式	代表	应用
Adversarial Patch	Brown et al., 2017	一块可见但语义不显眼的贴纸
Physical Perturbation	Eykholt et al., CVPR 2018 (“Robust Physical-World Attacks”)	在 STOP 标志上贴黑白方块, 让自动驾驶误判为“限速 45”
Adversarial Camouflage	Duan, Ma, Wang et al., CVPR 2020	把扰动伪装成自然 style, 肉眼看不出异常

3.2 训练要点 (Expectation over Transformations, EOT)

$$\delta^* = \arg \max_{\delta \in \Delta} \mathbb{E}_{T \sim \mathcal{T}} [L(f(T(x + \delta)), y)] \quad (6.8)$$

其中 T 是随机变换 (旋转、缩放、亮度、噪声) ——让 δ 对一系列变换都鲁棒。

4. 关键攻击算法对照表

算法	类别	公式核心	典型应用
FGSM	白盒	$x + \epsilon \text{sign}(\nabla L)$	教学 / 弱基线
BIM	白盒	多步 + Clip	鲁棒性下限
PGD	白盒	多步 + 随机起点 + Clip	评估金标准
C&W	白盒	最小化 $\ \delta\ + c \cdot g(x + \delta)$	突破弱防御
MI-FGSM	白盒 → 迁移	+ 动量	提升黑盒迁移
DI-FGSM	白盒 → 迁移	+ 输入变换	提升黑盒迁移
Square Attack	黑盒 score	随机方块搜索	高效
Boundary Attack	黑盒 hard-label	沿边界 walk	强限制场景
Adv Patch	物理	EOT + 贴纸	现实可部署

5. 一个完整例题

[EX] 例题 6.1 (PGD 手算一步)

设 1D 二分类, 模型 $f(x) = wx + b$ with $w = 2, b = -1$ 。真实类 $y = 1$, 标量 cross-entropy loss

$$L = -\log \sigma(wx + b) \cdot \mathbb{1}[y = 1] - \log(1 - \sigma(\cdot)) \cdot \mathbb{1}[y = 0]$$

取 $y = 1, x = 1$ 。 $\epsilon = 0.5, \alpha = 0.2, T = 2$ 步。

步骤:- $z = wx + b = 1, \sigma(1) \approx 0.731 - \partial L / \partial x = -w(1 - \sigma(z)) = -2 \cdot 0.269 \approx -0.538$
- 随机初始化 (略, 取 $x_0 = 1$)

Step 1: - $\text{sign}(\text{梯度}) = -1 - x_1 = \text{Clip}_{x, \epsilon}(1 + 0.2 \cdot (-1)) = \text{Clip}(0.8) = 0.8$ (落在 $[0.5, 1.5]$ 内)


注意 (6.4) 中加号是因为我们在 **最大化** loss (即扰动让模型置信度降低)。此处 loss 关于 x 是 **减函数** 在 $y = 1$ 类内 (减 x 让 logit 减、错误概率增、loss 增), 所以 $\text{sign}(\text{梯度})$ 取负, 方向 -1 让 x 减小。

Step 2: - 在 $x_1 = 0.8$ 处重新算梯度, sign 仍为 $-1 - x_2 = \text{Clip}(0.8 - 0.2) = 0.6$

此时 $z = 2 \cdot 0.6 - 1 = 0.2, \sigma(0.2) \approx 0.55$, 模型置信度从 0.73 降到 0.55, **接近决策边界**。

若再多走几步会被 Clip 限制在 0.5 (即 $x - \epsilon = 0.5$), 此时 $z = 0, \sigma = 0.5$, 刚好越过边界。

6. 概念关系图



7. 记号速查

符号	含义
x, x^{adv}	干净样本 / 对抗样本
δ	扰动 ($x^{\text{adv}} = x + \delta$)
ϵ	扰动幅度上限
$\ \cdot\ _p$	ℓ_p 范数 ($p \in \{0, 2, \infty\}$)
L	损失函数 (通常 cross-entropy)
$\nabla_x L$	损失关于输入的梯度
$\text{sign}(\cdot)$	逐元素符号
$\text{Clip}_{x, \epsilon}$	投影回 ϵ -ball
α	PGD 步长
T	PGD 步数
$f_{\text{src}}, f_{\text{tgt}}$	替代 / 目标模型
$Z_i(x)$	类 i 的 logit
$\mathcal{T}$	EOT 中的物理变换分布

8. 期中复习要点

[TIP] 期中复习要点

1. 对抗样本 min-max 形式 (6.1)–(6.2): 能写出训练 vs 攻击的两个公式; 说明攻击是固定 θ 后的最大化。2. FGSM / BIM / PGD 三式必背: 能写出 (6.3)、(6.4)、(6.5), 解释每个符号; 说出三者的相对强度。3. PGD 为什么是金标准: 随机起点 + 多步 + 投影, 是 first-order 攻击的强者。4. C&W 的目标函数 (6.6): 理解为什么 $\max(\dots, -\kappa)$ 中 κ 控制置信度。5. 白盒 vs 黑盒: 能说清访问权限差异及对应威胁模型。6. Transferability-based 提升技巧: 动量 / 输入多样化 / 架构 (skip connection)。7. Query-based 两类: score-based (ZOO / Square) vs hard-label (Boundary / RayS)。8. 物理攻击 + EOT 公式 (6.8): 理解为什么 EOT 让物理 AE 鲁棒。9. 评估陷阱: 单一弱攻击不能下“鲁棒”结论; 多种强攻击 (PGD + C&W + 黑盒) 综合评估。10. 范数选择对扰动可视感的影响: ℓ_∞ 强制每像素不超 $\epsilon \rightarrow$ 整体看噪声; ℓ_2 总能量小 $\rightarrow$ 视觉光滑; ℓ_0 稀疏 $\rightarrow$ 少数像素被改。

Lecture 07 —对抗防御 (Adversarial Defense)

[TIP] 学习指南

本节核心：在第 6 讲看清”攻击有多狠”之后，本节回到 **防御方**：以 **对抗训练 (Adversarial Training, AT)** 为主线，理解 min-max 优化、FOSC 收敛分析，并学习两类前沿改进——**AWP (从权重视角)** 与 **TRADES / MART (从损失结构视角)**。前置知识：第 6 讲的 PGD；优化的一阶 stationary 条件；PAC-Bayesian 直觉；正则化。重点关注：(1) AT 的 min-max 形式与”内 max + 外 min”两步迭代；(2) FOSC 公式 + 与鲁棒性的相关性；(3) AWP / TRADES / MART 三种改进的动机与公式。

0. 核心问题 / Motivation

第 6 讲展示：现代 DNN 在对抗扰动下”准确率清零”。所以我们注定脆弱吗？不一定。如同免疫系统接触病原后产生抗体，模型也可以在训练阶段 **见过对抗样本** → 学会忽略它们。这就是 **对抗训练 (AT)** 的本质。

Adversarial aspects = stress-testing our solutions.

0.1 已被否定的”伪防御”

Gradient Masking / Obfuscation ——隐藏 / 扰乱模型梯度让攻击者无法计算 PGD 更新。Athalye et al. (2018, ICML, “Obfuscated Gradients Give a False Sense of Security”) 系统性地展示：这类防御都 **能被 BPDA / EOT 等技巧绕过**。

[WARN] 易错点

任何”让攻击者算不出梯度”的防御都要警惕 gradient masking。真正的鲁棒性应在 PGD / AutoAttack 等强攻击下仍保有高准确率。

1. 对抗训练 (Adversarial Training) 基础

1.1 Madry 经典 min-max 框架

Madry et al., ICLR 2018:

$$\min_{\theta} \frac{1}{n} \sum_{i=1}^n \underbrace{\max_{\|\delta_i\|_{\infty} \leq \epsilon} L(f_{\theta}(x_i + \delta_i), y_i)}_{\text{Inner Max: 攻击}} \quad (7.1)$$

Outer Min: 训练

实现：

```

for batch (x, y) in train_loader:
    # Inner Maximization (一轮 PGD)
    x_adv = PGD(f_theta, x, y, eps, alpha, steps)
    # Outer Minimization (一步 SGD)
    loss = cross_entropy(f_theta(x_adv), y)
    loss.backward()
    optimizer.step()

```

1.2 直觉解读

标准训练 = 在 i.i.d. 训练分布下找最优 θ 。对抗训练 = 在 训练分布的 ϵ -邻域 worst case 下找最优 $\theta \rightarrow$ 学到的模型对最坏扰动也鲁棒。

1.3 性能预览 (CIFAR-10, PGD-20 $\ell_\infty = 8/255$)

方法	干净准确率	PGD 鲁棒准确率
标准训练	~95%	~0%
Madry AT	~85%	~50%
TRADES	~84%	~55%
MART	~83%	~57%
AWP-AT	~85%	~58%

(注：精确数字依赖架构 / 训练超参，此处为粗略量级)

可见：鲁棒模型的干净准确率会下降。这就是 §4 要讲的 accuracy-robustness trade-off。

2. FOSC: 度量”内 Max 是否解好了”

2.1 为什么要度量 inner-max 的解好不好？

PGD 步数过少 $\rightarrow$ 攻击太弱 $\rightarrow$ 模型见的对抗样本不强 $\rightarrow$ 训练出来的鲁棒性虚高。但 step 越多越慢。能否 自动判断 PGD 是否已收敛？

2.2 First-Order Stationary Condition (FOSC)

Wang, Ma, et al., ICML 2019 “On the Convergence and Robustness of Adversarial Training”:

[NOTE] 定义 7.1 (FOSC)

给定干净样本 x_0 ，记 x_k 是 PGD 第 k 步的中间点。FOSC 值为

$$c(x_k) := \max_{x \in \chi} \langle x - x_k, \nabla_x f(\theta, x_k) \rangle \quad (7.2)$$

其中 $\chi = \{x : \|x - x_0\|_\infty \leq \epsilon\}$ 是 ϵ -球， $f(\theta, x) = L(h_\theta(x), y)$ ， $\langle \cdot, \cdot \rangle$ 为内积。

性质：- $c(x_k) \geq 0$ 。 $c(x_k) = 0$ 意味着 PGD 找到了 inner-max 的精确解。- 越小，说明对抗样本越”逼近极大”，对抗训练的内层求解质量越好。- 有闭式解：

$$c(x_k) = \epsilon \|\nabla_x f(\theta, x_k)\|_1 - \langle x_k - x_0, \nabla_x f(\theta, x_k) \rangle \quad (7.3)$$

(推导：在 ℓ_∞ 球内最大化线性函数，最优解 $x^* = x_0 + \epsilon \text{sign}(\nabla)$ ，代入即得)

2.3 收敛定理

[NOTE] 定理 7.2 (AT 收敛, Wang et al., ICML 2019)

在一定假设下, 记 $\Delta = L_S(\theta_0) - \min_{\theta} L_S(\theta)$ 。若外层学习率 $\eta_t = \min(\frac{1}{L}, \sqrt{\Delta/(L\sigma^2 T)})$, 则 AT 输出满足

$$\frac{1}{T} \sum_{t=0}^{T-1} \mathbb{E} \|\nabla L_S(\theta_t)\|_2^2 \leq \frac{4\sigma\sqrt{L\Delta}}{\sqrt{T}} + 5L_{\phi x}^2 \cdot \frac{\delta}{\mu} \quad (7.4)$$

当内层 FOSC $\leq \delta$ 时, AT 能收敛到一阶 stationary 点, 精度 $\sim \delta/\mu$ 。

直观: 内层 max 解得越准 (δ 越小), 外层 min 收敛越精确。AT 的瓶颈在内层。

2.4 实验观察

- PGD-1/4 步长产生最佳鲁棒性, FOSC 分布集中在 0 附近
- PGD-20/30 步比 PGD-10 略好, FOSC 分布更陡
- 损失分布对鲁棒性区分度低, **FOSC 是更可靠的指标**

2.5 为什么需要 Warm-up

重要洞察: AT 早期阶段 **overfit 强 PGD 样本** 反而损害最终鲁棒性。原因: 早期模型还很弱, 强 PGD 找到的对抗样本太极端, 模型陷入糟糕的局部解。

Warm-up 策略: – 早期用弱攻击 (FGSM 或 PGD-1) – 等 epochs 多了再切到 PGD-10

实验: warm-up 后最终鲁棒性 +1–2%。FOSC 分布也更健康。

3. AWP: 从权重 Loss Landscape 视角

3.1 动机

Wu, Xia, Wang, NeurIPS 2020 “Adversarial Weight Perturbation Helps Robust Generalization”.

标准训练里有经典结论: **flatter weight loss landscape** **smaller generalization gap** (Li et al., NeurIPS 2018, “Visualizing the Loss Landscape”)。在对抗训练里这个结论还成立吗?

3.2 重写 AT 损失

把 (7.1) 重写以便和标准训练对比:

$$\underbrace{\min_{\theta} \frac{1}{n} \sum_i \max_{\delta_i} L(f_{\theta}(x_i + \delta_i), y_i)}_{\text{AT}} = \underbrace{\min_{\theta} \frac{1}{n} \sum_i L(f_{\theta}(x_i), y_i)}_{\text{Standard}} + \text{Robust gap} \quad (7.5)$$

3.3 关键实验

正确做法是 **on-the-fly** 重新生成对抗本来绘制 weight loss landscape (而非用 pre-generated AE)。结论:

weight loss landscape 越平坦, robust generalization gap 越小。

跨多个 AT 方法 (Madry AT, TRADES, MART, RST, AT-ES) 都成立。

3.4 AWP 算法：显式扁平化

把”平坦权重 loss landscape”建模成 对权重也求 worst-case:

$$\min_{\theta} \max_{\|v\| \leq \gamma \|\theta\|} \frac{1}{n} \sum_i \max_{\delta_i} L(f_{\theta+v}(x_i + \delta_i), y_i) \quad (7.6)$$

两个 max 嵌套：– 内 max (input perturbation)：对每个样本找 worst input – 外 max (weight perturbation)：对多个样本找 全局 worst weight 扰动

[NOTE] 直觉

输入扰动是 局部的 worst-case (per-sample)，权重扰动是 全局的 worst-case (over batch)。两层 max 同时存在，让最终 θ^* 既能扛输入攻击，又位于 loss landscape 的平坦区域。

3.5 PAC-Bayesian 视角

PAC-Bayes 界粗略说”测试损失 $\leq$ 训练损失 + 平坦性项”。AWP 通过显式最大化权重扰动，直接控制平坦性项，因此能改善鲁棒泛化。

3.6 性能

AWP 是 通用插件：可加到任意 AT 框架 (Madry / TRADES / MART)，普遍提升鲁棒准确率 1–3%。CVPR 2021 Adversarial Competition 的多支队伍把 AWP 作为标配。

4. Accuracy–Robustness Trade-off 与 TRADES

4.1 现象

更高鲁棒性 更低干净准确率。Madry AT 的干净准确率从 95% 降到 85%。

4.2 TRADES 损失

Zhang et al., ICML 2019:

$$\mathcal{L}_{\text{TRADES}} = \underbrace{\text{CE}(f(x), y)}_{\text{Natural Loss}} + \beta \underbrace{\max_{\|\delta\| \leq \epsilon} \text{KL}(f(x) \| f(x + \delta))}_{\text{Robust Regularization}} \quad (7.7)$$

解读：– 第 1 项保住干净准确率 – 第 2 项要求模型在 x 与 $x + \delta$ 之间输出分布保持一致 (KL 散度小) – β 控制 accuracy vs robustness 平衡

获 NeurIPS 2018 Adversarial Vision Challenge 第 1 名。

4.3 与 AT 的关系

TRADES 把 (7.1) 中”adv 样本上的 CE 损失”拆成 干净 CE + 一致性正则，结构更清晰，理论上能在 trade-off 曲线上达到更好的点。

5. MART: Misclassified Examples 视角

5.1 动机

Wang, Zou, et al., ICLR 2020 “Improving Adversarial Robustness Requires Revisiting Misclassified Examples”

关键观察：标准 AT 对所有样本一视同仁。但 **被错分类的样本** S^- (即 $f(x) \neq y$) 与 **正确分类的样本** S^+ 对最终鲁棒性的影响 **不对称**。

5.2 实验设计

用一个预训练网络选样本, 比较 S^- 与 S^+ 的 13% 子集 (大小相同): – **改变内 max 攻击强度** (FGSM vs PGD-20): 对 S^- , S^+ 影响都 **不大** – **改变外 min 正则 / 损失形式**: 对 S^- 影响显著, 对 S^+ 影响小

结论: misclassified examples 是鲁棒性的关键, 且改进点应在 outer minimization。

5.3 Misclassification-Aware Adversarial Risk

普通 adv risk:

$$\mathcal{R}_{\text{adv}}(f) = \frac{1}{n} \sum_i \max_{\delta_i} \mathbb{1}\{f(x_i + \delta_i) \neq y_i\} \quad (7.8)$$

按预测正确性拆分:

$$\mathcal{R}_{\text{adv}}(f) = \mathcal{R}_{\text{adv}}^+(f) + \mathcal{R}_{\text{adv}}^-(f) \quad (7.9)$$

MART 对错分类样本加更强惩罚:

$$\mathcal{L}_{\text{MART}} = \underbrace{\text{BCE}(f(x^{\text{adv}}), y)}_{\text{boosted CE}} + \lambda \underbrace{\text{KL}(f(x) \| f(x^{\text{adv}})) \cdot (1 - \hat{p}_y(x))}_{\text{重点关注错分样本}} \quad (7.10)$$

其中 $1 - \hat{p}_y(x)$ 是模型对真实类 y 的“非自信度”, 错分样本这一项较大, 从而权重更高。

5.4 实验

MART 在 CIFAR-10 / SVHN 等数据上比 Madry AT 提升 2–3% PGD 鲁棒准确率, 且干净准确率几乎不掉。

6. 三种改进对照

方法	关键洞察	公式核心	主要超参
Madry AT	min-max baseline	式 (7.1)	ϵ, α, T
AWP	weight loss landscape 越平 → robust gap 越小	式 (7.6), 两层 max	γ (权重扰动幅度)
TRADES	解耦干净准确率 / 鲁棒一致性	式 (7.7), CE + KL	β (trade-off)
MART	错分样本贡献最大	式 (7.10), boosted BCE + weighted KL	λ

7. 一个完整例题

[EX] 例题 7.1 (FOSC 计算)

假设损失函数 $f(\theta, x) = \frac{1}{2}\|x - x^*\|_2^2$ 其中 $x^* = [0, 0]^\top$, $x_0 = [1, 1]^\top$, $\epsilon = 0.5$ (使用 ℓ_∞ 球)。
当前 PGD 中间点 $x_k = [0.7, 0.8]^\top$ 。计算 FOSC $c(x_k)$ 。

解: 梯度 $\nabla_x f = x - x^* = [0.7, 0.8]^\top$
用闭式 (7.3):

$$\epsilon \|\nabla\|_1 = 0.5 \cdot (0.7 + 0.8) = 0.75$$


$$\langle x_k - x_0, \nabla \rangle = \langle [-0.3, -0.2], [0.7, 0.8] \rangle = -0.21 - 0.16 = -0.37$$

$$c(x_k) = 0.75 - (-0.37) = 1.12$$

$c = 1.12 > 0$ 说明 x_k 还没到 ϵ -ball 内的最大点。继续 PGD 才能让 FOSC 接近 0。

注: 这里 f 是凹的 $\rightarrow$ 增大 $\|x\|$ 增大 loss, PGD 会让 x 远离 $x^* = 0$, 最终落在 $x_0 + \epsilon \text{sign}(\nabla)$ 。

8. 概念关系图



9. 记号速查

符号	含义
f_θ	神经网络分类器
δ	输入扰动
ϵ	扰动幅度上限 (ℓ_∞)
x^{adv}	对抗样本
L	损失函数 (通常 CE)

符号	含义
$\nabla_x f$	损失对输入的梯度
$c(x_k)$	FOSC 值
χ	ϵ -球
v	AWP 中的权重扰动
γ	AWP 权重扰动相对大小
β	TRADES 平衡系数
λ	MART 正则系数
$\hat{p}_y(x)$	模型对真实类的预测概率
S^+, S^-	预训练分类正确 / 错误的子集

10. 期中复习要点

[TIP] 期中复习要点

1. **AT min-max 公式 (7.1)** 必背：能写出内 max 是 PGD、外 min 是 SGD。2. **Gradient Masking 是伪防御**：能举例（蒸馏 / 输入随机化等）并说明为什么。3. **FOSC 定义 (7.2) + 闭式 (7.3)**：理解 FOSC 测量内层解的收敛质量；能解释为什么 FOSC 接近 0 是好事。4. **Warm-up 策略**：早期用弱攻击避免 overfit，后期切强攻击；为什么这样 work。5. **AWP 双 max (7.6)**：能写出公式；解释 input perturbation 与 weight perturbation 的“局部 vs 全局”差异；PAC-Bayes 直觉。6. **平坦权重 loss landscape** 小 **robust generalization gap**：标准训练里就有这个结论，对抗训练里需要 **on-the-fly** 生成 AE 才能正确观察。7. **TRADES 损失 (7.7)**：CE + $\beta \cdot$ KL，能解释每一项的角色； β 调节 accuracy-robustness。8. **MART 损失 (7.10)**：boosted BCE + weighted KL，重点惩罚错分样本；为什么错分样本更重要？9. **Accuracy-Robustness Trade-off**：必然现象，所有 AT 方法都在这条曲线上挑点。10. **方法对照表**：能填出 AT / AWP / TRADES / MART 的关键洞察 / 公式核心 / 主要超参。