Trustworthy Machine Learning —PKU 25-26 春

可信机器学习课程笔记

AutoPku · 整理自王奕森老师课件

2026-05-03

目录

前言 **3**
全局知识图谱 . . . 3
全局符号与术语对照 . . . 3
阅读建议 . . . 4

Lecture 1: Course Overview **5**
核心问题/Motivation . . . 5
主要内容 . . . 5
概念关系 . . . 7
课程模块与作业 . . . 7
结论 . . . 7
记号速查 . . . 7

Lecture 2: Introduction of Machine Learning **8**
核心问题/Motivation . . . 8
主要内容 . . . 8
概念关系 . . . 10
结论 . . . 10
记号速查 . . . 10

Lecture 3: Convolutional Neural Network (CNN) **12**
核心问题/Motivation . . . 12
主要内容 . . . 12
概念关系 . . . 14
结论 . . . 14
记号速查 . . . 15

Lecture 4: Explanations (XAI) **16**
核心问题/Motivation . . . 16
主要内容 . . . 16
概念关系 . . . 20
结论 . . . 20
记号速查 . . . 20

Lecture 5: Saliency Maps and CAM **22**
核心问题/Motivation . . . 22
主要内容 . . . 22
概念关系 . . . 25
结论 . . . 25
记号速查 . . . 25

Lecture 6: Adversarial Attacks（对抗攻击） **26**
6.0 为什么要研究对抗攻击 . . . 26
6.1 形式化定义 . . . 27

6.2 一阶白盒：FGSM . . . 27
6.3 多步白盒：BIM / I-FGSM . . . 28
6.4 PGD（含 random restart） . . . 28
6.5 MI-FGSM（动量） . . . 29
6.6 DeepFool（线性近似最小扰动） . . . 29
6.7 C&W（带 box 约束的最优化） . . . 30
6.8 迁移增强：DI / TI / SI / SGM . . . 30
6.9 黑盒攻击全景 . . . 31
6.10 通用扰动 UAP（Moosavi-Dezfooli 2017） . . . 32
6.11 物理世界攻击 . . . 32
6.12 可迁移性与对抗子空间 . . . 33
概念关系 . . . 35
结论 . . . 35
记号速查 . . . 35

Lecture 7: Adversarial Defense（对抗防御） 37
7.0 为什么需要对抗训练 . . . 37
7.1 不变量：Madry min-max 鞍点目标 . . . 37
7.2 PGD-AT：用投影梯度近似内层 max . . . 38
7.3 FOSC：内层 max 解到什么程度才够?（Wang & Ma et al., ICML 2019） . . . 39
7.4 TRADES：把鲁棒拆成自然误差 + 边界误差（Zhang et al., ICML 2019） . . . 40
7.5 MART：把误分类样本”找回来”（Wang et al., ICLR 2020） . . . 41
7.6 AWP：在权重空间也做对抗（Wu, Xia & Wang, NeurIPS 2020） . . . 42
7.7 对比一览表 . . . 44
7.8 反模式：Gradient Masking / Obfuscated Gradients . . . 44
7.9 评估金标准 AutoAttack（Croce & Hein, ICML 2020） . . . 44
7.10 认证防御（一段简介） . . . 45
概念关系 . . . 46
结论 . . . 47
记号速查 . . . 47

前言

可信机器学习（Trustworthy Machine Learning, TML）研究让深度学习模型在保持精度的同时，满足**鲁棒性、可解释性、隐私性、公平性**等可信赖性要求。本课程由王奕森老师讲授，按"基础回顾 → 解释性 → 对抗攻防"主线展开。本笔记整理自前 7 讲课件（共 ~250 页），保留数学定义、定理、关键公式与证明思路，去除历史轶事与冗余比喻；每讲附 mermaid 概念图、易错点提示与期中复习要点。

全局知识图谱

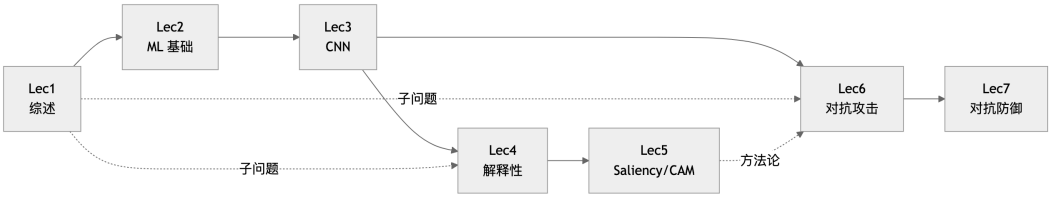

全局符号与术语对照

中文	English	符号 / 缩写	首次出现
模型 / 假设	Model / Hypothesis	$f_\theta : \mathcal{X} \to \mathcal{Y}$	Lec1
经验风险最小化	Empirical Risk Minimization	ERM	Lec2
卷积神经网络	Convolutional Neural Network	CNN	Lec3
感受野	Receptive Field	RF	Lec3
残差连接	Residual Connection	$y = F(x) + x$	Lec3
局部可解释模型	Local Interpretable Model-agnostic Explanations	LIME	Lec4
Shapley 值	Shapley Value	ϕ_i	Lec4
显著性图	Saliency Map	$S(x)$	Lec5
类激活图	Class Activation Map	CAM	Lec5
梯度类激活图	Gradient-weighted CAM	Grad-CAM	Lec5
对抗样本	Adversarial Example	$x' = x + \delta,\ \|\delta\|_p \le \epsilon$	Lec6
快速梯度符号法	Fast Gradient Sign Method	FGSM	Lec6
投影梯度下降	Projected Gradient Descent	PGD	Lec6
对抗训练	Adversarial Training	AT	Lec7
一阶平稳收敛准则	First-Order Stationary Condition	FOSC	Lec7
权重对抗扰动	Adversarial Weight Perturbation	AWP	Lec7
鲁棒蒸馏	TRADES	TRADES	Lec7

中文	English	符号 / 缩写	首次出现
误分类感知训练	MART	MART	Lec7

阅读建议

- 期中复习：直接看每讲末尾 `[!tip] 期中复习要点` callout。
- 速查公式：用 `\tag{X.Y}` 编号定位公式，例如 PGD 更新见 (6.3)。
- Anki 卡片：`notes/anki/all_cards.tsv` 共 113 张，可直接 import。

Lecture 1: Course Overview

[TIP] 学习指南

本节核心：可信机器学习（Trustworthy ML）研究在保持精度与效率的前提下，让模型同时满足可解释性、鲁棒性、隐私性、公平性等要求；本讲为整门课程导论与问题分类。前置知识：机器学习基础（监督学习、损失函数、梯度下降）、线性代数与概率论、深度学习基本结构（CNN/MLP）。重点关注：Trustworthy ML 的子问题分类与各自的形式化定义雏形（鲁棒性、隐私、公平性、可解释性、后门）。

核心问题/Motivation

- 传统 ML 只优化精度 (accuracy) 与效率 (efficiency)，但部署中暴露大量"不可信"案例：对抗样本（图像 + 微小扰动 → 分类错误）、Face ID 被破解、自动驾驶事故、ChatGPT 输出污染、AI 医疗误诊、模型偏见。
- 给定模型 $f_\theta : \mathcal{X} \to \mathcal{Y}$ 与输入 x，传统目标只关心

$$\min_\theta \mathbb{E}_{(x,y)\sim\mathcal{D}}\, \ell(f_\theta(x), y) \tag{1.1}$$

- 可信 ML 在 (1.1) 之外，需附加约束：鲁棒性 $R(f_\theta)$、隐私 $P(f_\theta)$、公平性 $F(f_\theta)$、可解释性 $E(f_\theta)$ 等同时达标。

主要内容

定义 1.1（Machine Learning，Tom Mitchell）

陈述：A computer program is said to learn from experience E with respect to task T and performance measure P, if its performance on T, as measured by P, improves with E。**符号**：T 任务，P 性能度量，E 经验/数据。

[NOTE] 直觉理解

ML 本质是数据驱动 (非规则驱动) 的"自我演化"过程；其能力上限由数据分布与假设空间共同决定。

定义 1.2（Deep Learning）

ML 的子领域，使用受脑结构启发的人工神经网络（ANN）作为假设类，通过多层非线性变换学习层次化表示。

定义 1.3（Trustworthy ML）

陈述：在保持传统 ML 精度与效率的同时，使模型在鲁棒性 (robustness)、隐私性 (privacy)、公平性 (fairness)、可解释性 (explainability)、抗后门 (backdoor) 等维度同样可信赖。**形式化雏形**：寻找 $\theta^\star$ 使

$$\theta^\star = \arg\min_\theta \ \mathbb{E}_{\mathcal{D}}\, \ell(f_\theta(x), y) \ \text{ s.t. } \ R, P, F, E \text{ 约束成立} \tag{1.2}$$

定义 1.4（AI Robustness）

陈述：AI robustness measures how much of the output changes of the AI system when the input is slightly changed。**形式化**：对扰动集 $\mathcal{B}_\epsilon(x) = \{x' : \|x' - x\|_p \le \epsilon\}$，鲁棒性可写作

$$\Pr_{x\sim\mathcal{D}}\Big[\forall x' \in \mathcal{B}_\epsilon(x) : \ f_\theta(x') = f_\theta(x)\Big] \tag{1.3}$$

[NOTE] 直觉理解

输入小扰动不应改变输出；对抗样本就是落在 $\mathcal{B}_\epsilon(x)$ 内但被误分类的点。

定义 1.5（Adversarial Example）

对真实标签 y，存在 $x' \in \mathcal{B}_\epsilon(x)$ 使 $f_\theta(x') \neq y$。课件示例：原图为"狗"82% 置信，加扰动后被分类为"鸵鸟"98% 置信。

定义 1.6（Privacy，Alan Westin）

个人、群体或机构有权自行决定 *何时、如何、在何种程度上*向他人传达关于自身的信息。在大数据/AI 时代，便利的代价是必须共享个人数据，由此产生 Deepfake、人脸数据泄漏等问题。

定义 1.7（Fairness）

即便假定"数据不会说谎"，由于数据质量（噪声、类别不平衡）或训练算法本身的归纳偏置，模型仍可能产生针对特定群体的系统性偏差，需在算法层面显式约束。

定义 1.8（Explainability）

要求模型给出 *为何*做出某预测的人类可理解依据。法律 (贷款审批)、医疗、司法、自动驾驶等高风险场景要求模型不可为黑盒。

后门攻击 (Backdoor)

训练阶段植入触发器 (trigger)，使模型在干净样本上表现正常，但遇到带触发器的输入即输出攻击者指定标签；属于训练时供应链威胁，与推理时的对抗攻击区分开。

[EX] 经典例子（课件汇总）

- 对抗图像：狗 → 鸵鸟（视觉几乎不变）。
- Face ID 被对抗眼镜攻破。
- 语音对抗：原始音频 vs 对抗音频，转写结果完全不同。
- 自动驾驶：路标加贴片导致误识别。
- NLP 情感分析：替换近义词翻转情感极性。
- 医疗误诊："正常 → 肺炎"。
- LLM：ChatGPT 输出污染中文互联网。

概念关系

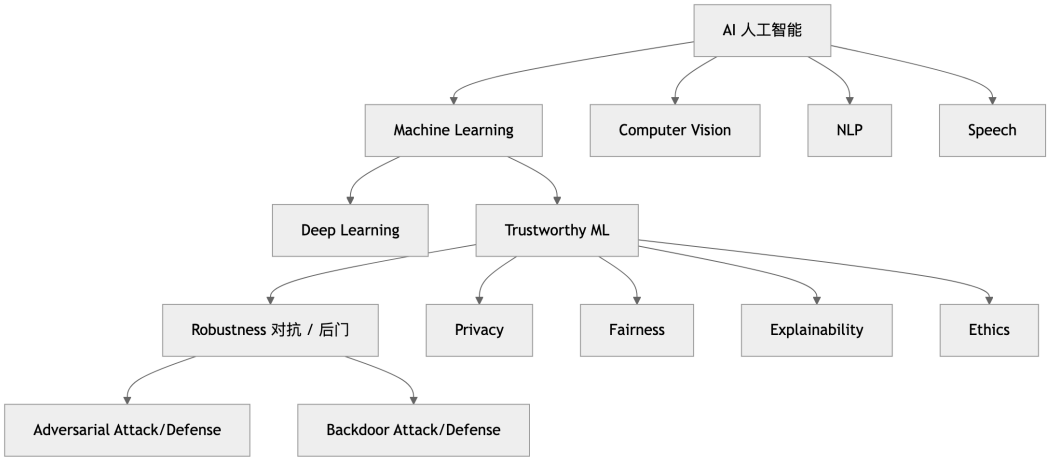

课程模块与作业

本节为课程导言，略（评分：HW1 解释 25% + HW2 隐私 25% + HW3 鲁棒性 25% + HW4 后门 25%；无考试，优秀率不限）。

结论

- Trustworthy ML = 传统 ML（精度 + 效率）+ 鲁棒性 + 隐私 + 公平 + 可解释 + 抗后门。
- 各子问题均可形式化为在式 (1.1) 基础上加约束的优化问题，参见式 (1.2)。
- 鲁棒性的量化模板见式 (1.3)：以 ℓ_p 球内输出一致性概率衡量。

[TIP] 期中复习要点

记住 Trustworthy ML 的五大支柱、AI/ML/DL 三层包含关系、鲁棒性与对抗样本的形式化定义，以及隐私 (Westin) 与公平性的非形式陈述。

记号速查

符号	含义
f_θ	参数为 θ 的模型
$\mathcal{D}$	数据分布
ℓ	损失函数
$\mathcal{B}_\epsilon(x)$	以 x 为中心、半径 ϵ 的 ℓ_p 球
T, P, E	任务、性能度量、经验 (Mitchell 定义)
R, P, F, E	鲁棒性、隐私、公平、可解释性约束

Lecture 2: Introduction of Machine Learning

[TIP] 学习指南

本节核心：以"找函数"视角统一描述监督学习，给出三步范式（模型族 → 损失 → 优化），从线性模型扩展到分段线性 / Sigmoid 神经网络，并讨论模型偏差–过拟合权衡。前置知识：多元微积分（梯度）、矩阵乘法、概率分布与交叉熵。重点关注：ERM 思想、梯度下降迭代式、Sigmoid 表示定理（万能逼近直觉）、过拟合定义与缓解、Softmax + 交叉熵。

核心问题/Motivation

- 机器学习要解决的任务可统一抽象为：从数据中学习一个函数 $f_\theta : \mathcal{X} \to \mathcal{Y}$。回归输出标量，分类输出离散类别。
- 关键三问：模型族如何选？怎样定义"好"？如何在参数空间里搜索最优？
- 训练损失低 ≠ 测试损失低，需要建立泛化视角并在模型复杂度上权衡。

主要内容

定义 2.1（监督学习的三步范式）

给定训练集 $\mathcal{D} = \{(\mathbf{x}_n, \hat{y}_n)\}_{n=1}^N$，监督学习由三步组成：

1. **假设类**：一族带未知参数的函数 $\mathcal{F} = \{f_\theta : \theta \in \Theta\}$。
2. **损失**：度量 θ 优劣的标量函数 $L(\theta) = \frac{1}{N}\sum_{n=1}^N \ell(f_\theta(\mathbf{x}_n), \hat{y}_n)$。
3. **优化**：求 $\theta^* = \arg\min_\theta L(\theta)$，并以 f_{θ^*} 预测测试样本。

定义 2.2（线性模型）

单变量与多变量形式：

$$y = b + wx_1, \qquad y = b + \sum_{j=1}^d w_j x_j \tag{2.1}$$

特征为 x_j，权重 w_j，偏置 b。

定义 2.3（常用损失）

样本误差 e_n 与平均损失 $L = \frac{1}{N}\sum_n e_n$。

- **MSE（均方误差）**：$e = (y - \hat{y})^2$。
- **MAE（平均绝对误差）**：$e = |y - \hat{y}|$。
- **交叉熵**（当 $y, \hat{y}$ 为分布）：$e = -\sum_i \hat{y}_i \ln y_i$。

定义 2.4（梯度下降）

对参数向量 $\theta \in \mathbb{R}^p$，从 $\theta^{(0)}$ 出发迭代：

$$\theta^{(t+1)} \leftarrow \theta^{(t)} - \eta\,\mathbf{g}, \qquad \mathbf{g} = \nabla L(\theta^{(t)}) \tag{2.2}$$

$\eta > 0$ 为学习率（超参数）。单变量退化为 $w^{(t+1)} \leftarrow w^{(t)} - \eta\,\partial L/\partial w$。

收敛性观察：梯度为正则减小 w，为负则增大 w；可能停在局部极小、鞍点或平台区。

定义 2.5（Mini-batch 与 Epoch）

将 $\mathcal{D}$ 划分为 B 个 batch，每个 batch 计算一次梯度并更新一次参数；遍历所有 batch 一次为 1 epoch。第 b 个 batch 的损失记 $L^b(\theta)$，更新规则为 $\theta \leftarrow \theta - \eta \nabla L^b(\theta)$。

定理 2.1（分段线性 → Sigmoid 表示）

任意连续函数可以用足够多片段的分段线性曲线任意精度逼近；而每段"hard sigmoid"可以由 Sigmoid 函数光滑近似：

$$c \cdot \sigma(b + wx_1) = c \cdot \frac{1}{1 + e^{-(b+wx_1)}} \tag{2.3}$$

因此（单输入）模型可写为 Sigmoid 之和：

$$y = b + \sum_i c_i \, \sigma(b_i + w_i x_1) \tag{2.4}$$

直觉：参数 w_i 调坡度、b_i 调平移、c_i 调高度，叠加足够多的 Sigmoid 即可拟合任意连续曲线。

定义 2.6（单隐层神经网络的矩阵形式）

对 d 维输入，隐层 h 个 Sigmoid 单元：

$$\mathbf{r} = \mathbf{b} + W\mathbf{x}, \quad \mathbf{a} = \sigma(\mathbf{r}), \quad y = b + \mathbf{c}^\top \mathbf{a} \tag{2.5}$$

即 $y = b + \sum_{i=1}^{h} c_i \, \sigma\Big(b_i + \sum_{j=1}^{d} w_{ij} x_j\Big)$。全部未知参数堆叠为

$$\theta = [\,\mathrm{vec}(W), \mathbf{b}, \mathbf{c}, b\,]^\top.$$

定义 2.7（过拟合）

若存在模型 f 使训练损失 $L_{\text{train}}(f)$ 远小于测试损失 $L_{\text{test}}(f)$，则称发生过拟合。极端反例：

$$f(\mathbf{x}) = \begin{cases} \hat{y}_i, & \exists\, \mathbf{x}_i = \mathbf{x} \\ \text{random}, & \text{otherwise} \end{cases}$$

训练损失为 0，测试损失却可任意大，说明零训练损失本身不可信。

定理 2.2（Bias–Complexity 权衡）

随模型复杂度（特征数 / 参数数）增加：训练损失单调下降；测试损失先降后升，呈 U 形。最优模型在二者之间。

- 模型受限过多 → 模型偏差大（欠拟合）。
- 模型过于灵活 → 训练贴合噪声 → 过拟合。

缓解过拟合手段：增加训练数据、数据增强、减少特征、减少参数 / 参数共享、正则化、早停（early stopping）、Dropout。

定义 2.8（N 折交叉验证）

将训练集划为 N 等份，每轮取 1 份为验证集、其余为训练集；对每个候选模型计算 N 次验证误差并取均值，选择平均验证误差最小者，用以避免在测试集上选模型造成的信息泄漏。

定义 2.9（Softmax）

将实向量 $\mathbf{y} \in \mathbb{R}^K$ 转为概率向量：

$$y'_i = \frac{\exp(y_i)}{\sum_{j=1}^{K} \exp(y_j)}, \qquad y'_i \in (0,1), \ \sum_i y'_i = 1 \tag{2.6}$$

定义 2.10（分类损失）

标签为 one-hot $\hat{\mathbf{y}}$，模型输出 $\mathbf{y}' = \text{softmax}(\mathbf{y})$。

- MSE：$e = \sum_i (\hat{y}_i - y'_i)^2$。
- **交叉熵**：$e = -\sum_i \hat{y}_i \ln y'_i$。分类任务通常用交叉熵：在 softmax 输出近 0/1 的饱和区，MSE 梯度趋近于 0，而交叉熵保持有效梯度信号。

[EX] 例题（YouTube 观看量预测）

特征 x_1 为前一日观看数，模型 $y = b + wx_1$。在 2017-2020 训练得 $w^* = 0.97$, $b^* = 0.1k$，训练 MAE $L = 0.48k$；用于 2021 年得 $L' = 0.58k$。扩展到 7 天滑窗（$d = 7$）后训练损失降至 $0.38k$、测试损失降至 $0.49k$；进一步增加特征至 28 / 56 天可继续降低，体现"更多特征 → 模型更灵活 → 训练损失下降"。

[EX] 例题（Sigmoid 拟合分段线性）

三段折线 0 → 1 → 2 → 3 可写为常数加三个 hard-sigmoid 之和；用三个 Sigmoid 近似即得 $y = b + \sum_{i=1}^{3} c_i\, \sigma(b_i + w_i x_1)$，3 个 Sigmoid 单元贡献 3 段。

概念关系

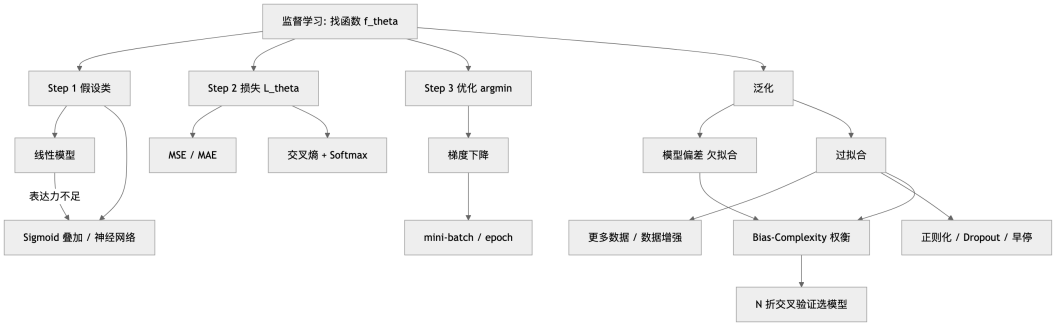

结论

监督学习的本质是在某个假设类内最小化经验损失，借助梯度下降迭代搜索参数。线性模型受限于"模型偏差"，通过叠加 Sigmoid（或更一般的非线性单元）即可逼近任意连续函数，自然引出神经网络。一旦模型足够灵活，训练损失可以任意小，必须用测试 / 验证误差监控泛化；最优复杂度位于偏差与方差的折中点。分类任务以 Softmax 把实数输出映射为概率分布，并用交叉熵作为损失。

[TIP] 期中复习要点

1. 三步范式（假设类 / 损失 / 优化）能否对任意 ML 任务给出形式化描述。
2. 梯度下降的标量与向量更新式，学习率角色，mini-batch / epoch 区分。
3. Sigmoid 叠加表达分段线性曲线的构造，单隐层网络矩阵式 (2.5)。
4. 过拟合的形式定义、极端反例、缓解清单。
5. Bias–Complexity U 形曲线及交叉验证流程。
6. Softmax 公式、为何分类用交叉熵而非 MSE。

记号速查

符号	含义
$\mathbf{x} \in \mathbb{R}^d$	输入特征向量
$\hat{y}, \hat{\mathbf{y}}$	真实标签 / one-hot 标签
f_θ	待学函数（模型）
θ, θ	模型参数（含 $W, \mathbf{b}, \mathbf{c}, b$）
ℓ, e_n	单样本损失
$L(\theta)$	平均损失 / 经验风险
η	学习率
$\mathbf{g} = \nabla L(\theta)$	损失关于参数的梯度
$\sigma(z) = 1/(1 + e^{-z})$	Sigmoid 激活
$W, \mathbf{b}$	隐层权重矩阵 / 偏置
$\mathbf{c}, b$	输出层权重 / 偏置
B	mini-batch 数量
L^b	第 b 个 batch 上的损失
Softmax	$y_i' = \exp(y_i)/\sum_j \exp(y_j)$

Lecture 3: Convolutional Neural Network (CNN)

[TIP] 学习指南

本讲围绕"为什么图像不需要全连接"展开。从两条观察（局部模式、模式平移）推出两条简化（感受野、参数共享），由此得到卷积层；再由"下采样不影响识别"推出池化层。掌握卷积/池化的数学定义、感受野与参数量公式、以及残差连接公式即可。

核心问题/Motivation

输入为 $H \times W \times C$ 的三通道图像（如 $100 \times 100 \times 3$）。若直接展平后接全连接层（如 1000 个神经元），首层参数量约 3×10^7，存在两大问题：参数量爆炸 + 忽略空间结构。CNN 通过两条结构性先验降低模型容量、引入图像偏置：

- **观察 1**：判别性模式（如鸟喙、眼睛）远小于整图，神经元无需看到整张图。
- **观察 2**：相同模式可出现在不同空间位置，应共享检测器参数。
- **观察 3**：对像素做下采样不改变物体语义。

主要内容

定义 3.1（二维离散卷积，单通道）

陈述：给定输入特征图 $x \in \mathbb{R}^{H \times W}$ 与卷积核 $k \in \mathbb{R}^{k_h \times k_w}$（kernel/filter），步长 s、填充 p，则输出特征图

$$y[i,j] \;=\; \sum_{m=0}^{k_h-1} \sum_{n=0}^{k_w-1} x[\,s \cdot i + m - p,\; s \cdot j + n - p\,] \cdot k[m,n] \;+\; b \tag{3.1}$$

注：深度学习里的"卷积"实为**互相关**（无核翻转），但仍约定俗成称作 convolution。

定义 3.2（多通道卷积层）

陈述：输入 $x \in \mathbb{R}^{H \times W \times C_{\text{in}}}$，使用 C_{out} 个 filter，每个 filter $K_\ell \in \mathbb{R}^{k_h \times k_w \times C_{\text{in}}}$，第 ℓ 张输出特征图为

$$y_\ell[i,j] \;=\; \sum_{c=1}^{C_{\text{in}}} \sum_{m,n} x[si + m - p,\; sj + n - p,\; c] \cdot K_\ell[m,n,c] + b_\ell \tag{3.2}$$

每个 filter 在整张图上滑动检测一种小模式（pattern detector），所有空间位置**共享**该 filter 参数。

定义 3.3（输出尺寸公式）

陈述：输入空间维 H，核 k_h，padding p，stride s：

$$H_{\text{out}} \;=\; \left\lfloor \frac{H + 2p - k_h}{s} \right\rfloor + 1 \tag{3.3}$$

宽度同理。常见设置：$k = 3, s = 1, p = 1$（保持尺寸）；$k = 3, s = 2, p = 1$（下采样 2×）。

定义 3.4（感受野 / Receptive Field）

陈述：输出特征图上某个神经元所"看到"的输入图像区域。单层 $k \times k$ 卷积的感受野为 k；堆叠 L 层 $k \times k$、stride 为 s_ℓ 的卷积，第 L 层神经元在原图上的感受野

$$r_L \;=\; r_{L-1} + (k_L - 1)\prod_{\ell=1}^{L-1} s_\ell, \qquad r_0 = 1 \tag{3.4}$$

直观：堆叠两层 $3 \times 3, s = 1$ 卷积，感受野 $= 1 + 2 + 2 = 5$，等价于一层 5×5，但参数更少。

定义 3.5（池化 / Pooling）

陈述：在 $k \times k$ 邻域内做无参数下采样。常用 Max Pooling：

$$y[i, j] \;=\; \max_{0 \le m, n < k} \; x[\, si + m,\; sj + n\,] \tag{3.5}$$

Average Pooling 把 max 换成均值。Pooling 通常 $k = 2, s = 2$，将空间维减半，**无可学习参数**，提供平移不变与尺度压缩。

命题 3.1（卷积层参数量）

陈述：一个卷积层（C_{in} 通道入，C_{out} 个 $k_h \times k_w$ filter，含偏置）的参数量

$$\#\text{params} \;=\; (k_h \cdot k_w \cdot C_{\text{in}} + 1) \cdot C_{\text{out}} \tag{3.6}$$

对比同形状全连接层 $\# = H \cdot W \cdot C_{\text{in}} \cdot H' \cdot W' \cdot C_{\text{out}}$，卷积通过**局部连接 + 权重共享**把参数量从 $O(N^2)$ 降到 $O(k^2 C_{\text{in}} C_{\text{out}})$，与图像分辨率无关。

定义 3.6（卷积层的浮点运算量 FLOPs）

陈述：单层乘加运算数

$$\text{FLOPs} \;=\; H_{\text{out}} \cdot W_{\text{out}} \cdot C_{\text{out}} \cdot (k_h \cdot k_w \cdot C_{\text{in}}) \tag{3.7}$$

定义 3.7（残差连接 / Residual Connection, ResNet）

陈述：堆叠两层卷积 $\mathcal{F}$ 后，加上输入恒等映射：

$$y \;=\; \mathcal{F}(x; \{W_i\}) \;+\; x \tag{3.8}$$

若维度不匹配，用 1×1 卷积投影 W_s：$y = \mathcal{F}(x) + W_s x$。**作用**：让网络学习残差 $\mathcal{F} = H - x$ 而非完整映射 H，缓解深层网络的梯度消失，使 100+ 层可训。

经典架构的数学贡献（去史化）

架构	关键改动
LeNet-5	首个 conv+pool+FC 范式
AlexNet	ReLU + Dropout + GPU 训练
VGG	全部用 3×3 卷积堆叠（两层 $3 \times 3 \approx$ 一层 5×5，参数更少）
ResNet	残差连接 (3.8)，深度 $\to$ 152 层

[EX] 例题 1（输出尺寸 + 参数量）

输入 $32\times32\times3$，conv: $C_{\text{out}}=64, k=3, s=1, p=1$。- 输出尺寸 $H_{\text{out}}=\lfloor(32+2-3)/1\rfloor+1=32$，故输出 $32\times32\times64$。- 参数量 $=(3\cdot3\cdot3+1)\cdot64=28\cdot64=1792$。- FLOPs $=32\cdot32\cdot64\cdot(3\cdot3\cdot3)=1\,769\,472$。

[EX] 例题 2（感受野计算）

三层结构：conv $3\times3, s=1\to$ conv $3\times3, s=2\to$ conv $3\times3, s=1$。$r_0=1$；$r_1=1+(3-1)\cdot1=3$；$r_2=3+(3-1)\cdot1=5$；$r_3=5+(3-1)\cdot2=9$。最终感受野 9×9。

[EX] 例题 3（VGG 替换）

一层 5×5 卷积（同 $C_{\text{in}}=C_{\text{out}}=C$）参数 $25C^2$；改为两层 3×3：$2\cdot9C^2=18C^2$。感受野相同，参数减 28%，多一次非线性。

概念关系

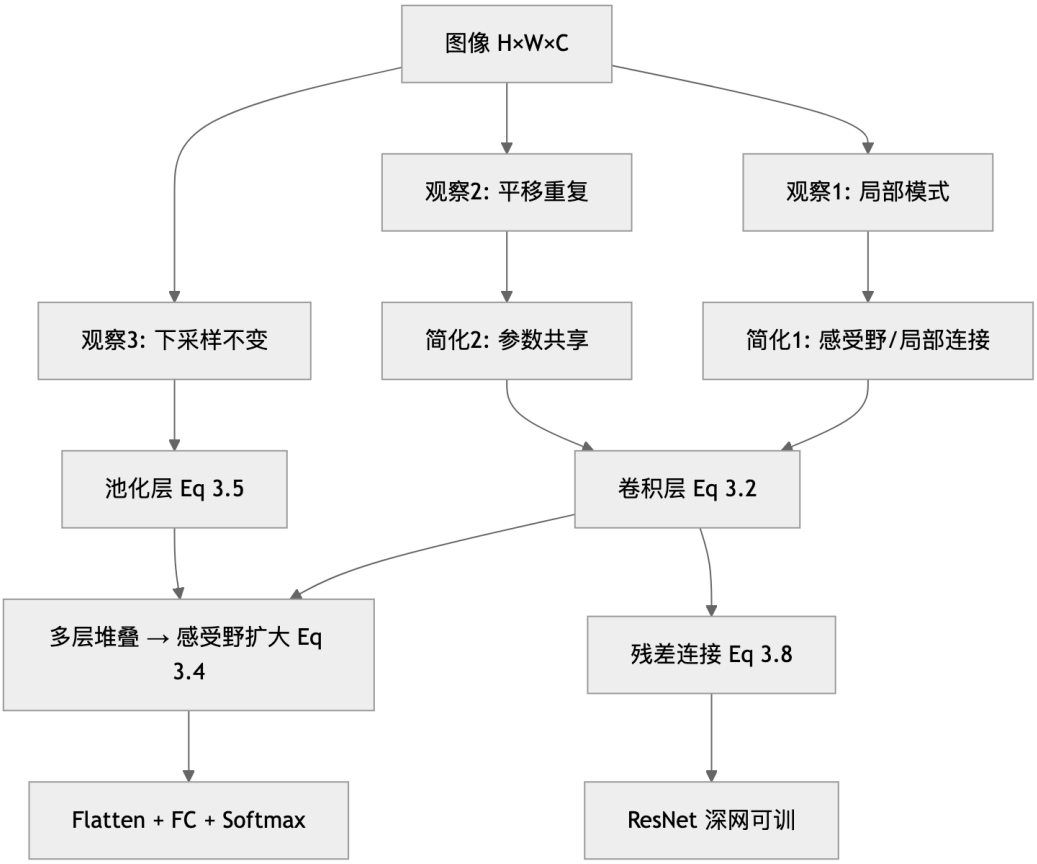

结论

CNN = 在全连接基础上施加两条结构先验：**局部感受野**与**参数共享**，配合**池化**做空间下采样。代价是更强的模型偏置（“image bias”），收益是参数量与 FLOPs 大幅下降，且天然具备平移近似不变性。深层堆叠通过 (3.4) 扩张感受野；残差连接 (3.8) 解决深度训练难题。

[TIP] 期中复习要点

1. 默写卷积输出尺寸公式 (3.3) 与参数量公式 (3.6)。
2. 给定结构计算感受野 (3.4)；理解为何 VGG 用 3×3 堆叠。
3. 残差连接公式 (3.8) 及其动机（梯度消失）。
4. 区分 conv 中的 stride、padding、kernel size 三个超参对输出尺寸的影响。
5. Pooling 无参数；卷积的两条先验对应两条观察。

记号速查

符号	含义
H, W, C	高、宽、通道数
k_h, k_w	卷积核空间维
s	stride（步长）
p	padding（填充）
$C_{\text{in}}, C_{\text{out}}$	输入/输出通道数（filter 个数）
r_L	第 L 层在原图上的感受野边长
$\mathcal{F}(x; \{W_i\})$	残差块的非恒等分支
K_ℓ	第 ℓ 个 filter 张量

Lecture 4: Explanations (XAI)

[TIP] 学习指南

本讲围绕"为什么模型这样预测"展开。两条主线：LIME（局部线性近似）与 Shapley（基于合作博弈的公理化分配）。重点掌握：

- LIME 的目标函数、采样、加权回归与超像素 (super-pixel) 表示
- Shapley 的四条公理及唯一性定理的证明思路
- Shapley 用于分类的公式 (4.5) 与 Monte-Carlo 近似
- 两类方法的对比、优缺点与典型反例（Husky vs Wolf）

核心问题/Motivation

给定训练集 $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$，$x_i \in \mathbb{R}^p$，已学得模型 f，对单个实例 $\vec{x} \in \mathbb{R}^p$，需为 $f(\vec{x})$ 给出**人类可理解的解释**。动因：

- 法律合规：贷款、司法决策需可追溯
- 安全：医疗、自动驾驶失败时需归因
- 调试：定位虚假相关（spurious correlation），如 husky/wolf 误判源于雪地背景
- 科学：从黑盒中提取可信知识

主要内容

定义 4.1（分类法）

按解释器获取模型的方式：

- **Model-specific**：依赖模型内部结构。如线性模型中权重 w_j 直接表示特征重要性 $\partial f/\partial x_j = w_j$；决策树用路径与基尼下降。
- **Model-agnostic**：只通过输入–输出查询黑盒，不假设结构。LIME 与 Shapley 均属此类。

按粒度：

- **Global**：刻画 f 在整体输入域的行为
- **Local**：仅解释 $f(\vec{x})$ 在 $\vec{x}$ 邻域的行为（LIME / Shapley 均为局部）

按时机：

- **Intrinsic**（自带可解释性，线性、浅树、GAM）
- **Post-hoc**（事后解释，LIME / Shapley / SHAP / Grad-CAM）

方法 4.1 LIME

Local Interpretable Model-Agnostic Explanations：在 $\vec{x}$ 附近用一个简单可解释模型 $g \in \mathcal{G}$（如稀疏线性、浅树）局部逼近 f。

形式化目标：

$$\xi(\vec{x}) = \arg\min_{g \in \mathcal{G}} \mathcal{L}\big(f, g, \pi_{\vec{x}}\big) + \lambda\, \Omega(g) \tag{4.1}$$

其中 $\pi_{\vec{x}}(z)$ 是邻近度核，$\Omega(g)$ 度量复杂度（如非零权数）。

算法步骤：

1. **扰动采样**：生成 m 个邻近样本 $\mathcal{Z} = \{z_i\}_{i=1}^m$。表格特征下，对每维 j 独立采 $z_{ij} \sim \mathcal{N}(\mu_j, \sigma_j^2)$，$\mu_j, \sigma_j^2$ 取自训练集 $\mathcal{D}$ 的边际统计。
2. **黑盒标注**：用 $f(z_i)$ 作为代理标签。
3. **加权**：以核

$$w_i = \exp\left(-\frac{\|z_i - \vec{x}\|_2^2}{\sigma_{\text{kernel}}^2}\right) \tag{4.2}$$

赋权（距离越近权越大）。

4. **加权回归**：在 $\mathcal{G}$ 上求

$$\arg\min_{g \in \mathcal{G}} \frac{1}{m} \sum_{i=1}^{m} w_i \, L\big(f(z_i), g(z_i)\big) + \lambda \, \Omega(g) \tag{4.3}$$

若 $\mathcal{G}$ 为带稀疏先验的线性族，则 (4.3) 化为加权 Lasso：

$$\arg\min_{\vec{\beta} \in \mathbb{R}^p} \frac{1}{m} \sum_{i=1}^{m} w_i \big(f(z_i) - \langle \vec{\beta}, z_i \rangle\big)^2 + \lambda \, \|\vec{\beta}\|_1$$

通过调 λ 控制非零特征数（用户指定）。

图像超像素 (super-pixel) 表示：原始像素维度过高且不可解释；先用 SLIC/Quick-Shift 把图像分成 K 个语义连通块（super-pixels）。可解释表示

$$z' \in \{0, 1\}^K$$

含义：第 k 块是否保留（取消则用均值灰或 0 填充）。在 z' 空间随机置零得 $\mathcal{Z}$，逆映回原图喂给 f，再用 (4.3) 学线性权 β_k，权重大的块即解释。

Husky vs Wolf 案例：

- 训练集中 wolf 多带雪地背景
- 分类器在测试图（husky 站雪地）输出 wolf
- 用 LIME 解释发现高权重 super-pixel 落在雪而非动物本体
- 结论：模型学到了"雪 □wolf"的虚假相关；LIME 揭示模型缺陷而非数据点是否难

优缺点：

- 优：模型无关、人类友好、文本/图像有专用变体
- 缺：邻域核宽 σ_{kernel} 与 Ω 影响大；同点不同采样下解释**不稳定**

方法 4.2 Shapley

来自合作博弈：项目 Proj $= \langle P, v \rangle$，$P = \{1, \dots, p\}$，价值函数 $v : 2^P \to \mathbb{R}, v(\varnothing) = 0$。例：3 玩家编码 500 行项目 $v(\{1\}) = 100, v(\{2\}) = 125, v(\{3\}) = 50, v(\{1,2\}) = 270, v(\{2,3\}) = 350, v(\{1,3\}) = 375, v(\{1,2,3\}) = 500$。如何把 500 公平分给三人？

四条公理：

- **Efficiency（效率）**：$\sum_{i=1}^{p} \phi_i(v) = v(P)$，全部产值被分完。
- **Symmetry（对称）**：若 $\forall S \subseteq P \setminus \{i, j\}, v(S \cup \{i\}) = v(S \cup \{j\})$，则 $\phi_i(v) = \phi_j(v)$。

- **Linearity（线性）**：对任意两博弈 v, w 与实数 a，$\phi_i(av + w) = a\phi_i(v) + \phi_i(w)$。
- **Null player（零元）**：若 $\forall S \not\ni i, v(S \cup \{i\}) = v(S)$，则 $\phi_i(v) = 0$。

唯一性定理：满足以上四条的分配唯一，且为

$$\phi_j(v) = \sum_{S \subseteq P \setminus \{j\}} \frac{|S|!\,(p - |S| - 1)!}{p!} \big(v(S \cup \{j\}) - v(S)\big) \tag{4.4}$$

唯一性证明（详细）：

*第一步：构造"承载博弈"基底。*对每个非空 $T \subseteq P$，定义承载博弈

$$u_T(S) = \begin{cases} 1, & T \subseteq S \\ 0, & \text{otherwise} \end{cases}$$

共 $2^p - 1$ 个。任意博弈 v 在 $\{u_T\}$ 下有唯一展开

$$v = \sum_{T \neq \emptyset} c_T\, u_T, \qquad c_T = \sum_{R \subseteq T} (-1)^{|T| - |R|} v(R)$$

（Möbius 反演）。

*第二步：在 u_T 上确定 ϕ。*对 au_T（$a \in \mathbb{R}$）：

- 若 $i \notin T$，则 i 是零元（向任何 S 加入 i 不改变 $u_T(S)$），由 Null 公理 $\phi_i(au_T) = 0$。
- 若 $i, j \in T$，则 i, j 在 au_T 中可互换，由 Symmetry 公理 $\phi_i(au_T) = \phi_j(au_T)$。
- 由 Efficiency，$\sum_{i \in T} \phi_i(au_T) = au_T(P) = a$，结合对称性得

$$\phi_i(au_T) = \begin{cases} a/|T|, & i \in T \\ 0, & i \notin T \end{cases}$$

第三步：用 Linearity 推广到任意 v。

$$\phi_i(v) = \sum_{T \ni i} \frac{c_T}{|T|}$$

代入 c_T 的 Möbius 表达并整理（按 $S = T \setminus \{i\}$ 重新求和），即得 (4.4)。证毕。

(4.4) 中 $v(S \cup \{j\}) - v(S)$ 是玩家 j 加入联盟 S 的边际贡献；权 $\frac{|S|!(p-|S|-1)!}{p!}$ 是在均匀随机排列下，j 之前正好为 S 中元素的概率。故 ϕ_j 是 j 的边际贡献在所有排列上的平均。

复杂度：精确 (4.4) 需对 2^{p-1} 个子集求和，对每个还需调一次 v（即 f），整体 $O(2^p \cdot c_f)$，特征数稍大即不可承受。

方法 4.3 Shapley 用于分类

类比映射：

- 博弈 ≡ 一次预测
- 玩家 ≡ 特征
- 联盟 ≡ 已观测的特征子集
- 总价值 ≡ $f(\vec{x}) - \mathbb{E}[f(X)]$（与平均预测之差）
- 分配 ≡ 特征重要性

形式化：定义部分预测期望

$$\psi(f,\vec{x},S)=\mathbb{E}\big[f(X)\mid X_k=x_k,\ k\in S\big]$$

特征 j 对 $f(\vec{x})$ 的 Shapley 值：

$$\varphi(j,f,\vec{x})=\sum_{S\subseteq\{1,\dots,p\}\setminus\{j\}}\frac{|S|!\,(p-|S|-1)!}{p!}\big(\psi(f,\vec{x},S\cup\{j\})-\psi(f,\vec{x},S)\big) \tag{4.5}$$

由 Efficiency 立即有

$$\sum_{j=1}^{p}\varphi(j,f,\vec{x})=f(\vec{x})-\mathbb{E}[f(X)] \tag{4.6}$$

即所有特征的归因恰好把"该次预测偏离均值"分完。

Monte-Carlo 近似：直接枚举 2^{p-1} 子集不可行，按"随机排列"视角无偏估计：

1. 重复 M 次：
   - 抽一随机排列 π 与一参考样本 $\vec{z}\sim\mathcal{D}$
   - 记 $S_\pi^{<j}$ 为 π 中 j 之前的位置集合
   - 构造 $\vec{x}_{+j}$：在 $S_\pi^{<j}\cup\{j\}$ 位置取 $\vec{x}$ 的值，其余取 $\vec{z}$
   - 构造 $\vec{x}_{-j}$：仅在 $S_\pi^{<j}$ 位置取 $\vec{x}$，其余（含 j）取 $\vec{z}$
   - 记录 $\Delta_m=f(\vec{x}_{+j})-f(\vec{x}_{-j})$
2. 取平均 $\hat{\varphi}(j)=\frac{1}{M}\sum_m\Delta_m$

复杂度 $O(M\cdot p\cdot c_f)$，M 通常几百到几千；p 较大时仍可行。

像素归因示例：MNIST 图像由 8 错分为 3。

- (a) 输入图
- (b)(c) 红色像素 = 该像素增大目标类概率，蓝色 = 减小
- (d) 把红色像素掩去后，预测从 8 翻转为 3，验证归因方向正确

[EX] Shapley 手算 3 玩家

$v(\{1\})=100, v(\{2\})=125, v(\{3\})=50$；$v(\{1,2\})=270, v(\{2,3\})=350, v(\{1,3\})=375$；$v(\{1,2,3\})=500$，$v(\varnothing)=0$。$p=3$，权重 $|S|!(p-|S|-1)!/p!$：$|S|=0$：$1/3$；$|S|=1$：$1/6$；$|S|=2$：$1/3$。

计算 ϕ_1，遍历 $S\subseteq\{2,3\}$：

- $S=\varnothing$：边际 $v(\{1\})-0=100$，权 $1/3$，贡献 $100/3$
- $S=\{2\}$：边际 $270-125=145$，权 $1/6$，贡献 $145/6$
- $S=\{3\}$：边际 $375-50=325$，权 $1/6$，贡献 $325/6$
- $S=\{2,3\}$：边际 $500-350=150$，权 $1/3$，贡献 $150/3$

合计 $\phi_1=\frac{200+145+325+300}{6}=\frac{970}{6}\approx 161.67$。同理可得 $\phi_2\approx 158.33$, $\phi_3\approx 180$（向上取整后三者和 $=500=v(P)$，验证 Efficiency 公理）。

[WARN] 易错点

- LIME 的 σ_{kernel} 太大 $\to$ 退化为全局线性回归；太小 $\to$ 几乎所有 $w_i\approx 0$，回归病态。
- LIME 的可解释表示 z' 与原始 z 不同：$z'\in\{0,1\}^K$，z 是反映回的实际输入。

- Shapley 公式中权 $\frac{|S|!(p-|S|-1)!}{p!}$ 的两次阶乘分别对应 S 内排列与 j 后元素排列；常被错记成 $\binom{p-1}{|S|}^{-1}$（数值上 $= \frac{|S|!(p-|S|-1)!}{(p-1)!}$，差一个 $1/p$）。
- 条件期望 $\mathbb{E}[f(X) \mid X_S = x_S]$ 严格需联合分布；实践用 marginal（独立采样）替代会引入偏差，但仍是 KernelSHAP/Monte-Carlo 的常见做法。
- Shapley 不保证"稀疏"解释；想要少特征仍需后处理或换 LIME。

概念关系

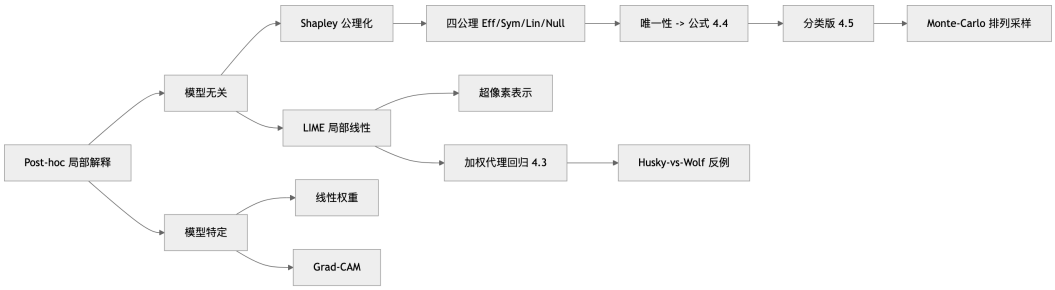

对比表（LIME vs Shapley vs 同类方法）：

维度	LIME	Shapley/SHAP	Saliency/Grad	Anchors
模型访问	黑盒	黑盒	需梯度	黑盒
理论保证	局部拟合	四公理	一阶近似	高精度规则
复杂度	$O(m \cdot c_f)$	精确 $O(2^p)$ / MC $O(Mp)$	$O(c_f)$	搜索式
稳定性	低（采样依赖）	高	噪声敏感	中
输出形式	稀疏权	完整归因和	热力图	if-then

结论

[TIP] 期中复习要点

- LIME 三要素：邻域 $\pi_{\vec{x}}$、加权 (4.2)、稀疏代理 (4.3)；图像版需 super-pixel 二元化。
- Shapley 四公理 + 唯一性定理 + 公式 (4.4)；分类版本 (4.5) 与 Efficiency 推论 (4.6)。
- 复杂度：精确 $O(2^p)$，Monte-Carlo $O(Mp)$。
- 优劣对比：LIME 直观快但不稳定；Shapley 理论坚实但贵。
- Husky/Wolf：解释暴露虚假相关，体现解释的"调试"价值。

记号速查

符号	含义
f	黑盒模型
$\vec{x} \in \mathbb{R}^p$	待解释实例

符号	含义
$\mathcal{G}$	可解释模型族（线性/树等）
$\mathcal{Z}, z_i$	LIME 扰动样本集 / 单个扰动样本
$z' \in \{0,1\}^K$	图像 super-pixel 二元表示
$\pi_{\vec{x}}, w_i$	邻近核 / 样本权重 (4.2)
$\Omega(g), \lambda$	复杂度正则 / 强度
P, p	玩家集 / 玩家数（= 特征数）
$S \subseteq P$	联盟（特征子集）
$v(S)$	联盟价值（合作博弈）
$\phi_i(v)$	玩家 i 的 Shapley 值
u_T	承载博弈基底（证明用）
$\psi(f, \vec{x}, S)$	部分预测期望 $\mathbb{E}[f(X) \mid X_S = x_S]$
$\varphi(j, f, \vec{x})$	特征 j 对 $f(\vec{x})$ 的 Shapley 归因 (4.5)
M	Monte-Carlo 采样次数

Lecture 5: Saliency Maps and CAM

[TIP] 学习指南

本讲从"模型自身可作解释器"的视角切入，讲两条主线：基于反向传播的 Saliency（Vanilla Gradient → SmoothGrad）与基于前向激活的 CAM（→ Grad-CAM）。重点掌握三个推导：(1) 为何梯度能反映像素重要度（Taylor 一阶展开）；(2) CAM 公式 $S_c = \sum_{x,y} M_c(x,y)$ 全过程；(3) Grad-CAM 中权重 α_k^c 的来源。Pokémon-vs-Digimon 案例展示 saliency 暴露捷径学习的实用价值。

核心问题/Motivation

LIME、SHAP 属于"模型无关"（model-agnostic）的事后解释，需要在输入邻域反复采样并拟合代理模型，**计算昂贵**。本讲转向"模型特定"（model-specific）思路：**直接利用网络自身的梯度或激活**，在一次或少数前/反向传播内输出像素级重要度图（saliency map），从而回答：

- 哪个像素 / 区域对模型决策 $f_c(x)$ 最关键?
- 高准确率背后，模型是否学到了正确的视觉特征，还是利用了 spurious shortcut?

主要内容

方法 5.1 Vanilla Gradient

思想：以"扰动 Δx_i 引起决策值的变化 Δe"度量第 i 个分量的重要性，但逐像素扰动需 $O(d)$ 次前向传播，太贵。改用一阶 Taylor 展开。

推导。设类别 c 的输出 $f_c : \mathbb{R}^d \to \mathbb{R}$，在样本点 x_0 处展开：

$$f_c(x_0 + \Delta x) \approx f_c(x_0) + \nabla_x f_c(x_0)^\top \Delta x + O(\|\Delta x\|^2) \tag{5.1}$$

仅扰动第 i 个分量 $\Delta x = \Delta x_i e_i$：

$$\Delta e \;=\; f_c(x_0 + \Delta x_i e_i) - f_c(x_0) \;\approx\; \left.\frac{\partial f_c}{\partial x_i}\right|_{x_0} \Delta x_i \tag{5.2}$$

故"单位扰动的影响"由偏导数模长刻画，定义 saliency：

$$S_i(x_0) \;=\; \left|\frac{\partial f_c(x)}{\partial x_i}\right|_{x=x_0} \tag{5.3}$$

实现：一次反向传播得到 $\nabla_x f_c$，对 RGB 三通道取绝对值后取最大或求和得到 2D 热力图。

局限：

- 梯度噪声大（ReLU 不连续、saturation 区域梯度饱和）；
- 仅在 x_0 局部线性化，对剧烈非线性区域不可信；
- 视觉上呈"椒盐"散点，难以人类阅读。

方法 5.2 SmoothGrad

思想：原始梯度 ∇f_c 在输入空间高频抖动；在 x 周围加高斯噪声后**平均梯度**，等价于对决策面做平滑核卷积，可消除高频噪声。

公式：

$$\hat{S}(x) \;=\; \frac{1}{N}\sum_{n=1}^{N}|\nabla_x f_c(x+\eta_n)|, \qquad \eta_n \sim \mathcal{N}(0,\sigma^2 I) \tag{5.4}$$

为什么减噪：把原始 saliency 视作随机变量 $S(x+\eta)$，蒙特卡洛平均按 $1/\sqrt{N}$ 缩小其方差；同时，平滑后的目标函数 $\tilde{f}_c(x) = \mathbb{E}_\eta[f_c(x+\eta)]$ 满足 $\nabla\tilde{f}_c(x) = \mathbb{E}_\eta[\nabla f_c(x+\eta)]$（高斯卷积与求导可交换），等价于在更光滑曲面上取梯度。

超参数：

- σ：噪声幅度。常以 $\sigma/(x_{\max}-x_{\min})$ 形式给出，典型 0.10–0.20。σ 太小退化为 vanilla；太大破坏语义。
- N：采样数。常 25–50 张；增大 N 减方差但线性增加计算。

直观例子：瞪羚（Gazelle）图像，vanilla saliency 在背景处零碎激活，SmoothGrad 集中到目标轮廓。

方法 5.3 CAM (Class Activation Map)

CAM 不依赖梯度，**只用前向激活 + 最后一层全连接权重**得到定位图。

前置约定（缺一不可）：

- **倒数第二层**：Global Average Pooling (GAP)；
- **最后一层**：单个 Linear（即 softmax 前的全连接）；
- 偏置项忽略（设为 0）；
- 经典网络：ResNet、GoogLeNet。VGG / AlexNet 含 fc-fc 结构，需改造（GAP 替换 fc）才能用 CAM。

记号：$f_k(x,y)$ 表示最后一个卷积层中第 k 个 channel 在空间位置 (x,y) 的激活；GAP 后得 F_k；w_k^c 为类别 c 对应单元 k 的权重。

完整推导。GAP 定义：

$$F_k \;=\; \sum_{x,y} f_k(x,y) \tag{5.5}$$

类别 c 进入 softmax 的得分（忽略偏置）：

$$S_c \;=\; \sum_k w_k^c F_k \;=\; \sum_k w_k^c \sum_{x,y} f_k(x,y) \;=\; \sum_{x,y} \underbrace{\sum_k w_k^c f_k(x,y)}_{M_c(x,y)} \tag{5.6}$$

交换求和顺序合法，因为求和有限。由此**定义** Class Activation Map：

$$M_c(x,y) \;=\; \sum_k w_k^c f_k(x,y), \qquad S_c = \sum_{x,y} M_c(x,y) \tag{5.7}$$

经验解释：$M_c(x,y)$ 表示空间位置 (x,y) 对类别 c 得分的直接贡献；上采样到原图大小（双线性插值）即可叠加显示。

应用：弱监督定位——仅用图像级标签训练，CAM 在未见过 bounding box 的情况下可定位 dome / palace 等物体的不同部分。

局限：网络架构受限（必须 GAP+Linear），改造已有模型代价高。

方法 5.4 Grad-CAM（CAM 的自然推广）

动机：去掉对 GAP+Linear 的结构限制，使任意末端（多层 fc、分支结构、文本/检测网络）都能获得类似 CAM 的图。

推导 α_k^c 的来源。在 CAM 中，权重 w_k^c 直接从最后线性层读取；但在通用网络里这一权重不再存在。改问：**第 k 个特征图整体对 S_c 的影响系数是多少？**取偏导：

$$\alpha_k^c = \frac{1}{Z}\sum_{x,y}\frac{\partial S_c}{\partial f_k(x,y)}, \qquad Z = \sum_{x,y} 1 \tag{5.8}$$

即"对空间位置做全局平均池化的梯度"。在 CAM 的特殊情形下 $S_c = \sum_{x,y,k} w_k^c f_k(x,y)$ 直接给出 $\partial S_c/\partial f_k(x,y) = w_k^c$，对 (x,y) 平均仍得 w_k^c，因此 $\alpha_k^c = w_k^c$，**Grad-CAM 严格还原 CAM**。

Grad-CAM 输出（加 ReLU 只保留正贡献）：

$$L^c_{\text{Grad-CAM}}(x,y) = \text{ReLU}\Big(\sum_k \alpha_k^c f_k(x,y)\Big) \tag{5.9}$$

推广性：可放在任意卷积层后，且不要求 GAP；只要能反传到该层即可。这就是把 CAM 从"结构特定"提升为"层不可知"的关键。

方法对比表

方法	信号来源	网络结构要求	计算量	噪声	备注
Vanilla Gradient	$\nabla_x f_c$	任意可微	1 次 BP	高	Taylor 一阶
SmoothGrad	N 次扰动梯度均值	任意可微	N 次 BP	低	超参 σ, N
CAM	末层激活 f_k + 权重 w_k^c	GAP+Linear	1 次 FP	中	弱监督定位
Grad-CAM	任意层激活 + 梯度 α_k^c	任意	1 次 FP+BP	中	推广 CAM

[EX] Pokémon vs Digimon 案例

任务：二分类 Pokémon（宝可梦）/ Digimon（数码宝贝）卡通形象。
结果：Training Acc 98.9%，Testing Acc 98.4%——看似完美。
Saliency 揭露：用 vanilla gradient 可视化，重要像素**几乎全在背景**而不在角色身上。
根因：Pokémon 数据集是 PNG（透明背景，加载后变黑色），Digimon 多为 JPEG（白色背景）。模型实际学到"背景颜色 → 类别"的捷径（shortcut / spurious correlation），而非角色形态特征。
教训：高 acc 不等于学到正确特征；saliency 是发现数据偏置与捷径学习的低成本工具。修复方式：统一格式 / 随机背景增强 / 抠图后再训练。

[WARN] 易错点

- Vanilla saliency 视觉散乱**不是 bug**，是高频梯度的真实反映；想清晰先看 SmoothGrad 或 Grad-CAM。
- SmoothGrad 的 σ 是相对输入动态范围的相对值，不是绝对像素值。
- CAM 必须 **GAP + 单层 Linear**；用 fc-fc 网络套 CAM 公式会得到错误结果。
- CAM 推导中"忽略偏置"是简化假设，源论文实测影响极小。
- Grad-CAM 的 α_k^c 是**先对空间位置求平均，再加权 channel**，顺序不能颠倒。

- 高 acc + 错误 saliency 的组合 = 捷径学习，需立刻怀疑数据。

概念关系

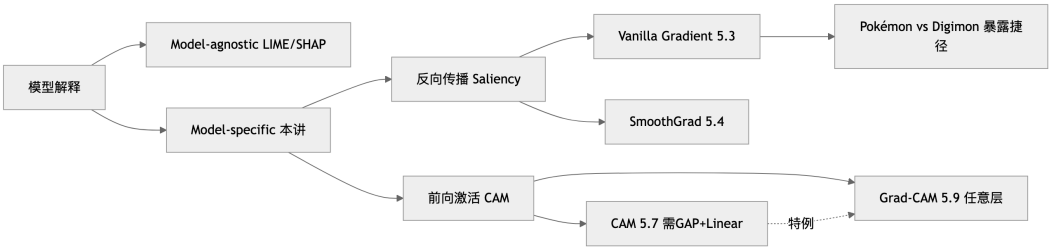

结论

- **Saliency 系列**：用一阶 Taylor 把"重要性"等价于偏导数；SmoothGrad 用噪声平均换取低方差。
- **CAM 系列**：把分类得分 S_c 沿空间维拆解，得到逐像素贡献图；Grad-CAM 用梯度平均替代线性层权重，去除结构约束。
- **诊断价值**：Pokémon-vs-Digimon 显示 saliency 是暴露 shortcut learning 的关键工具。

[TIP] 期中复习要点

- 必背公式：(5.3) Vanilla、(5.4) SmoothGrad、(5.7) CAM、(5.8)(5.9) Grad-CAM。
- 必会推导：从 (5.1) Taylor 到 (5.3)；从 GAP (5.5) + 线性层到 (5.6) → (5.7)；CAM 是 Grad-CAM 在 GAP+Linear 下的特例。
- 必答陷阱：Pokémon-vs-Digimon 的根因（PNG/JPEG 背景）。
- CAM 与 Grad-CAM 的核心差异：是否需要 GAP+Linear。

记号速查

记号	含义
$f_c(x)$	类别 c 的输出 logit
$S_i(x)$	第 i 像素 saliency
$\eta_n \sim \mathcal{N}(0, \sigma^2 I)$	SmoothGrad 噪声
N	SmoothGrad 采样数
$f_k(x, y)$	末卷积层 channel k 在 (x, y) 激活
$F_k = \sum_{x,y} f_k(x, y)$	GAP 输出
w_k^c	末线性层权重（CAM 用）
S_c	类别 c 的 softmax 输入
$M_c(x, y)$	CAM
α_k^c	Grad-CAM 中 channel k 的权重
$L_{\text{Grad-CAM}}^c$	Grad-CAM 输出图
Z	特征图空间位置数（归一化常数）

Lecture 6: Adversarial Attacks（对抗攻击）

[TIP] 学习指南

- 本讲想解决的问题：当我们已经能用 CAM（Lec 5）解释模型"看哪里"之后，自然要追问——如果**故意**改一点点输入，能不能让模型看错？
- 读完后能做的事：写出 FGSM/BIM/PGD/MI-FGSM/DeepFool/C&W 的公式与算法；区分白盒/黑盒/物理三类威胁模型；解释 transferability 与 gradient masking 的来龙去脉。
- 与上下讲关系：上一讲 CAM 提供"为什么模型这么判"，本讲提供"如何让模型判错"；下一讲 Lec 7 讲对抗防御，是本讲的对偶。

6.0 为什么要研究对抗攻击

6.0.1 安全场景动机

对抗攻击不是学术玩具，而是**已经在每个 ML 落地领域出现过的安全风险**：

- **自动驾驶**：在 STOP 标志上贴几条黑白胶带（RP², Eykholt CVPR 2018），分类器在多角度多距离下持续误判为 "Speed Limit 45"。
- **人脸识别**：戴上一副印花眼镜（Sharif CCS 2016），可冒充任意目标身份通过门禁。
- **医疗影像**：在皮肤镜图像上叠加 $\epsilon = 2/255$ 的扰动，分类器把恶性黑色素瘤判成良性痣，且病人和医生肉眼无法察觉。
- **NLP**：替换一两个同义词（TextFooler），情感分类器从 negative 翻成 positive。
- **LLM**：构造特定后缀（GCG, Zou 2023），让对齐良好的 ChatGPT 输出有害内容（jailbreak）。

这些案例的共同点是：扰动**幅度极小**（图像 $\ell_\infty \le 8/255$ 即 3% 的像素动态范围），但模型的**输出标签可以被任意操控**。这种"输入小扰动 → 输出大跳变"的脆弱性需要被理论解释、被算法刻画、被工程防御。

6.0.2 Linearity Hypothesis（Goodfellow 2014）

为什么 DNN 这么脆？最早的直觉解释是**线性假设**。考察一阶 Taylor 展开：

$$f(x+\delta) \approx f(x) + \nabla_x f(x)^\top \delta. \tag{6.0a}$$

在 ℓ_∞ 约束 $\|\delta\|_\infty \le \epsilon$ 下，$\nabla_x f(x)^\top \delta$ 的最大值为 $\epsilon \|\nabla_x f(x)\|_1$。设输入维度 d 很大（ImageNet $d \approx 150{,}000$），梯度每维平均量级 $\bar{g}$，则扰动可使 logit 漂移约 $\epsilon \cdot d \cdot \bar{g}$。**$\epsilon$ 哪怕只有 0.007，乘以 d 后也足以撬动 softmax 决策**。结论：DNN 的脆弱性主要不来自"高度非线性"，恰恰来自**局部太线性**——这条直觉直接孕育了 FGSM。

6.0.3 攻击与训练的对偶

把训练损失最小化（最小化 over θ）和对抗样本最大化（最大化 over x'）放在一起，得到对偶视角：

$$\underbrace{\min_\theta \mathbb{E}_{(x,y)\sim\mathcal{D}}\big[L(f_\theta(x), y)\big]}_{\text{标准训练}} \quad \text{vs.} \quad \underbrace{\max_{\|x'-x\|_p \le \epsilon} L(f_\theta(x'), y)}_{\text{对抗攻击}}. \tag{6.0b}$$

把两者嵌套就是 Lec 7 要讲的 **对抗训练 (Min-Max)**：$\min_\theta \mathbb{E}\big[\max_{x'} L(f_\theta(x'), y)\big]$。所以本讲（攻击）和下一讲（防御）是同一优化问题的两面。

6.1 形式化定义

6.1.1 对抗样本定义

给定模型 f_θ、干净样本 (x_0, y)、损失 L、扰动预算 ϵ、范数 $\|\cdot\|_p$，**对抗样本**是满足约束的扰动样本：

$$x^* = \arg\max_{x'} \; L(f_\theta(x'), y), \quad \text{s.t. } \|x' - x_0\|_p \le \epsilon, \; x' \in [0,1]^d. \tag{6.1}$$

像素盒约束 $x' \in [0,1]^d$ 保证它仍是合法图像（不是负值或超饱和）。

6.1.2 威胁模型三维

刻画一次攻击需要回答三个问题：

1. **攻击者知道什么？**——白盒（拥有架构 + 权重 + 梯度）/ 灰盒（只有架构）/ 黑盒（只能查询 API）。白盒最强但最不现实，黑盒最现实但最弱。
2. **攻击的目标是什么？**——Untargeted：使 $f(x^*) \neq y$（任意错类）；Targeted：使 $f(x^*) = y_t$（指定目标类，目标函数改为 $\min L(f(x'), y_t)$）。Targeted 严格更难。
3. **扰动如何度量？**——ℓ_p 范数。

6.1.3 ℓ_∞ vs ℓ_2 vs ℓ_0 的语义对比

三种范数对应**三种不同的"小扰动"哲学**：

- ℓ_∞：每个像素最多改 ϵ，**改多少像素不限**。最常用，因为它直接对应"逐像素肉眼可见性"，且与 8-bit 量化天然兼容（$\epsilon = 8/255 \approx 3\%$）。
- ℓ_2：扰动总能量 $\sqrt{\sum \delta_i^2} \le \epsilon$。允许某些像素动得更多，只要总能量小。DeepFool / C&W 默认范数。几何上对应"球"，可微，便于优化。
- ℓ_0：**改动像素个数** $\le \epsilon$，幅度不限。对应"贴一小撮像素的对抗"，例如 one-pixel attack。不可微，需组合优化。

经验：$\epsilon_\infty = 8/255$ 与 $\epsilon_2 = 0.5$ 在 CIFAR-10 上大致同强度，但**不能混报**——任何论文都必须明确范数与预算。

6.2 一阶白盒：FGSM

直觉。Goodfellow 2014 的洞察是：既然 DNN 局部接近线性（式 6.0a），那么"如何在 ℓ_∞ 球内最快增加损失"就是一个**线性规划**——目标线性，约束是无穷范数球。这种线性规划有闭式解，根本不需要迭代：每个坐标独立地朝梯度符号方向走到 ϵ 即可。这就是 FGSM 的全部思想。它是一**步**到位的方法，速度极快，常作为 baseline 与防御训练时的内层 attacker。

威胁模型：白盒，untargeted（也有 targeted 版），ℓ_∞，单步。

形式化。

$$x^{adv} = x_0 + \epsilon \cdot \operatorname{sign}\big(\nabla_x L(f_\theta(x_0), y)\big). \tag{6.2}$$

Targeted 版（要 push 到 y_t）：$x^{adv} = x_0 - \epsilon \cdot \operatorname{sign}(\nabla_x L(f_\theta(x_0), y_t))$。

推导。在 x_0 处对 $L(\cdot, y)$ 做一阶 Taylor 展开：$L(x_0 + \delta, y) \approx L(x_0, y) + g^\top \delta$，其中 $g = \nabla_x L$。我们要最大化增量 $g^\top \delta$，约束 $\|\delta\|_\infty \le \epsilon$：

$$\max_{\|\delta\|_\infty \le \epsilon} g^\top \delta \;=\; \sum_i \max_{|\delta_i| \le \epsilon} g_i \delta_i \;=\; \sum_i \epsilon |g_i| = \epsilon \|g\|_1.$$

每个坐标独立达到最优当 $\delta_i = \epsilon \cdot \operatorname{sign}(g_i)$。代入即得式 (6.2)。这里 **sign 之所以是 ℓ_∞ 球的最优方向**，是因为线性目标在超立方体上的极值必在顶点取到。

何时失败 / 复杂度。一次前向 + 一次反向，复杂度 $O(1)$。**失败模式**：当损失曲面强非线性（Taylor 一阶严重偏离实际）或 ϵ 较大时，单步走过头反而错过损失峰，攻击成功率低。这正是 BIM/PGD 出现的原因。

6.3 多步白盒：BIM / I-FGSM

直觉。FGSM 的弱点很清楚：一阶 Taylor 近似只在小邻域成立，ϵ 一大就不准。一个最自然的修补是——把 ϵ 拆成 T 小步，每走一步都重新算梯度。这样每步只在很小邻域内做 Taylor 近似，累计起来比单步 FGSM 更接近真实最大化。这就是 Kurakin 2016 的 **Iterative FGSM (I-FGSM, 也叫 BIM, Basic Iterative Method)**。

威胁模型：白盒，untargeted，ℓ_∞，多步（典型 $T = 10$）。

形式化。

$$x_{t+1} = \mathrm{Clip}_{x_0,\epsilon}\Big(x_t + \alpha \cdot \mathrm{sign}\big(\nabla_x L(f_\theta(x_t), y)\big)\Big), \tag{6.3}$$

其中 $\mathrm{Clip}_{x_0,\epsilon}(z) = \min(\max(z, x_0 - \epsilon), x_0 + \epsilon)$ 再裁到 $[0, 1]$，步长典型 $\alpha = \epsilon/T$。

算法。

1. 初始化 $x_0^{adv} = x_0$。
2. For $t = 0, 1, \ldots, T-1$：计算 $g_t = \nabla_x L(f_\theta(x_t^{adv}), y)$。
3. 更新 $x_{t+1}^{adv} = \mathrm{Clip}_{x_0,\epsilon}(x_t^{adv} + \alpha \cdot \mathrm{sign}(g_t))$。
4. 返回 x_T^{adv}。

何时失败 / 复杂度。$O(T)$ 次梯度，比 FGSM 慢但显著更强。**失败模式**：起点固定为 x_0，容易卡进局部极大值（特别是损失面有多个尖峰时），无法找到全局最优扰动。这就是 PGD 引入 random restart 的原因。

6.4 PGD（含 random restart）

直觉。BIM 一旦初始化在 x_0，整条轨迹是确定的；如果损失面有多个局部极大值，BIM 只会到最近的一个。Madry 2017 的 **Projected Gradient Descent (PGD)** 在 BIM 之上做两件事：(1) 用**随机均匀初始化** $x_0 + \mathrm{Uniform}(-\epsilon, \epsilon)$ 打散起点；(2) 跑 K 次独立 restart 取最强结果。Madry 把 PGD 称为"first-order universal adversary"——用一阶信息能找到的最强攻击。

威胁模型：白盒，untargeted/targeted，ℓ_∞（也有 ℓ_2 版），多步多 restart。

形式化。每次 restart：

$$x_0^{adv} = x_0 + \mathrm{Uniform}(-\epsilon, \epsilon), \quad x_{t+1}^{adv} = \Pi_{\mathcal{B}_\epsilon(x_0)}\Big(x_t^{adv} + \alpha \cdot \mathrm{sign}(\nabla_x L)\Big), \tag{6.4}$$

$\Pi_{\mathcal{B}_\epsilon(x_0)}$ 是到 ℓ_∞ 球 $\{x : \|x - x_0\|_\infty \le \epsilon\}$ 的投影（即逐元素 clip）。ℓ_2 版用归一化梯度 $\nabla L/\|\nabla L\|_2$ 替换 sign，投影改为缩放。

算法（带 random restart）。

1. For $k = 1, \ldots, K$（restart 循环）：
2. 　采样 $x_0^{(k)} = x_0 + \mathrm{Uniform}(-\epsilon, \epsilon)$。
3. 　For $t = 0, \ldots, T-1$：$x_{t+1}^{(k)} = \Pi_{\mathcal{B}_\epsilon(x_0)}(x_t^{(k)} + \alpha \cdot \mathrm{sign}(\nabla_x L))$。
4. 　记录该 restart 的最终 loss L_k。
5. 返回 $\arg\max_k L_k$ 对应的 $x_T^{(k)}$。

何时失败 / 复杂度。$O(KT)$ 次梯度。CIFAR-10 经典配置：$\epsilon = 8/255$, $\alpha = 2/255$, $T = 10 \sim 20$, $K = 1 \sim 10$。评估时常用 PGD-50 / PGD-100 / PGD-1000。**失败模式**：当模型存在 **gradient masking / obfuscated gradients** 时（梯度被防御机制人为弄成 0 或随机），PGD 看似失效但鲁棒性其实是假的；此时要换 BPDA（Backward Pass Differentiable Approximation）或 EOT（详见本章末警示）。

6.5 MI-FGSM（动量）

直觉。前面 FGSM/BIM/PGD 都是白盒攻击——它们假设你能看到目标模型的梯度。但现实中目标模型常常被藏在云端，攻击者只能在**自己的源模型** f_s 上做 FGSM 然后期望它**迁移**到目标模型 f_t。问题是：源模型上的对抗轨迹会**过拟合**源模型的损失面（每步走的是源模型的局部尖峰方向），跳到目标模型后未必还是上升方向。Dong 2018 的 **MI-FGSM (Momentum Iterative FGSM)** 借鉴 SGD 动量的思想：用指数滑动平均把历史梯度累加起来，平均掉源模型特有的噪声方向，留下"在多个步骤中持续上升"的稳定方向，这种方向更可能在目标模型上也是上升的。

威胁模型：白盒生成 + 黑盒迁移（即在源模型 f_s 上跑、攻击目标 f_t），untargeted，ℓ_∞。

形式化。维护动量 g_t，每步累加 ℓ_1 归一化梯度：

$$g_{t+1} = \mu \cdot g_t + \frac{\nabla_x L(f_\theta(x_t), y)}{\|\nabla_x L(f_\theta(x_t), y)\|_1}, \quad x_{t+1} = \mathrm{Clip}_{x_0,\epsilon}\big(x_t + \alpha \cdot \mathrm{sign}(g_{t+1})\big). \tag{6.5}$$

典型 $\mu = 1.0$，$\alpha = \epsilon/T$。

推导/直觉补全。ℓ_1 归一化是因为不同步的梯度幅值差异极大（损失面陡峭区与平坦区），不归一化会让大幅梯度主导，破坏动量平滑效果。最后用 $\mathrm{sign}(g_{t+1})$ 而不是 g_{t+1} 本身，是为了保持 ℓ_∞ 球的最优方向性质。**Nesterov 版 (NI-FGSM, Lin ICLR 2020)** 把"先看一步再算梯度"加进来：在 $x_t + \alpha\mu g_t$ 处求梯度，类似 SGD 的 Nesterov look-ahead。

何时失败 / 复杂度。$O(T)$，与 BIM 同阶。**关键参数**：μ 太小退化为 BIM，太大轨迹不收敛。**失败模式**：动量加速了"找到源模型尖峰"，但若源模型与目标模型架构差异极大（CNN vs ViT），迁移性仍有限，需配合 DI/TI/SI（见 6.8）。

6.6 DeepFool（线性近似最小扰动）

直觉。前面 FGSM/PGD 都是固定 ϵ 求最大 loss，是"把预算花光"型攻击。但有时我们想问反过来的问题：**让模型刚刚好误分类，需要的最小扰动是多少？**这是评估鲁棒半径的核心指标。Moosavi-Dezfooli 2016 的 **DeepFool** 给出了一个迭代的几何答案：把分类器在 x_t 处线性化为一组超平面（每个类对一个），算到最近超平面的距离，沿垂直方向推过去，再迭代直到误分类。

威胁模型：白盒，untargeted，ℓ_2（默认；也有 ℓ_∞ 版），多步。

形式化。二分类时（决策面 $f(x) = 0$），点到超平面 $\{x' : f(x) + \nabla f^\top(x' - x) = 0\}$ 的最小 ℓ_2 扰动为

$$\delta^* = -\frac{f(x)}{\|\nabla f(x)\|_2^2} \nabla f(x). \tag{6.6}$$

多分类时，对每个错类 $k \neq y$ 定义 $w_k = \nabla(f_k - f_y), b_k = f_k - f_y$；选最近的边界

$$\hat{l} = \arg\min_{k \neq y} \frac{|b_k|}{\|w_k\|_2}, \quad \delta_t = \frac{|b_{\hat{l}}|}{\|w_{\hat{l}}\|_2^2} w_{\hat{l}}.$$

算法。

1. 初始化 $x_0^{adv} = x_0$，累积扰动 $r = 0$。
2. While $\arg\max_k f_k(x_t^{adv}) = y$：
3. 　对每个 $k \neq y$，算 w_k, b_k，找最近边界 $\hat{l}$。
4. 　$\delta_t = \frac{|b_{\hat{l}}|}{\|w_{\hat{l}}\|_2^2} w_{\hat{l}}$；$x_{t+1}^{adv} = x_t^{adv} + \delta_t$。
5. 返回累积扰动 $r = x_t^{adv} - x_0$。

推导。式 (6.6) 来自经典几何：点 x 到超平面 $\{z : a^\top z = c\}$ 的最近点为 $x - \frac{a^\top x - c}{\|a\|_2^2} a$。把 $a = \nabla f(x), c = a^\top x - f(x)$（一阶展开）代入即得。

何时失败 / 复杂度。通常 2-3 次迭代收敛，比 PGD 快。**失败模式**：(1) 决策面曲率大时线性近似差，需更多迭代；(2) DeepFool 给出的是**几何最小**扰动，但可能集中在边缘等高显著性像素，**视觉显著性高**，所以它常用于评估鲁棒半径而非生成隐蔽攻击。

6.7 C&W（带 box 约束的最优化）

直觉。FGSM/PGD 用 sign 牺牲了梯度幅值信息；DeepFool 假设线性，曲面弯就不准。Carlini & Wagner 2017 想做"最强白盒攻击"——不近似、不投影，直接把"找最小扰动且使模型错分"当成一个完整的连续优化问题，让 Adam 跑到底。它有两个关键工程技巧：(1) 用 tanh 重参数化把 box 约束 $[0,1]^d$ 消掉，无需投影；(2) 用 logit 而非 softmax 定义 surrogate loss，避免 softmax 饱和导致梯度消失。它至今是 ℓ_2 范数下最强的白盒攻击之一，常作"金标准"用来 stress-test 防御。

威胁模型：白盒，targeted/untargeted，ℓ_2（主版本，也有 ℓ_0/ℓ_∞），优化型。

形式化（targeted 到 t）。

$$\min_w \ \|x' - x_0\|_2^2 + c \cdot f(x'), \quad x' = \tfrac{1}{2}(\tanh(w) + 1), \tag{6.7}$$

其中 surrogate loss

$$f(x') = \max\Big(\max_{i \neq t} Z_i(x') - Z_t(x'),\ -\kappa\Big).$$

Z 是 logits，$\kappa \geq 0$ 是 confidence margin（要求目标类比次高类至少高 κ）。

推导/算法。

1. **tanh 重参数**：令 $w \in \mathbb{R}^d$ 自由，$x' = \frac{1}{2}(\tanh(w) + 1) \in [0,1]^d$ 自动满足 box 约束。
2. **Surrogate f 的设计**：当目标类 logit Z_t 已是最大时 $f \leq 0$，再继续优化只会让 $\|x' - x_0\|_2$ 减小（推近原图）；用 $-\kappa$ 截断防止过度自信。
3. **内层 Adam**：固定 c 跑 $T = 10^4$ 步。
4. **外层 binary search on c**：c 太小则 $\|x' - x_0\|_2$ 主导、攻击失败；c 太大则 surrogate 主导、扰动过大。从 $c = 10^{-3}$ 起，能成功就减小（追小扰动），失败就乘 10（追成功率），二分 5-9 轮。

何时失败 / 复杂度。$O(c_{\text{steps}} \cdot T) \approx 5 \times 10^4$ 次梯度，**极慢**，通常用于评估而不用于训练。**失败模式**：(1) 防御若做 gradient masking，f 的梯度被搅乱；(2) ℓ_∞ 版收敛差，ℓ_∞ 默选仍是 PGD。

6.8 迁移增强：DI / TI / SI / SGM

直觉。MI-FGSM 解决了"梯度方向噪声"，但还有另一类问题：源模型在某些**输入特性**上过拟合（比如对中心位置敏感、对特定纹理敏感、对单一尺度敏感）。如果让源模型在每步看的是**经过随机变换的输入**或**一组多样化的输入**，那它给出的梯度就被迫平均掉这些过拟合方向，剩下的就是"对各种变换都能持续攻击"的鲁棒方向，迁移性自然更强。这就是 DI / TI / SI 的统一思想——**输入多样性 = 平均化梯度 = 提升迁移**。SGM 则从另一个角度切入：在 ResNet 反传时强化 skip-connection 的梯度。

四个"插件"可叠在 MI-FGSM 之上（M-DI-TI-SI-FGSM 是 NeurIPS 2018-2020 的强 baseline）：

- **DI-FGSM (Diverse Input, Xie 2019)**：每步以概率 p 对 x_t 做随机 resize+pad 变换 $\mathcal{T}$，再喂模型：$\nabla_x L(f_\theta(\mathcal{T}(x_t; p)), y)$。直觉：让源模型每步看不同视图，避免梯度过度依赖中心物体的精确像素位置。
- **TI-FGSM (Translation-Invariant, Dong 2019)**：用预定义高斯核 W 卷积梯度图：$g_{t+1} = W * \nabla_x L$。等价于对一组平移版本求平均梯度（因为 CNN 的平移性允许把"对平移图求梯度"换成"对原图求平移梯度"）。直觉：绕过依赖局部纹理位置的防御。
- **SI-FGSM (Scale-Invariant, Lin ICLR 2020)**：对输入做尺度集合 $\{x/2^i\}_{i=0}^{m-1}$ 求平均梯度：$\nabla_x \frac{1}{m} \sum_{i=0}^{m-1} L(f(x/2^i), y)$。利用 DNN 对尺度的近似不变性做"集成"，无需多个模型。

- **SGM (Skip Gradient Method, Wu ICLR 2020)**：在 ResNet 反传时给 skip-connection 的梯度乘衰减因子 $\gamma < 1$（典型 $\gamma = 0.5$）。直觉：residual block 的非线性是 source-model-specific 的，skip 路径携带的信息更"通用"，强化 skip 通道使梯度更具迁移性。

6.9 黑盒攻击全景

到此白盒章节结束。问题来到黑盒：**攻击者只有 API**——输入图像，得到 top-1 类（hard label）或带概率的 top-k（score）。我们无法直接拿梯度。这一节展示三条路线如何应对。

6.9.1 Transfer-based

最简单的黑盒思路：**自己训一个源模型 f_s，在 f_s 上跑白盒攻击（如 MI-DI-TI-SI），希望对抗样本迁移到目标 f_t**。优点：零 query。缺点：迁移成功率 50-90%，**很难 100%**；对抗训练过的目标模型迁移成功率显著下降。

6.9.2 Score-based 估梯：NES / SPSA / ZOO

直觉。如果 API 返回 softmax 概率（"score"），那么对每个候选输入，我们能算 loss——只是不能反传。但**有 loss 就能用有限差分估梯度**，这是数值优化的标准做法。问题是图像维度 $d \approx 10^5$，逐坐标差分（ZOO 那样）需要 $2d$ 次 query 才得一次梯度估计，慢到不可行。NES 和 SPSA 用**随机方向采样**降低 query 数。

威胁模型：黑盒，score-based，untargeted/targeted，ℓ_∞。

ZOO (Chen 2017)。坐标级有限差分：$\hat{g}_i = (f(x + he_i) - f(x - he_i))/(2h)$，每像素 2 次 query。配合坐标分组、Adam 与重要性采样加速。

NES (Ilyas ICML 2018) 的高斯采样估梯推导。考察平滑函数 $\tilde{L}(x) = \mathbb{E}_{\delta\sim\mathcal{N}(0,\sigma^2 I)}[L(x+\delta)]$。Stein lemma / score function trick 给出

$$\nabla_x \tilde{L}(x) = \mathbb{E}_{\delta\sim\mathcal{N}(0,\sigma^2 I)}\big[L(x+\delta)\,\nabla_x \log p(\delta)\big] = \frac{1}{\sigma^2}\,\mathbb{E}_\delta\big[L(x+\delta)\,\delta\big],$$

因为 $\nabla_x \log \mathcal{N}(\delta; 0, \sigma^2 I) = \delta/\sigma^2$（这里 δ 与 x 相对位移）。蒙特卡洛逼近，并用 antithetic sampling（对称采样 $\pm\delta_k$）减方差：

$$\hat{g} \approx \frac{1}{2n\sigma}\sum_{k=1}^{n} \delta_k \left(L(x+\sigma\delta_k) - L(x-\sigma\delta_k)\right), \quad \delta_k \sim \mathcal{N}(0, I). \tag{6.8}$$

每次估梯耗 $2n$ 次 query（典型 $n = 50$），把 $\hat{g}$ 喂给 PGD 做更新。

SPSA (Simultaneous Perturbation Stochastic Approx., Spall 1992)。用 Rademacher 噪声 $\Delta_k \in \{-1, +1\}^d$ 代替 Gaussian：

$$\hat{g} \approx \frac{1}{n}\sum_{k=1}^{n} \frac{L(x+c\Delta_k) - L(x-c\Delta_k)}{2c}\,\Delta_k.$$

也是 $2n$ 次 query。SPSA 对 gradient masking 防御（如 thermometer encoding）特别鲁棒，是检测假鲁棒的标准工具。

6.9.3 Decision-based：Boundary Attack

直觉。最严苛的黑盒是 **API 只返回 top-1 类**（无概率）。此时连 loss 都没有，估梯度也无从谈起。Brendel ICLR 2018 的 **Boundary Attack** 反向操作：**先找一个明显的对抗样本**（例如一张随机图，必然不是真类），再让它**沿决策边界向 x_0 逼近**。每步在边界附近做小步随机游走 + 朝 x_0 收缩，只要还满足"被分错"就接受，否则回退。最终得到一个"勉强还在错类一侧、距 x_0 最近"的对抗样本。

威胁模型：黑盒，hard-label，untargeted/targeted。零梯度调用。

何时失败 / 复杂度：query 数 $\approx 10^5$ 起步，比 score-based 慢一个数量级，但对最严苛的 API 也能用。

6.9.4 Random search：Square Attack

直觉。Andriushchenko ECCV 2020 发现：与其费劲估梯度，不如在 ℓ_∞ 球内做**结构化随机搜索**——每步在随机位置贴一个边长 h 的正方形 patch，patch 值取 $\pm\epsilon$；若 loss 上升则保留，否则丢弃。零梯度估计，query 效率比 NES 高 5-20 倍。这说明很多防御的"鲁棒性"对随机方向就脆弱。

6.9.5 Query 复杂度对比表

方法	假设	每步 query	总 query (典型)
Transfer	有源模型	0	0
ZOO	score	$2d$	$> 10^6$
NES	score	$2n \approx 100$	10^4-10^5
SPSA	score	$2n \approx 100$	10^4
Square	score	1	10^3-10^4
Boundary	hard label	1-2	10^5

6.10 通用扰动 UAP（Moosavi-Dezfooli 2017）

直觉。前面所有攻击都是 **per-sample**——对每张图分别求扰动。**Universal Adversarial Perturbation (UAP)** 问一个更深的问题：能否找到**一个单独的固定扰动 v，加在数据集中绝大多数图上都能让模型错分**？如果存在，意味着 DNN 的决策边界中存在一个"对所有自然图都有效的公共病态方向"——这是模型脆弱性比 per-sample 攻击更深刻的证据。

威胁模型：白盒（用 DeepFool 子程序），untargeted，ℓ_p，**与样本无关**。

形式化。

$$\Pr_{x\sim\mathcal{D}}\big[f(x+v)\neq f(x)\big]\geq 1-\xi,\quad \|v\|_p\leq\epsilon. \tag{6.9}$$

算法（贪心累加）。

1. 初始化 $v \leftarrow 0$。
2. While 当前 fool rate $< 1-\xi$：
3. 　For 每个 x in 训练样本子集：
4. 　　If $f(x+v)=f(x)$（还没攻破 x）：
5. 　　$\Delta v \leftarrow \mathrm{DeepFool}(x+v, f)$（找最小扰动让它越界）。
6. 　　$v \leftarrow \Pi_\epsilon(v+\Delta v)$（投影回 ϵ 球内）。
7. 返回 v。

何时失败 / 复杂度。需要数千张训练样本调用 DeepFool。**失败模式**：模型集成 + 数据增广 / 对抗训练后，UAP 效果显著下降——这恰好支持"UAP 利用的是非鲁棒共性特征"的解释。

6.11 物理世界攻击

数字攻击假设你能直接修改像素值。**物理攻击**则要把对抗扰动**打印出来贴在物体上**，让相机拍到时仍是对抗的。难度陡升：相机视角、距离、光照、打印色域、JPEG 压缩……都会破坏精心设计的数字扰动。物理攻击的核心方法论是 **Expectation Over Transformation (EOT)**——优化时**对一组物理变换求期望**，使扰动对每种变换都鲁棒。

6.11.1 Adversarial Patch (Brown 2017)

直觉。如果 ϵ 太小、物理变换破坏太严重，那干脆**放弃 ϵ 约束**——允许扰动任意鲜艳，但限定它只占图像一个**小区域**（像贴纸）。这种 patch 可以印出来贴在任何物体上，让分类器恒定输出目标类。

形式化。EOT 目标：

$$\hat{p} = \arg\max_{p} \mathbb{E}_{x\sim X,\, t\sim T,\, \ell\sim L}\big[\log P(y_t \mid A(p, x, \ell, t))\big], \tag{6.10}$$

$A(p, x, \ell, t)$ 把 patch p 经位置 ℓ、变换 t（缩放、旋转、亮度、噪声）贴到背景 x 上。期望对**多种背景**和**多种变换**求平均，确保 patch 在物理世界各种条件下都有效。

6.11.2 RP² (Robust Physical Perturbations, Eykholt CVPR 2018)

直觉。Adversarial Patch 太显眼。RP² 想做**贴纸式攻击**：扰动只允许出现在少数细长贴纸的形状内（用掩码 M_x 限定），并要求扰动颜色在打印机色域内可复现（NPS, Non-Printability Score）。

形式化：

$$\arg\min_{\delta} \lambda\|M_x \cdot \delta\|_p + \mathrm{NPS}(\delta) + \mathbb{E}_{x_i\sim X^V}\big[J(f_\theta(x_i + T_i(M_x \cdot \delta)), y_t)\big]. \tag{6.11}$$

三项分别为：扰动幅度正则、打印色域损失、对多视角图像 $\{x_i\}$ 求期望的对抗损失。**实验**：在 STOP 标志贴几条黑白贴纸，自动驾驶模型在 80%+ 多角度多距离照片中误判为“Speed Limit 45”。

6.11.3 Adversarial Camouflage (Duan CVPR 2020)

进一步把对抗扰动伪装成自然纹理（锈迹、涂鸦）：在式 (6.11) 上加风格迁移损失，让 perturbation 视觉上像合理的环境磨损，**既鲁棒又隐蔽**。

6.12 可迁移性与对抗子空间

为什么白盒攻击的扰动也常常能骗黑盒模型？这就是 **transferability**，是黑盒攻击的实证基础。三个互补的解释：

1. **决策边界对齐**。在自然数据流形附近，独立训练的不同 DNN（不同架构、不同初始化、不同数据子集）会学到相似的判别方向——因为可分性主要由**数据分布**决定，模型只是去逼近它。这意味着源模型和目标模型在 x_0 附近的决策边界几乎平行，“把 x_0 推过源边界”的方向多半也能”推过目标边界”。
2. **公共非鲁棒特征**（Ilyas 2019, “Adversarial Examples are Features Not Bugs”）。对抗扰动并非随机噪声，而是**有意义的高频/纹理特征**，这些特征虽然与人类感知不一致，但被多个模型共同依赖。改动这些特征会同时影响源和目标。
3. **对抗子空间维度**（Tramèr 2017）。在某点处能愚弄模型的扰动方向不是孤立的，而是占据一个维度高达 $50 \sim 100$ 的**线性子空间**；不同模型的对抗子空间显著重叠，重叠区就是 transfer 成功的方向。

提升迁移性的实战策略：(a) 加噪/平滑梯度（MI/NI 动量）；(b) 输入多样化（DI 变换、TI 平移核、SI 尺度集成）；(c) 模型集成 ensemble（在 K 个源模型 logits 加权和上做 PGD）；(d) 架构层面（SGM 强化 skip 路径）。**经验**：迁移成功率 50-90%，达 100% 需 query。

[EX] FGSM/PGD 像素级手算

设 3 维输入 $x_0 = (0.4, 0.6, 0.5)^\top$，3 类 logit 由线性模型 $Z(x) = Wx$ 给出，

$$W = \begin{pmatrix} 1 & -1 & 0 \\ 0 & 2 & 1 \\ -1 & 1 & 1 \end{pmatrix}, \quad \text{真类} y = 1.$$

当前 logits $Z(x_0) = (0.4 - 0.6 + 0,\ 0 + 1.2 + 0.5,\ -0.4 + 0.6 + 0.5) = (-0.2,\ 1.7,\ 0.7)$。模型预测类 1，与真类一致；untargeted 目标是让它从类 1 跳走。

FGSM 单步（$\epsilon = 0.1$，cross-entropy loss $L = -Z_y + \log \sum_k e^{Z_k}$，对线性模型 $\nabla_x L = -W_y + \sum_k p_k W_k$，其中 p_k 是 softmax 概率）：

- softmax: $e^Z = (0.819, 5.474, 2.014)$，sum $= 8.307$，$p = (0.099, 0.659, 0.242)$。
- $W_0 = (1, -1, 0)$, $W_1 = (0, 2, 1)$, $W_2 = (-1, 1, 1)$（行向量）。
- $\sum_k p_k W_k = 0.099(1, -1, 0) + 0.659(0, 2, 1) + 0.242(-1, 1, 1) = (-0.143,\ 1.461,\ 0.901)$。
- $\nabla_x L = -(0, 2, 1) + (-0.143, 1.461, 0.901) = (-0.143,\ -0.539,\ -0.099)$。
- $\text{sign}(\nabla_x L) = (-1, -1, -1)$。
- $x^{adv} = x_0 + 0.1 \cdot (-1, -1, -1) = (0.3,\ 0.5,\ 0.4)$。

验证：新 $Z = (0.3 - 0.5 + 0,\ 1.0 + 0.4,\ -0.3 + 0.5 + 0.4) = (-0.2,\ 1.4,\ 0.6)$。$Z_1$ 从 1.7 降到 1.4，$Z_1 - Z_2$ 从 1.0 降到 0.8——loss 上升，攻击有效。

PGD-2 两步（$\alpha = 0.05$，$\epsilon = 0.1$，无 random restart）：

- 第 1 步：在 x_0 处梯度 sign $= (-1, -1, -1)$；$x_1 = x_0 + 0.05 \cdot (-1, -1, -1) = (0.35, 0.55, 0.45)$。
- 第 2 步：在 x_1 重算 $Z = (-0.2, 1.55, 0.65)$，softmax/sign 计算相似，sign 仍 $(-1, -1, -1)$；$x_2 = (0.30, 0.50, 0.40)$。

两步 PGD 终点恰好等于一步 FGSM 终点——这是因为 sign 方向稳定。**关键观察**：sign 把每个像素独立推到 ℓ_∞ 球的角点；当 sign 在迭代中不翻转时 PGD 退化到 FGSM；当 sign 翻转（曲面非线性强）时，PGD 比 FGSM 强，因为它在中途修正了方向。

[WARN] Gradient Masking 警示

如果某个防御让 $\nabla_x L \approx 0$（手段：non-differentiable 操作如离散化、随机化输入、shattered gradients、梯度爆炸），PGD 会"看似失败"——但**鲁棒性是假的**，因为攻击者可以绕过梯度路径。诊断流程：

- **黑盒 transfer 检查**：用一个独立训练的源模型生成对抗样本，喂给被防御模型。如果防御只是把自己的梯度藏起来，transfer 攻击仍然有效。
- **SPSA 检查**：用 SPSA 估梯度（不依赖反向传播），看 PGD 是否仍失败。
- **BPDA (Backward Pass Differentiable Approximation)**：把 non-differentiable 的防御层替换成 identity 或可微近似做反传。
- **EOT**：若防御做随机化，攻击应对随机化的 EOT 期望优化。

Athalye ICML 2018 用上述工具一次性打破 9 篇 ICLR 防御论文中的 7 篇，证明它们的鲁棒性都是 gradient masking 假象。**这正是 Lec 7 对抗训练 (Madry) 出现的动机**——只有对抗训练给出的鲁棒性能扛住 BPDA + EOT + transfer 的全方位评估。

概念关系

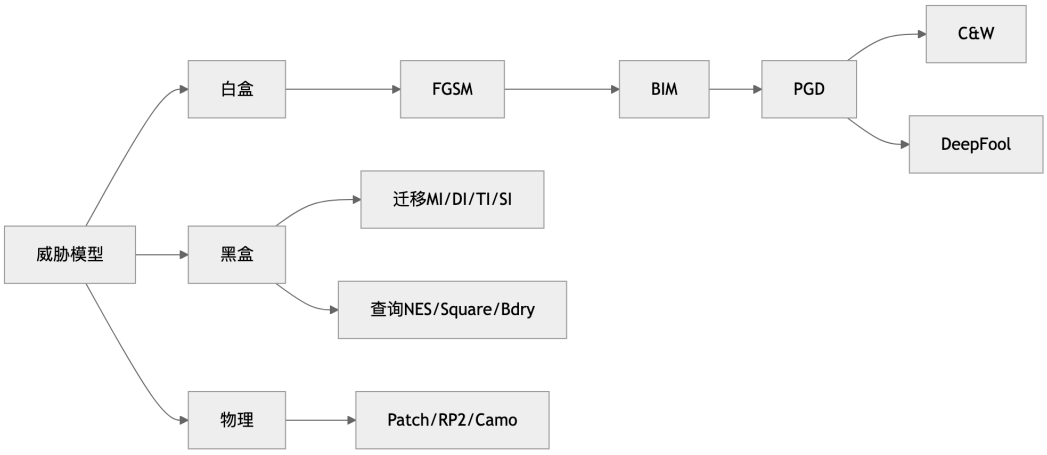

结论

[TIP] 期中复习要点

- 默写式 (6.2)–(6.7)，写清范数、约束、是否投影、targeted/untargeted 的符号差异。
- PGD 三个超参：步长 α、步数 T、restart 数 K；C&W 双层：内 Adam、外 binary search on c。
- 区分 score-based vs decision-based 黑盒攻击，能写出 NES 估梯式 (6.8)。
- 知道 MI/DI/TI/SI 各自做了什么变换，分别解决了什么过拟合。
- 解释 gradient masking 为什么是假鲁棒，能列举至少 2 种检测手段。
- 物理攻击的 EOT 期望项的作用，写出 RP² 的三项损失。
- Universal 算法 6 行循环写得出。
- 解释 transferability 的三个原因：决策边界对齐、公共非鲁棒特征、对抗子空间。

记号速查

记号	含义
x_0, y	干净样本与真标签
y_t	目标类（targeted）
x', x^{adv}	对抗样本
δ	扰动 $x' - x_0$
ϵ	扰动预算
$\lVert \cdot \rVert_p$	p-范数（默认 ℓ_∞）
α	PGD/BIM 步长
T	迭代步数
K	random restart 次数
$\Pi_{\mathcal{B}}$	投影到 ϵ-球
$\mathrm{Clip}_{x_0,\epsilon}$	逐元素裁到 $[x_0 - \epsilon, x_0 + \epsilon] \cap [0, 1]$
$Z_i(x)$	logit（softmax 之前）

记号	含义
μ	MI-FGSM 动量系数
σ, n	NES 高斯标准差与采样数
κ	C&W confidence margin
c	C&W 损失权衡系数
M_x	物理攻击的扰动掩码
EOT	Expectation Over Transformation
NPS	Non-Printability Score
UAP	Universal Adversarial Perturbation

Lecture 7: Adversarial Defense（对抗防御）

[TIP] 学习指南

本讲核心：从 Madry 的 min-max 鞍点目标出发，沿一条主干演化出 **PGD-AT → TRADES → MART → AWP**；以及一条平行线索回答"如何识别假鲁棒"——即 gradient masking 反模式与 AutoAttack 评估。读完本章你应能独立解释三件事：(1) PGD-AT 为什么 work、它的内层 max 解到什么程度才够；(2) TRADES 与 MART 各自补的是 PGD-AT 的哪一块短板（前者补"clean acc 掉太多"，后者补"misclassified 样本被忽略"）；(3) AWP 在权重空间做什么，以及为什么这件事和 robust generalization 挂钩。所有公式默认在 ℓ_∞ 球 $\|x' - x\|_\infty \le \epsilon$ 下叙述（CIFAR-10 标配 $\epsilon = 8/255$）。

7.0 为什么需要对抗训练

上一讲我们看到：对任意一个标准训练的分类器，只要在输入 x 周围一个肉眼不可见的 ϵ-球 $\mathcal{B}_\epsilon(x)$ 内搜索，几乎总能找到一个被错分的对抗样本 x'；典型案例是把"狗"以 82% 置信度推到"鸵鸟"98% 置信度。问题在于：**标准训练只优化干净样本上的损失**

$$\min_\theta \ \mathbb{E}_{(x,y)\sim\mathcal{D}} L(f_\theta(x), y),$$

它对 $\mathcal{B}_\epsilon(x)$ 内的最坏点没有任何约束。对抗防御的目标因此自然写成"最坏情形损失"——这就是后面 (7.1) 的来源。

防御范式速览（本讲只展开第一类）：

- **经验防御**（Empirical defense）：以对抗训练 (Adversarial Training, AT) 为代表，在训练循环中显式引入对抗样本。**没有形式保证，但实测效果最强**，是工业界事实标准。
- **认证防御**（Certified defense）：以 randomized smoothing 为代表，给出"在某个半径内绝不被攻破"的概率证明，**有保证但精度更低**。
- **检测防御**（Detection-based）：训练一个判别器把对抗样本从输入中"挑出来"。**通常被自适应攻击破解**，本讲不展开。

[NOTE] 笔记

本章 7.1–7.6 全在经验防御框架里推进。认证防御只在 7.10 做一段简介。检测防御在 Athalye et al. 2018 之后基本退出主流，知道有这条路即可。

7.1 不变量：Madry min-max 鞍点目标

7.1.1 从期望损失到鞍点

把"最坏情形"形式化。把鲁棒风险定义为

$$\mathcal{R}_{\text{rob}}(\theta) \ = \ \mathbb{E}_{(x,y)\sim\mathcal{D}}\Big[\max_{\|\delta\|_\infty \le \epsilon} L\big(f_\theta(x+\delta), y\big)\Big],$$

即"先把扰动 δ 推到使损失最大的位置，再对模型参数求期望"。经验化后即得 Madry 鞍点目标 (Madry et al., ICLR 2018)：

$$\min_\theta \ \frac{1}{n}\sum_{i=1}^{n} \underbrace{\max_{\|\delta_i\|_\infty \le \epsilon} L\big(f_\theta(x_i+\delta_i), y_i\big)}_{\text{inner maximization：攻击}}. \tag{7.1}$$

外层 $\min_\theta$ 是常规模型训练；内层 $\max_\delta$ 是攻击者，对每个样本独立寻找最具杀伤力的扰动。

7.1.2 为何是 min-max 而非 min-min?

这是初学者最常见的混淆。把 (7.1) 与"min-min 平均损失"对比：

- **min-min**（普通数据增广）：$\min_\theta \min_\delta L(f_\theta(x+\delta), y)$ ——同时让 θ 和 δ 减小损失。这没意义：训练时谁会主动选最简单的扰动?
- **min-max**（对抗训练）：训练时 δ **作为对手**先动，把损失推到最大；θ **作为防御者**再针对这个最坏点更新。

只有 min-max 才能让模型在测试期面对未知攻击时仍稳健——因为训练期它就是按"最坏情形"被磨过的。

7.1.3 与 GAN 的 minimax：相同与不同

维度	Madry AT	GAN
形式	$\min_\theta \max_\delta L$	$\min_G \max_D V(G, D)$
对手	每样本独立的扰动 δ_i（无参数）	全局判别器 D（有参数）
鞍点存在性	内层是连续紧集上的连续函数最大值，外层非凸；**鞍点未必存在但局部驻点有意义**	D, G 均参数化非凸，**鞍点同样难找**
求解方式	内层 PGD，外层 SGD（一边对冲一边走）	交替梯度下降

关键不同：AT 的"对手"δ 是 per-example、无记忆的，每个 mini-batch 重新生成；GAN 的判别器 D 跨样本共享参数、有记忆。这也是为何 AT 不会像 GAN 那样陷入模式坍塌——它每个样本独立解一次内层。

7.1.4 内层 $\max_\delta$ 为什么不可解?

直接求 (7.1) 内层最优有三重困难：

1. 神经网络 $f_\theta(\cdot)$ 关于输入 x **既非凸也非凹**，全局 max 是 NP-hard。
2. 可行域 $\{\delta : \|\delta\|_\infty \le \epsilon\}$ 是凸盒，但目标在该盒上呈高度非线性。
3. 梯度可用、二阶信息昂贵 □ 唯一现实做法是**一阶投影梯度**。

这把我们直接推向 PGD。

7.2 PGD-AT：用投影梯度近似内层 max

7.2.1 它解决了什么问题

(7.1) 写得很美但内层不可解。**PGD-AT 给出最朴素的工程答案**：用 K 步投影梯度上升近似内层 max，再在近似解 $x^{(K)}$ 上做一步外层 SGD。它是后续所有方法的 baseline。

7.2.2 形式化

内层 K 步迭代：

$$x^{(k+1)} \;=\; \Pi_{\mathcal{B}_\epsilon(x)}\Big(x^{(k)} \;+\; \alpha \cdot \mathrm{sign}\big(\nabla_x L(f_\theta(x^{(k)}), y)\big)\Big), \tag{7.2}$$

其中 Π 为到 ℓ_∞ 球的投影（逐维 clip 到 $[x-\epsilon, x+\epsilon]$），初值 $x^{(0)} = x + \mathrm{Unif}(-\epsilon, \epsilon)$（**随机初始化**至关重要：避免每次都陷入对称局部解）。最终对抗样本 $x' := x^{(K)}$。

外层 SGD：

$$\theta \leftarrow \theta - \eta \nabla_\theta L(f_\theta(x'), y). \tag{7.3}$$

7.2.3 推导：为什么用 sign 而不是原始梯度？

在 ℓ_∞ 约束下，**线性化目标的最优单步上升方向恰好是符号方向**：

$$\arg\max_{\|\delta\|_\infty \le \alpha} \langle \nabla_x L, \delta \rangle = \alpha \cdot \mathrm{sign}(\nabla_x L),$$

由 Hölder 不等式 $\langle g, \delta \rangle \le \|g\|_1 \|\delta\|_\infty$ 取等条件即得。这同时解释了 FGSM ($K = 1$) 的形式。

7.2.4 算法（一个 mini-batch）

1. 取 mini-batch $\{(x_i, y_i)\}_{i=1}^B$，**冻结当前** θ。
2. 对每个 i，从 $x_i^{(0)} = x_i + \mathrm{Unif}(-\epsilon, \epsilon)$ 出发，按 (7.2) 跑 K 步，得到对抗样本 $x_i' = x_i^{(K)}$。
3. 解冻 θ，按 (7.3) 用 $\{(x_i', y_i)\}$ 计算 SGD 梯度。
4. 更新 $\theta \leftarrow \theta - \eta \frac{1}{B} \sum_i \nabla_\theta L(f_\theta(x_i'), y_i)$。

7.2.5 超参 / 计算开销 / 经验现象

- **典型设置**（CIFAR-10, $\epsilon = 8/255$）：$\alpha = 2/255$，$K = 10$，外层 100–200 epochs。
- **经验法则**：$\alpha \approx \epsilon/4 \sim \epsilon/2$，且 $\alpha K \ge 2\epsilon$（保证能遍历到球面）。
- **开销**：每个 mini-batch 需要 K 次前向 + 反向 □ 训练时间约为标准训练的 K+1 倍。
- **结果区间**：CIFAR-10 / ResNet-18 上 clean acc ≈ 84%，AutoAttack 下 robust acc ≈ 44%（标准训练 robust=0%）。
- **失败模式**：K 太小（$K \le 3$）会出现 gradient masking 假象——见 7.8。

7.3 FOSC：内层 max 解到什么程度才够？（Wang & Ma et al., ICML 2019）

7.3.1 它解决了什么问题

PGD-AT 的核心遗留问题是：**内层 PGD 一定要 $K = 10$ 吗？$K = 5$ 不行吗？$K = 20$ 是不是更好？** 既无理论也无可量化的标准。FOSC（First-Order Stationary Condition）提供了第一个**可计算的内层求解质量分数**，并把它接到外层收敛性上。这是王老师本人 ICML 2019 的工作。

7.3.2 FOSC 定义

给定中间点 $x^{(k)} \in \mathcal{X}$（$\mathcal{X} = \{x : \|x - x_0\|_\infty \le \epsilon\}$），设 $f(\theta, x) := \ell(h_\theta(x), y)$，定义

$$c(x^{(k)}) = \max_{x \in \mathcal{X}} \langle x - x^{(k)}, \nabla_x f(\theta, x^{(k)}) \rangle. \tag{7.4}$$

直觉：**站在 $x^{(k)}$ 看可行域内有没有"还能往上爬"的方向**。$c(x^{(k)}) \ge 0$；$c = 0$ 当且仅当 $x^{(k)}$ 是内层 max 的一阶驻点。

闭式解（ℓ_∞ 约束下由 Hölder 立得）：

$$c(x^{(k)}) = \epsilon \|\nabla_x f\|_1 - \langle x^{(k)} - x_0, \nabla_x f \rangle.$$

每步 PGD 计算一次，几乎无额外开销。**c 越小代表内层解得越好**。

7.3.3 收敛定理（定理 7.1）

设 $\Delta = L_S(\theta_0) - \min_\theta L_S(\theta)$，外层步长 $\eta_t = \min\{1/L, \sqrt{\Delta/(LT\sigma^2)}\}$，每步内层满足 FOSC $\le \delta$，则

$$\frac{1}{T}\sum_{t=0}^{T-1} \mathbb{E}\,\|\nabla L_S(\theta_t)\|_2^2 \;\le\; 4\sigma\sqrt{\frac{L\Delta}{T}} \;+\; 5L_{gx}^2\frac{\delta}{\mu}, \tag{7.5}$$

其中 $L = L_{\theta x}^2/\mu + L_{\theta\theta}$，$\mu$ 为内层目标在 x^* 邻域的强凹常数（局部假设）。

7.3.4 证明 sketch（核心两步即可）

1. **Danskin 定理**：外层目标 $\phi(\theta) = \max_\delta L(f_\theta(x+\delta), y)$ 处处可微，且 $\nabla\phi(\theta) = \nabla_\theta L|_{x^*}$，其中 x^* 是内层精确解。□ 我们关心的是"用 $x^{(K)}$ 代 x^*"造成的梯度误差。
2. **FOSC □ 距离界**：在 x^* 邻域强凹假设下，$c(x^{(K)}) \le \delta$ 蕴含 $\|x^{(K)} - x^*\| \le O(\delta/\mu)$（由强凹的"梯度差—距离差"对应）。
3. **梯度误差被控**：$\|\nabla_\theta L|_{x^{(K)}} - \nabla_\theta L|_{x^*}\| \le L_{\theta x} \cdot \|x^{(K)} - x^*\| \le L_{\theta x}\delta/\mu$。
4. 把这个偏差代入标准非凸 SGD 收敛证明（含方差 σ^2、smoothness L）即得 (7.5)。

结论的可读版：内层 FOSC 越小（$\delta \to 0$），第二项消失，外层就退化为标准非凸 SGD 速率 $O(1/\sqrt{T})$。**反过来：内层解得差则外层注定有不可消除的偏差项**——这就是为什么 PGD-3 训出来的模型 robust acc 永远上不去。

7.3.5 实证观察

PDF 第 14–15 页的实验：

- **PGD 步长扫描**：$\alpha = \epsilon/4, \epsilon/2$ 时鲁棒性最佳，对应 FOSC 分布**最集中在 0 附近**。
- **PGD 步数扫描**：$K \in \{20, 30\}$ 比 $K = 10$ 略好，FOSC 分布更紧。
- **损失分布**几乎不区分鲁棒性差异，**FOSC 分布反而能区分**——它是比 loss 更 sharp 的指示器。

7.3.6 Dynamic-α（warm-up 的理论解释）

进一步观察：训练**早期**用强 PGD（K 大、FOSC 小）反而**过拟合**到强对抗样本，导致后期鲁棒性下降。FOSC 给出干净解释：早期模型未稳定，强对抗样本噪声极大；训练初期允许高 FOSC（弱攻击 FGSM），后期再压低 FOSC（强 PGD），即"FOSC schedule"。这等价于业界常用的 **warm-up trick**——只是终于有了理论 backing。

7.4 TRADES：把鲁棒拆成自然误差 + 边界误差（Zhang et al., ICML 2019）

7.4.1 它解决了什么问题

PGD-AT 直接最小化 worst-case 损失，但这个目标和"自然准确率"是冲突的：损失被对抗样本主导，模型在 clean 数据上必然让步（PGD-AT 通常 clean acc 比标准训练低 10%+）。**TRADES 的想法是把对抗鲁棒性显式拆成两项**——*自然误差*与*决策边界稳定性*——然后用一个权重 β 显式调控两者的 trade-off。这样既让用户拿回了控制权，也提供了一个新的优化目标。

7.4.2 形式化

把鲁棒错误分解：

$$\mathcal{R}_{\text{rob}} \;=\; \underbrace{\Pr[f(x) \ne y]}_{\mathcal{R}_{\text{nat}}} \;+\; \underbrace{\Pr\big[f(x) = y \text{ 但} \exists\delta:\; f(x+\delta) \ne f(x)\big]}_{\mathcal{R}_{\text{bdy}}}.$$

$\mathcal{R}_{\text{nat}}$ 是自然误差；$\mathcal{R}_{\text{bdy}}$ 度量"决策边界离 x 太近"的概率。**TRADES 损失**：

$$\mathcal{L}_{\text{TRADES}}(\theta; x, y) \;=\; \underbrace{\mathrm{CE}\big(f_\theta(x), y\big)}_{\text{自然项}} + \beta \cdot \underbrace{\max_{\|\delta\| \le \epsilon} \mathrm{KL}\big(f_\theta(x) \,\|\, f_\theta(x+\delta)\big)}_{\text{鲁棒正则项}}. \tag{7.6}$$

外层 $\min_\theta \mathbb{E}\mathcal{L}_{\text{TRADES}}$，内层依然用 PGD 但**用 KL 而非 CE 作为攻击目标**。

7.4.3 推导：KL 方向为什么是 $f(x) \,\|\, f(x+\delta)$?

这是 TRADES 最容易写反的地方。设 $P = f_\theta(x)$（"教师"分布），$Q = f_\theta(x+\delta)$（"学生"分布）。

- **正向 KL** $\mathrm{KL}(P\|Q) = \sum_k P_k \log(P_k/Q_k)$：$P$ 固定为参考，Q 必须**覆盖 P 的所有支持**。优化时迫使 $Q \to P$，即让对抗预测"贴回"自然预测。**这正是我们想要的**：边界要远离 x，扰动后的预测不能偏离自然预测。
- **反向 KL** $\mathrm{KL}(Q\|P)$：迫使 $P \to Q$，即让自然分布去"投降"到对抗分布。这与目的相悖，会主动牺牲 clean acc。

直觉版：正向 KL 把"自然预测"作为锚，对抗预测是被拉回的对象；反向 KL 反了过来，让自然预测被对抗预测拉走。**只有正向才同时定义了"边界稳定"这个语义**。

把 (7.6) 看成"自然项 + 局部 Lipschitz 正则"：第二项控制 f 在 x 附近 KL 意义下的振荡。$\beta \to 0$ 退化为标准训练；$\beta \to \infty$ 接近 PGD-AT。

7.4.4 算法（一个 mini-batch）

1. 计算自然预测 $P_i = f_\theta(x_i)$（softmax 输出，**作为常数缓存，不回传梯度到 P 这一支**——TRADES 实现里通常用 `.detach()`）。
2. 对每个 i，PGD 内循环：从 $x_i^{(0)} = x_i + \mathrm{Unif}(-\epsilon, \epsilon)$ 出发，按 $\nabla_x \mathrm{KL}(P_i \,\|\, f_\theta(x_i^{(k)}))$ 的 sign 上升 K 步，得 x_i'。
3. 在解冻 θ 后，按 (7.6) 计算 $\mathrm{CE}(f_\theta(x_i), y_i) + \beta\,\mathrm{KL}(f_\theta(x_i) \,\|\, f_\theta(x_i'))$。
4. SGD 更新 θ。

7.4.5 超参 / 经验现象

- **典型 β**：CIFAR-10 取 6（PDF 与原论文一致）；$\beta = 1$ 偏标准训练，$\beta = 10$ 偏 PGD-AT。
- **clean / robust**（CIFAR-10, ResNet-18, $\epsilon = 8/255$, AutoAttack）：clean ≈ 82%，robust ≈ 49%。**比 PGD-AT 多 ~5% robust，少 ~2% clean**——这正是显式 trade-off 的好处：用户可调。
- **声誉**：NeurIPS 2018 Adversarial Vision Challenge 第一名。

7.5 MART：把误分类样本"找回来"（Wang et al., ICLR 2020）

7.5.1 它解决了什么问题

PGD-AT 与 TRADES 都默认"对抗样本是在正确分类样本周围生成的"——但**对那些当前已经被错分的样本 x（$f(x) \neq y$）呢**？严格说，"对抗样本"概念在 $S^- = \{x : f(x) \neq y\}$ 上根本没定义。PDF 第 29–30 页给出关键实验：取同等大小的 S^+（正确分类，13%）和 S^-（误分类，13%）两个子集，发现：

- 在**内层最大化**端用强/弱攻击区分 S^+ 和 S^-：影响**可忽略**。
- 在**外层最小化**端用不同正则（强弱）区分两子集：影响**显著**。

结论：误分类样本对最终鲁棒性的贡献被 PGD-AT/TRADES 系统性低估。MART 的对策是在外层损失里**显式给 S^- 加权**。

7.5.2 形式化：misclassification-aware 风险

把对抗错误展开为正确/错误两段：

$$\mathcal{R}_{\text{adv}}(\theta) = \mathbb{E}\Big[\, \mathbb{1}\{f(x) = y\} \cdot \mathbb{1}\{\exists \delta,\, f(x+\delta) \neq y\} \;+\; \mathbb{1}\{f(x) \neq y\} \,\Big].$$

第二项 $\mathbb{1}\{f(x) \neq y\}$ 不可微，需要一个**可微紧上界**作为代理。MART 选 $1 - p_y(x;\theta)$，其中 p_y 是真类的 softmax 概率：

- $f(x) = y \Leftrightarrow p_y > \max_{k\neq y} p_k$；当 $f(x) \neq y$ 时 p_y 通常较小，$1 - p_y \to 1$。
- $1 - p_y \in [0,1]$ 且关于 θ 可微 □ 完美的连续松弛。
- $1 - p_y \geq \mathbb{1}\{f(x) \neq y\}$ 不严格成立，但作为"误分类严重度"的连续度量是业界共识。

把它当作**样本权重**插到 KL 正则前面：

$$\mathcal{L}_{\text{MART}}(\theta; x, y) \;=\; \underbrace{\text{BCE}\big(f_\theta(x'),\, y\big)}_{\text{对抗项}} + \lambda \cdot \underbrace{(1 - p_y(x;\theta))}_{\text{误分类权重}} \cdot \text{KL}\big(f_\theta(x) \,\|\, f_\theta(x')\big), \tag{7.7}$$

其中 BCE（Boosted CE）定义为

$$\text{BCE}(p, y) \;=\; -\log p_y \;-\; \log\Big(1 - \max_{k\neq y} p_k\Big).$$

7.5.3 推导细节：为什么是 BCE 而不是 CE?

CE 只惩罚 $-\log p_y$，**不显式压低 runner-up 类**（即 $\max_{k\neq y} p_k$）。但对抗鲁棒性的关键恰是 runner-up——攻击者把概率从 y 推到 runner-up 才让模型翻车。BCE 多加的 $-\log(1 - \max_{k\neq y} p_k)$ 直接把 runner-up 概率压向 0，**和误分类样本的语义直接对齐**。

为什么权重是 $1 - p_y$ 而不是 1？看 (7.7) 第二项的极端情形：

- 若 x 已经被高置信度正确分类（$p_y \approx 0.99$），权重 ≈ 0.01 □ KL 几乎不起作用，避免在已稳的样本上浪费正则预算。
- 若 x 被严重误分类（$p_y \approx 0.05$），权重 ≈ 0.95 □ 强力把 $f(x')$ 拉回 $f(x)$，相当于在 S^- 上下重药。

7.5.4 算法（一个 mini-batch）

1. **PGD 内循环**（与 PGD-AT 完全相同）：得到 x_i'。
2. 计算自然概率 $p_y^i = [f_\theta(x_i)]_{y_i}$（注意需保留梯度——MART 的 $1 - p_y$ 项是要回传的）。
3. 计算 BCE 项 $-\log p_{y_i}^i(x_i') - \log(1 - \max_{k\neq y_i} p_k^i(x_i'))$。
4. 计算加权 KL 项 $(1 - p_y^i) \cdot \text{KL}(f_\theta(x_i) \,\|\, f_\theta(x_i'))$。
5. 求和、SGD 更新。

7.5.5 超参 / 经验现象

- **典型 λ**：CIFAR-10 取 5–6。
- **clean / robust**（CIFAR-10, ResNet-18, AutoAttack）: clean ≈ 83%, robust ≈ 50%——比 PGD-AT 多 ~6%，与 TRADES 相当但**对 misclassified 子集的 robust 提升尤其显著**。
- **小坑**：$1 - p_y$ 必须从 **clean 输入** x 算起（不是 x'），否则失去"我先看你 clean 时的状态"这一语义。

7.6 AWP：在权重空间也做对抗（Wu, Xia & Wang, NeurIPS 2020）

7.6.1 它解决了什么问题

到此为止 PGD-AT / TRADES / MART 都在改 θ 与 δ 在**输入空间**的关系。但实测有一个更刺眼的现象：**鲁棒泛化间隙**（train robust acc − test robust acc）远大于标准泛化间隙——往往达 30%+。这意味着模型对**输入扰动**或许鲁棒了，但对**权重邻域**的扰动一点也没被约束，**测试期权重一旦落到 sharp minima 就崩**。AWP 的目标就是把"对抗"从输入空间复制到权重空间。这是王老师团队 NeurIPS 2020 的工作。

7.6.2 Flat minima 与对抗鲁棒的桥梁

PDF 第 18–22 页讲透了三件事：

1. **标准训练**已知结论（Hao Li et al., NeurIPS 2018）：**weight loss landscape 越平坦 □ 标准泛化间隙越小**。
2. 在 AT 里，**这个结论仍然成立**——但前提是必须 **on-the-fly 生成对抗样本**来画 landscape。预先固定一批对抗样本去画 landscape 会得到错误图像（PDF 第 19 页"Failed to draw the conclusion"那张图），因为预先的样本不再是当前 θ 周围的最坏点。
3. 跨 AT / TRADES / MART / RST / AT-ES 五种方法，**weight loss landscape 的平坦度与 robust generalization gap 强负相关**。

理论层面（PAC-Bayesian bound 启发）：泛化界含一个"权重邻域内的损失起伏"项；这项越小（landscape 越平），泛化越好。**因此鼓励平坦化的最直接方式就是把"邻域内 max"显式塞进训练目标**——这就是 AWP 的 double min-max。

7.6.3 形式化：double min-max

$$\min_{\theta} \max_{\|v\| \le \gamma \|\theta\|} \frac{1}{n} \sum_{i=1}^{n} \max_{\|\delta_i\|_\infty \le \epsilon} L\big(f_{\theta+v}(x_i + \delta_i), y_i\big). \tag{7.8}$$

三层结构：

- **最内** $\max_{\delta_i}$：每样本的局部 worst-case 输入扰动（与 PGD-AT 同）。
- **中层** $\max_v$：对**全 batch 共享**的 worst-case 权重扰动。注意约束 $\|v\| \le \gamma\|\theta\|$——逐层归一化，避免大模长层吃掉小模长层。
- **外层** $\min_\theta$：在被 v 扰动过的"邻居"上仍要小损失 □ 强制 landscape 在 θ 邻域内全平。

对偶解读（PDF 第 22 页）：输入扰动是"局部 worst per example"，权重扰动是"全局 worst over many examples"。两者正交。

7.6.4 算法（一个 mini-batch）

1. **冻结** θ，对每个 i 跑 PGD-K 得 x_i'（与 PGD-AT 同）。
2. **求 worst-case** v：用一步上升（逐层归一化）

$$v \;=\; \gamma\,\|\theta_\ell\| \cdot \frac{\nabla_\theta \frac{1}{n}\sum_i L(f_\theta(x_i'), y_i)}{\|\nabla_\theta L\|_\ell} \qquad (\text{逐层}\ell)$$

   即先求外层目标对 θ 的梯度，沿其方向扰动。
3. **临时把权重设为** $\theta + v$，在 $\theta + v$ 处计算同一批 $\{x_i'\}$ 的损失梯度 $g = \nabla_\theta L|_{\theta+v}$。
4. **恢复** θ（不保留 v！v 只用作"探测方向"），用 g 更新：$\theta \leftarrow \theta - \eta g$。

7.6.5 推导：为什么 max-on-θ 解释为 flat minima

把 (7.8) 中层展开 Taylor 一阶：

$$\max_{\|v\| \le \rho} L(\theta + v) \;\approx\; L(\theta) \;+\; \rho\,\|\nabla_\theta L\|.$$

最小化这个上界等价于同时压低 $L(\theta)$ 和 $\|\nabla_\theta L\|$——后者正是"平坦"的一阶代理（梯度小 □ 局部曲面平）。二阶展开则会同时压制 Hessian 谱，是更严格的平坦化。这与 SAM (Sharpness-Aware Minimization) 在标准训练里的推导是同构的；AWP 可以看作是 **SAM 的对抗训练版本**。

7.6.6 超参 / 经验现象

- **典型** γ：5×10^{-3}（CIFAR-10）。γ 太大会让 $\theta + v$ 偏离过远导致训练不稳；太小则平坦化效果消失。
- **正交性 / 即插即用**：AWP 可叠加在 AT / TRADES / MART / RST 上，普遍带来 1–3% AutoAttack robust acc 提升，几乎不损 clean。
- **代价**：每 mini-batch 多一次前向反向（求 v）+ 一次前向反向（在 $\theta + v$ 处求 g），约 1.5–2× PGD-AT 的 wall-clock。

- **荣誉**：CVPR 2021 对抗鲁棒性竞赛冠军方案的核心组件。

7.7 对比一览表

方法	损失公式简写	关键改动	关键超参	clean / robust（CIFAR-10, ResNet-18, AA）
标准训练	$\mathrm{CE}(f(x), y)$	—	—	95% / **0%**
PGD-AT (Madry 2018)	$\mathrm{CE}(f(x'), y)$	inner PGD + outer SGD	$\alpha = 2/255$, $K = 10$	84% / 44%
FOSC-AT (Wang & Ma 2019)	同上 + warm-up	动态调内层强度	FOSC 阈值 δ	84% / 46%
TRADES (Zhang 2019)	(7.6)	自然 + KL 边界正则	$\beta = 6$	82% / 49%
MART (Wang 2020)	(7.7)	$1 - p_y$ 加权 KL + BCE	$\lambda = 5$–6	83% / 50%
AWP (Wu 2020)	(7.8)	加权重对抗 max-on-θ	$\gamma = 5 \times 10^{-3}$	与 base 同 / +1–3%
TRADES + AWP	(7.6)+(7.8)	叠加	$\beta = 6$, $\gamma = 5 \times 10^{-3}$	81% / 52%

7.8 反模式：Gradient Masking / Obfuscated Gradients

7.8.1 现象

很多 2017–2018 的"防御"在论文里写出 90%+ robust acc，但 Athalye, Carlini & Wagner（ICML 2018, "Obfuscated Gradients Give a False Sense of Security"）证明：它们没有真鲁棒，只是**让攻击者拿不到有用梯度**——一旦换种攻击立即崩盘。这种现象统称 **gradient masking / obfuscated gradients**。

7.8.2 三个诊断信号（"看到 X 就要怀疑"）

1. **One-step (FGSM) 比 iterative (PGD) 更强**：正常情况下 PGD 严格不弱于 FGSM（PGD 第一步就是 FGSM）。**反过来 □ 多步迭代被某种数值技巧破坏**（如随机预处理、不可导层）。
2. **黑盒攻击比白盒攻击更强**：迁移攻击不依赖目标模型梯度，**白盒应永远 ≥ 黑盒。反过来 □ 白盒梯度已被遮蔽**。
3. **大 ϵ 仍接近 100% 准确**：若 $\epsilon = 0.5$（已可任意改图）模型仍坚挺，**违反"足够大扰动应能任意改变标签"的常识 □ 必是数值/梯度问题**。

补充信号：unbounded ϵ 攻击仍失败、随机化预处理使损失曲面非光滑、shattered gradients（不可导激活如 quantize/round）。

7.8.3 案例

- **Defensive distillation**（Papernot 2016）：用高温 softmax 蒸馏，使输入梯度近似为 0 □ FGSM/PGD 一步接近全失效；但 C&W 攻击（用 logits 而非 softmax）可一击攻破，gradient masking 的经典代表。
- **Thermometer encoding / input quantization** 等离散预处理：直接破坏可导性。

7.9 评估金标准 AutoAttack（Croce & Hein, ICML 2020）

7.9.1 为什么是金标准

单一 PGD-20 极易被 gradient masking 蒙骗。AutoAttack 的回应：**集成 4 种互补无超参攻击**，任一攻破即记不鲁棒。这对评估者友好（无需调参），对论文作者形成强约束（无法挑攻击）。已成 RobustBench leaderboard 默认评估协议。

7.9.2 4 种攻击各覆盖什么

攻击	类型	捕捉的失败模式
APGD-CE	白盒、自适应步长 PGD + 交叉熵	普通梯度可用模型的 baseline；自适应步长缓解步长难调
APGD-DLR	白盒、自适应步长 PGD + Difference-of-Logits-Ratio 损失	logits **缩放/平移不变**，破解"靠 logits 数值幅度伪装鲁棒"的防御
FAB	白盒、几何最小扰动	直接找最小 $\|\delta\|$ □ 对**非平滑边界**的防御特别有效，发现 PGD 漏看的近距离边界
Square Attack	黑盒、score-based、随机搜索方块扰动	不需要梯度 □ **抵御 gradient masking** 的最后兜底

7.9.3 实践协议

声称鲁棒前先用 AutoAttack 跑一遍；任何"PGD-20 高、AutoAttack 暴跌"的方法都要**怀疑 gradient masking**。

7.10 认证防御（一段简介）

[NOTE] 笔记

本节内容**未在课件覆盖**，仅作为背景指针。

经验防御（AT 系）只能给"AutoAttack 下 robust acc"这种**经验数字**，无形式保证。**认证防御**给出"在某半径 r 内绝不被攻破"的概率证明。代表方法 **randomized smoothing**（Cohen et al., 2019）：把分类器 f 输入端注入高斯噪声 $\mathcal{N}(0,\sigma^2 I)$，定义"平滑分类器"$g(x) = \arg\max_c \Pr_{\eta\sim\mathcal{N}(0,\sigma^2 I)}[f(x+\eta)=c]$；该 g 在 ℓ_2 球内有可证半径 $r = \sigma\Phi^{-1}(p_A)$，其中 p_A 是真类被采到的概率下界。代价：精度低、半径有限、ℓ_∞ 难处理。**经验防御 + 认证防御往往互补**。

[EX] 数值对比：PGD-AT vs TRADES vs MART 在同一玩具点

设 2 类分类，模型给样本 x（真标签 $y=0$）输出 softmax $f(x) = (p_0, p_1)$；其对抗样本 x' 输出 $f(x') = (0.4, 0.6)$（即 x' 已被推过决策边界）。比较 $p_y(x) \in \{0.6, 0.95\}$ 两情形下三种损失：

情形 A：clean 已边缘正确， $f(x) = (0.6, 0.4)$（$p_y = 0.6$）

项	计算	数值
PGD-AT $\mathrm{CE}(f(x'), y)$	$-\log 0.4$	**0.916**
TRADES 自然项 $\mathrm{CE}(f(x), y)$	$-\log 0.6$	0.511
TRADES KL $\mathrm{KL}(f(x)\|f(x'))$	$0.6\log\frac{0.6}{0.4} + 0.4\log\frac{0.4}{0.6}$	0.081
TRADES 总 ($\beta = 6$)	$0.511 + 6\times 0.081$	**0.997**
MART BCE $-\log 0.4 - \log(1-0.6)$	$0.916 + 0.916$	1.832
MART 加权 KL $(1-0.6)\times 0.081$	0.4×0.081	0.032
MART 总 ($\lambda = 5$)	$1.832 + 5\times 0.032$	**1.994**

情形 B：clean 高置信正确， $f(x) = (0.95, 0.05)$（$p_y = 0.95$）

项	计算	数值
PGD-AT CE$(f(x'), y)$	$-\log 0.4$	**0.916**
TRADES 自然项	$-\log 0.95$	0.051
TRADES KL KL$(f(x) \| f(x'))$	$0.95 \log \frac{0.95}{0.4} + 0.05 \log \frac{0.05}{0.6}$	0.697
TRADES 总 ($\beta = 6$)	$0.051 + 6 \times 0.697$	**4.233**
MART BCE	同上	1.832
MART 加权 KL $(1 - 0.95) \times 0.697$	0.05×0.697	0.035
MART 总 ($\lambda = 5$)	$1.832 + 5 \times 0.035$	**2.007**

读图：

1. **PGD-AT 对 clean 置信度完全无感**：A、B 两种情形损失都是 0.916，只看对抗样本被错分的程度。
2. **TRADES 对"clean 已稳"的样本变得更激进**：B 情形 KL 项暴涨到 0.697（边界离 x 太近），总损失 4.233 远超 A——它把更多预算花在"边界推远"上。
3. **MART 反过来对 clean 已稳的样本几乎不加 KL 权重**：A 的加权 KL = 0.032，B 的加权 KL = 0.035，相差极小；它把 KL 预算几乎全留给 S^-（$1 - p_y$ 大的那批）。

这正好对照三种损失的设计哲学：PGD-AT 不区分；TRADES 按"边界稳定性是否被破坏"分配；MART 按"clean 时是否还在错"分配。

概念关系

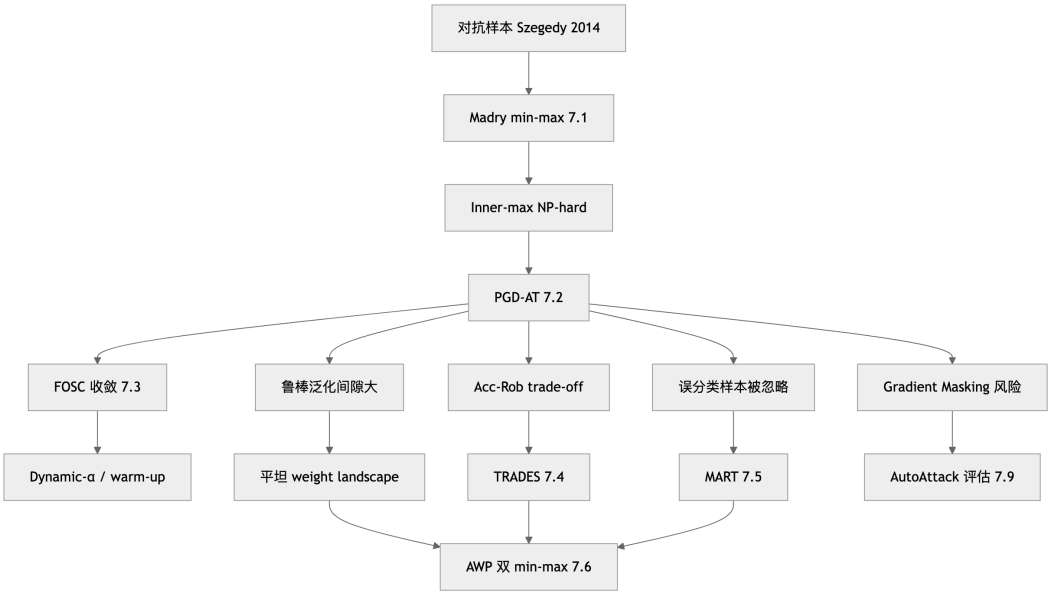

结论

[WARN] 易错点

- **PGD 必须随机初始化**：否则陷入对称局部解，FOSC 难下降。
- **TRADES 中 KL 方向不能反**：必须 $\mathrm{KL}(f(x)\,\|\,f(x'))$；反向 KL 会让自然分布去逼近对抗分布，破坏 clean acc。
- **MART 的 $1-p_y$ 必须从 clean x 算起**：用 x' 算就失去"先看你 clean 状态"的语义。
- **AWP 的 v 是探测方向不是新权重**：每步用完即丢，不要存。
- **不要用预生成对抗样本画 weight landscape**：必须 on-the-fly。
- **不要只用 PGD-20 评估**：极易被 gradient masking 蒙骗，必须报 AutoAttack。
- **$\alpha=\epsilon$ 是常见错误**：一步直接跨到边界，等价 FGSM，inner-max 严重欠求解。
- **Athalye 三信号要会反向用**：自检自家防御时主动造这三类条件。

[TIP] 期中复习要点

- 默写 (7.1) min-max；解释为何不是 min-min；与 GAN minimax 的相同/不同。
- 默写 (7.2) PGD 迭代；解释为什么是 sign（Hölder 取等）以及为什么要随机初始化。
- FOSC 定义 (7.4) 与闭式解；定理 7.1 结论形式（不必证）；"FOSC 是比 loss 更 sharp 的指示器"。
- TRADES 损失 (7.6)；KL 方向 $f(x)\,\|\,f(x+\delta)$ 的语义论证；β 含义。
- MART 损失 (7.7)；$1-p_y$ 作为 $\mathbb{1}\{f(x)\neq y\}$ 的可微紧上界；为什么用 BCE。
- AWP 双 min-max (7.8)；"输入扰动局部 / 权重扰动全局"对偶；与 SAM 的关系；flat minima 解释。
- Gradient masking 三个诊断信号；AutoAttack 4 攻击各覆盖什么。

记号速查

记号	含义
x, y	干净样本 / 标签
x', δ	对抗样本 / 扰动，$x'=x+\delta$
ϵ	扰动预算，$\|\delta\|_\infty \le \epsilon$
α, K	PGD 步长 / 步数
f_θ, p_y	模型 / 真类 softmax 概率
$\Pi_{\mathcal{B}_\epsilon}$	投影到 ℓ_∞ 球
$c(x^{(k)})$	FOSC 收敛得分 (7.4)
β	TRADES 鲁棒正则系数
λ	MART KL 项系数
v, γ	AWP 权重扰动 / 半径比
$\mathcal{R}_{\mathrm{nat}}, \mathcal{R}_{\mathrm{bdy}}$	自然误差 / 边界误差
S^+, S^-	正确分类 / 误分类样本子集
AA	AutoAttack